



دانشگاه صنعتی امیرکبیر

(پلی‌تکنیک تهران)

دانشکده‌ی مهندسی صنایع و سیستم‌های مدیریت

پایان‌نامه‌ی کارشناسی ارشد گرایش مهندسی صنایع – سیستم‌های سلامت

## توسعه مدل تشخیص آریتمی قبلی با استفاده از الگوریتم‌های یادگیری ماشین

نگارش

پریا قره داغی

اساتید راهنما

دکتر عباس احمدی

دکتر مجید امین نیری

استاد مشاور

سید حبیب الله رحمتی

۱۴۰۲ بهمن

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ

## صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته دفاع



اینجانب پریا قره داغی متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی استادی دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آن‌ها استفاده شده است، مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبل‌اً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادرشده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است.

نقل مطالب با ذکر مآخذ بلامانع است.

پریا قره داغی

امضا



## چکیده

آریتمی قلبی یکی از شایع‌ترین انواع بیماری‌های قلبی است که رایج‌ترین نوع آن فیبریلاسیون دهلیزی است. فیبریلاسیون دهلیزی باعث ایجاد مشکلات متعدد قلبی مانند نارسایی قلبی، ایجاد لخته‌ی خونی و سکته‌ی مغزی می‌شود و بیماری خطرناکی به شمار می‌رود که جان انسان‌ها را تهدید می‌کند. در پژوهش پیش‌رو با استفاده از روش‌های هوش مصنوعی به طبقه‌بندی سیگنال‌های الکتروکاردیوگرام جهت تشخیص فیبریلاسیون دهلیزی پرداخته شده است. پایگاه داده‌ی مربوط به بانک داده‌ی چالش ۲۰۱۷ فیزیونت بوده و شامل سیگنال‌های الکتروکاردیوگرام کوتاه تک لید می‌باشد. در روش پیشنهادی با ترکیب دو رویکرد مبتنی بر روش‌های یادگیری عمیق و روش‌های یادگیری ماشین سنتی و بهره بردن از مزایای آن‌ها، سیگنال‌های الکتروکاردیوگرام در چهار کلاس مربوط به ریتم نرمال سینوسی، فیبریلاسیون دهلیزی، سایر ریتم‌ها و ریتم‌های طبقه‌بندی شده‌اند. به این ترتیب که ویژگی‌هایی که به صورت خودکار از شبکه‌ی عمیق استخراج شده‌اند با ویژگی‌های ساختاری و کلیدی مربوط به سیگنال الکتروکاردیوگرام ترکیب شده و به عنوان ورودی در یک الگوریتم طبقه‌بند سنتی استفاده شده‌اند. ابتدا از لایه ماقبل آخر یک شبکه عمیق ترکیبی CNN-LSTM تعداد ۶۰ ویژگی عمیق استخراج شده و با ۶۴ ویژگی ساختاری استخراج شده ترکیب شده‌اند. سپس با استفاده از روش تحلیل مولفه‌ی اصلی تعداد ۳۰ تا از مهم‌ترین ویژگی‌های عمیق و ساختاری به دست آمده است. در نهایت ویژگی‌های به دست آمده با استفاده از الگوریتم طبقه‌بند جنگل تصادفی در چهار کلاس مذکور طبقه‌بندی شده‌اند. روش پیشنهادی موفق شده است به دقت ۹۴ درصد دست یابد که مقایسه‌ها نشان می‌دهد روش پیشنهادی توانسته از سایر روش‌های موجود پیشی بگیرد.

## واژه‌های کلیدی:

یادگیری ماشین، یادگیری عمیق، فیبریلاسیون دهلیزی، شبکه‌ی عصبی کانولوشنال، جنگل تصادفی.

## صفحه

## فهرست مطالب

۱	.....	فصل اول.....
۴	.....	۱-۱- بیان مساله و ضرورت تحقیق
۵	.....	۱-۲- روش تحقیق
۶	.....	۱-۳- نوآوری تحقیق
۷	.....	۱-۴- ساختار پایان نامه
۸	.....	فصل دوم.....
۹	.....	۲-۱- تعریف آریتمی قلبی
۹	.....	۲-۱-۱- انواع آریتمی قلبی
۱۰	.....	۲-۲- تعریف فیبریلاسیون دهلیزی
۱۱	.....	۲-۲-۱- درمان فیبریلاسیون دهلیزی
۱۱	.....	۲-۲-۲- علائم فیبریلاسیون دهلیزی
۱۲	.....	۲-۲-۳- انواع فیبریلاسیون دهلیزی
۱۲	.....	۲-۲-۴- علت بروز فیبریلاسیون دهلیزی
۱۳	.....	۲-۲-۵- عوامل ابتلاء به فیبریلاسیون دهلیزی
۱۳	.....	۲-۲-۶- فاکتورهای موثر در ابتلاء
۱۴	.....	۲-۲-۷- عوارض بیماری
۱۴	.....	۲-۲-۸- جلوگیری از ابتلاء به فیبریلاسیون دهلیزی
۱۵	.....	۲-۲-۹- تشخیص فیبریلاسیون دهلیزی
۱۶	.....	۲-۲-۱۰- اجزای تشکیل دهنده سیگنال الکتروکاردیوگرام
۱۸	.....	۲-۲-۱۱- تعریف ویژگی های فیبریلاسیون دهلیزی در سیگنال الکتروکاردیوگرام
۲۰	.....	۲-۳- هوش مصنوعی
۲۱	.....	۲-۴- یادگیری ماشین
۲۱	.....	۲-۴-۱- یادگیری با ناظر
۲۲	.....	۲-۴-۲- یادگیری بدون ناظر
۲۲	.....	۲-۴-۳- یادگیری تقویتی
۲۳	.....	۲-۵- یادگیری عمیق
۲۳	.....	۲-۶- مروری بر روش های ارائه شده برای تشخیص فیبریلاسیون دهلیزی
۴۵	.....	۲-۷- جمع بندی
۴۷	.....	فصل سوم.....
۴۹	.....	۳-۱- پیش پردازش مجموعه دادگان

۴۹	۳-۱-۱- نرمال‌سازی سیگنال‌ها
۴۹	۳-۱-۲- یکسان‌سازی طول سیگنال‌ها
۵۰	۳-۱-۳- تولید داده
۵۳	۳-۲- معماری شبکه طبقه‌بندی
۵۳	۳-۲-۱- استخراج ویژگیهای ساختاری از سیگنال.
۵۴	۳-۲-۱-۱- دسته اول: ویژگی‌های شکل سیگنال کامل.
۵۷	۳-۲-۱-۲- دسته دوم: ویژگی‌های قطعه‌های سیگنال.
۵۸	۳-۲-۱-۳- دسته سوم: ویژگی‌های بازه <b>RR</b>
۵۸	۳-۲-۲- استخراج ویژگی‌های عمیق سیگنال
۵۹	۳-۲-۲-۱- شبکه‌های عصبی کانولوشنال
۶۰	۳-۲-۲-۲- شبکه‌ی عصبی حافظه طولانی کوتاه مدت
۶۳	۳-۲-۳- الگوریتم کاهش بعد تحلیل مولفه اصلی
۶۴	۳-۲-۴- الگوریتم طبقه‌بند جنگل تصادفی
۶۵	۳-۳- جمع‌بندی
۶۶	<b>فصل چهارم</b>
۶۷	۴-۱- ابزار پژوهش
۶۷	۴-۲- پایگاه داده
۶۸	۴-۲-۱- معرفی چالش فیزیونت
۶۹	۴-۲-۲- مجموعه دادگان چالش فیزیونت
۷۱	۴-۳- معرفی معیارهای سنجش
۷۲	۴-۳-۱- معیار <i>Precision</i>
۷۲	۴-۳-۲- معیار <i>Recall</i>
۷۲	۴-۳-۳- معیار <i>F1_score</i>
۷۳	۴-۳-۴- معیار <i>Support</i>
۷۳	۴-۳-۵- منحنی <i>ROC</i>
۷۴	۴-۴- تنظیم ابرپارامترها
۷۴	۴-۴-۱- ابرپارامترهای شبکه <i>CNN-LSTM</i>
۷۸	۴-۴-۲- ابرپارامترهای روش تحلیل مولفه اصلی
۷۹	۴-۴-۳- ابرپارامترهای شبکه‌ی طبقه‌بند جنگل تصادفی
۸۰	۴-۵- نتایج طبقه‌بندی روش پیشنهادی
۸۲	۴-۶- ماتریس درهم ریختگی
۸۳	۴-۷- مقایسه روش پیشنهادی با کارهای پیشین
۸۶	۴-۸- جمع‌بندی
۸۸	<b>فصل پنجم</b>

۸۹	۱- جمع‌بندی
۸۹	۲- پیشنهادات
۹۱	منابع و مراجع

## صفحه

## فهرست اشکال

شکل ۱-۲. اجزای تشکیل دهنده سیگنال الکترو کار دیوگرام.	۱۷
شکل ۲-۲. مقایسه قلب فرد سالم و قلب فرد مبتلا به فیبریلاسیون دهلیزی.	۱۸
شکل ۳-۲. نمایش دو سیگنال الکترو کار دیوگرام در ردیف اول و ردیف دوم فاصله‌ی RR متناظر با آن‌ها.	۱۹
شکل ۴-۲. معماری روش پیشنهادی افادلا و همکاران.	۲۵
شکل ۵-۲. معماری روش پیشنهادی فن و همکاران در سال ۲۰۱۸.	۲۶
شکل ۶-۲. معماری روش پیشنهادی فن و همکاران در سال ۲۰۱۹.	۲۷
شکل ۷-۲. معماری روش پیشنهادی شیا و همکاران.	۲۸
شکل ۸-۲. معماری روش پیشنهادی اندرسن و همکاران.	۲۹
شکل ۹-۲. معماری روش پیشنهادی پتمzas و همکاران.	۳۰
شکل ۱۰-۲. معماری روش پیشنهادی وو و همکاران.	۳۱
شکل ۱۱-۲. معماری روش پیشنهادی کومار و همکاران.	۳۲
شکل ۱۲-۲. معماری روش پیشنهادی گمال و همکاران.	۳۳
شکل ۱۳-۲. معماری روش پیشنهادی هوویفانگ شو و همکاران.	۳۴
شکل ۱۴-۲. معماری روش پیشنهادی ساروج کومار پاندی و همکاران.	۳۵
شکل ۱۵-۲. معماری روش پیشنهادی هونگپو جانگ و همکاران.	۳۶
شکل ۱۶-۲. معماری روش پیشنهادی ذبیحی و همکاران (رتبه اول کسب شده در چالش فیزیونت).	۳۹
شکل ۱۷-۲. معماری پیشنهادی هانگ و همکارانش به نام ENCASE.	۴۰
شکل ۱۸-۲. معماری روش پیشنهاد شده توسط داتا و همکارانش.	۴۱
شکل ۱۹-۲. معماری ارائه شده توسط چور هی شی و همکاران برای تشخیص AF.	۴۲
شکل ۲۰-۲. معماری شبکه HADLN ارائه شده توسط مین فنگ چانگ و همکاران.	۴۳
شکل ۲۱-۲. معماری شبکه FDRNet چند مقایسه پیشنهادی توسط اکسین چنگ سیو و همکاران.	۴۴
شکل ۲۲-۲. معماری شبکه ی پیشنهادی توسط دواج ورما و همکاران.	۴۵
شکل ۱-۳. نمای کلی از روش پیشنهادی.	۴۸
شکل ۲-۳. مراحل تولید سیگنال با استفاده از شبکه GAN.	۵۱
شکل ۳-۳.تابع توزیع. شکل سمت راست: نمونه‌ای از تابع توزیع احتمال نرمال. شکل سمت چپ: توزیع نرمال از تابع توزیع احتمال.	۵۲
شکل ۴-۳. نمای کلی از شبکه مولد تخصصی (GAN).	۵۲
شکل ۵-۳. تصویر نمونه‌هایی از چند خانواده موجک.	۵۵
شکل ۶-۳. نمونه‌های از نقاط موج انتخاب شده برای ریتم نرمال سینوسی.	۵۷
شکل ۷-۳. نمونه‌های از نقاط موج انتخاب شده برای فیبریلاسیون دهلیزی.	۵۷
شکل ۵-۳. طرح شماتیک از معماری در نظر گرفته شده برای استخراج ویزگی‌های عمیق.	۵۸
شکل ۶-۳. نمایشی از شبکه‌ی عصبی حافظه طولانی کوتاه مدت.	۶۰
شکل ۷-۳. نمای کلی از الگوریتم جنگل تصادفی برای طبقه‌بندی ۴ کلاسه.	۶۵

۷۰	شکل ۱-۴. نمونه‌های سیگنال الکتروکاردیوگرام از چهار کلاس مجموعه دادگان.
۷۵	شکل ۲-۴.تابع فعال ساز ReLU
۷۷	شکل ۳-۴. مقایسه بهینه‌ساز آدام با سایر الگوریتم‌های بهینه‌ساز.
۷۹	شکل ۴-۴. نمودار واریانس تجمعی از تعداد مولفه‌ها.
۸۱	شکل ۵-۴. منحنی مشخصه عملکرد روش پیشنهادی.
۸۲	شکل ۶-۴. ماتریس درهم ریختگی طبقه‌بند.
۸۵	شکل ۷-۴. مقایسه دقیقت روش پیشنهادی با سایر روش‌های موجود.
۸۶	شکل ۸-۴. مقایسه نمودار ROC چهار مدل به همراه ROC روش پیشنهادی.

صفحه

فهرست جداول

جدول ۱-۲. خلاصه‌ای از تحقیقات ارائه شده در زمینه‌ی تشخیص فیبریلاسیون دهلیزی.	۳۶
جدول ۲-۲. خلاصه‌ای از تحقیقات ارائه شده بر روی پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت	۴۵
جدول ۱-۳. لایه‌های شبکه‌ی عمیق ترکیبی	۶۲
جدول ۱-۱۴. جزئیات داده‌های آموزش	۷۱
جدول ۲-۴. سناریوهای مختلف CNN-LSTM و دقต به ازای هر سناریو.	۷۴
جدول ۳-۴. لایه‌های شبکه‌ی عمیق ترکیبی.	۷۷
جدول ۴-۴. ارزیابی شبکه‌ی طبقه‌بند چهار کلاسه با روش پیشنهادی با چهار معیار ارزیابی مختلف.	۸۰
جدول ۵-۴. مقایسه‌ی نتایج دو رویکرد با روش ترکیبی پیشنهاد شده.	۸۳
جدول ۶-۴. مقایسه دقت روش پیشنهادی با سایر پژوهش‌های انجام شده در مساله تشخیص فیبریلاسیون دهلیزی.	۸۴

## **فصل اول**

**مقدمه**

## مقدمه

امروزه با پیشرفت تکنولوژی ورود آن به عرصه‌های مختلف، تحولی در روش‌های تصمیم‌گیری و به‌تبع آن دقت نتایج حاصله، ایجاد شده است. ابزارهای کامپیوتری همه‌ی جوانب زندگی بشر را تحت تأثیر قرار داده است. فرآگیری و داشتن دانش کامپیوتر در عصر حاضر از اولویت‌های زندگی در جوامع امروزی است. این نگرش از حدود نیم قرن پیش با گسترش و پیشرفت روز افزون علوم به ظهور دانش ماشین‌های هوشمند که کامپیوترهای امروزی مولود آن هستند، بر فضای علمی و پژوهشی جوام بشری حاکم شده و انسان‌ها را ملزم به پذیرش آن می‌کند. علوم پزشکی نیز از تأثیر تکنولوژی بی‌بهره نمانده است. میزان آگاهی و شناخت نسبت به بیماری‌های مختلف، متناسب با افزایش اطلاعات و داده‌هایی که با معیارهای کیفی و کمی از پارامترهای زیستی جمع‌آوری شده، افزایش یافته است. از این رو، استفاده از ابزارهای کامپیوتری به شکل فرایندهای در بین متخصصان علم پزشکی در حال افزایش است. از این ابزار برای جمع‌آوری و آزمایش داده‌ها استفاده شده که در نهایت به طور قابل توجهی به بهبود فرآیند تصمیم‌گیری از سوی پزشکان کمک می‌کند.

اهمیت بهره‌مندی از ابزارهای کامپیوتری دقیق در تشخیص بیماری‌ها، به دلیل مرتبط بودن این حوزه با سلامت افراد و همچنین با توجه به شانس بالاتر در درمان بیماری با تشخیص زودهنگام، بسیار قابل توجه است. از همین رو، متخصصان علوم کامپیوتر و علم پزشکی با تعامل سازنده و هم‌افزایی، قادر به انتشار و بسط هرچه وسیع‌تر علم خواهند بود. یکی از ابزارهای کامپیوتری که در سال‌های اخیر مورد توجه محققان قرار گرفته است، یادگیری ماشین با تشخیص بیماری تحول شگرفی در پزشکی، بهداشت و درمان ایجاد خواهد کرد. داده‌های تشخیص بیماران از قبیل سیگنال‌های حیاتی، تصاویر پرتو ایکس، نوار مغزی و سونوگرافی با یادگیری ماشین به شکل بهتری مورد تجزیه و تحلیل قرار می‌گیرند؛ بنابراین، این تغییراتِ عمده زمینه را برای تشخیص بیماری در مراحل ابتدایی فراهم می‌کند.

قلب انسان اصلی‌ترین عضو بدن است که می‌تواند سایر سیستم‌های بدن را به یک باره از کار بیاندازد. به همین دلیل پیش‌بینی بیماری‌های قلبی یکی از پژوهش‌های چالش برانگیز است که نیازمند تحلیل دقیق ریتم قلب می‌باشد. ریتم غیرعادی قلب که به آن آریتمی قلبی گفته می‌شود، زمانی رخ می‌دهد که ضربان قلب در مقایسه با حالت طبیعی که بین ۶۰ تا ۱۰۰ تپش در دقیقه است، کمتر یا بیشتر باشد. آریتمی قلبی یک بیماری است که اگر برای مدت طولانی درمان نشود، می‌تواند بسیار خطرناک و مرگبار باشد. بنابراین به یک سیستم پیش‌بینی که بتواند آریتمی قلبی را پیش‌بینی و نوع آن را تشخیص دهد نیاز است.

ثبت سیگنال‌های پزشکی مانند سیگنال الکتروکاردیوگرام (ECG<sup>۱</sup>) کمک شایانی به علم پزشکی در تشخیص انواع بیماری‌های قلبی کرده است. یکی از راه‌های تشخیص و پیش‌بینی بیماری‌ها و ناهنجاری‌های قلبی از جمله فیبریلاسیون دهلیزی (AF<sup>۲</sup>), پردازش سیگنال‌های قلبی از جمله سیگنال الکتروکاردیوگرام می‌باشد [۱]. سیگنال الکتروکاردیوگرام به عنوان یک ابزار غیرقابل جایگزین، غیرتھاجمی، ایمن و سریع برای درک فعالیت الکتریکی قلب به کار می‌رود. غیرتھاجمی بودن این سیگنال به این معنی است که برای کسب اطلاعات پزشکی از شرایط بیماری فرد، آسیب جانی به او وارد نمی‌شود. برخلاف روش‌های تھاجمی مانند ابليشن<sup>۳</sup> که بخش‌هایی از بافت‌های سطحی قلب سوزانده می‌شود تا عامل ایجاد مشکل از بین برود.

فیبریلاسیون دهلیزی یکی از شایع‌ترین آریتمی‌های قلبی است که احتمال وقوع آن با بالارفتن سن افزایش می‌یابد. فیبریلاسیون دهلیزی باعث ایجاد مشکلاتی مانند نارسایی قلبی، ایجاد لخته‌ی خونی و سکته‌ی مغزی می‌شود و بیماری خطرناکی به شمار می‌رود که جان انسان‌ها را تهدید می‌کند. این آریتمی چهارنوع دارد که عبارتند از نوع ناگهانی (PAF<sup>۴</sup>، مداوم<sup>۵</sup>، مدارم بلند مدت<sup>۶</sup> و دائمی<sup>۷</sup>. تفاوت انواع مختلف فیبریلاسیون دهلیزی در تعداد دفعات و مدت بروز علائمی است که نشان می‌دهند [۲]. تشخیص به هنگام و اقدام برای درمان این بیماری نقش بهسزایی در حفظ جان بیمار و جلوگیری از بروز و عود عوارض ناشی از فیبریلاسیون دهلیزی ایفا می‌کند. اما تشخیص فیبریلاسیون دهلیزی به ویژه در مراحل ابتدایی که بروز آن از نوع ناگهانی (PAF) است بسیار چالش برانگیز است. زیرا فیبریلاسیون دهلیزی معمولاً علائم خاصی در بیمار ندارد و به صورت دوره‌ای رخ می‌دهد و معمولاً در روش‌های سنتی پایش بیمار با دستگاه‌های الکتروکاردیوگرام نمی‌توان آن را تشخیص داد، زیرا این دستگاه‌ها فعالیت قلب را در یک بازه‌ی زمانی خاص مورد سنجش قرار می‌دهند که ممکن است در آن بازه علائم فیبریلاسیون دهلیزی رخ ندهد. بنابراین دستگاه‌های هوشمندی برای جمع‌آوری و ثبت سیگنال الکتروکاردیوگرام در بازه‌های طولانی تر طراحی شده‌اند. این دستگاه‌ها باید مجهز به الگوریتم‌های هوش مصنوعی جهت تشخیص خودکار فیبریلاسیون دهلیزی بدون نیاز به کمک یک متخصص باشند.

امروزه پردازش سیگنال نقش مهمی در علم پزشکی دارد. یکی از کاربردهای مهم آن می‌تواند شناسایی خودکار بسیاری از بیماری‌های قلبی باشد. از مزایای تشخیص خودکار بیماری می‌توان به مواردی همچون دسترسی همیشگی و آسان، تشخیص سریع و دقیق بیماری و همچنین کاهش خطای

<sup>1</sup> Electrocardiogram

<sup>2</sup> Atrial Fibrillation

<sup>3</sup> Ablation

<sup>4</sup> Paroxysmal

<sup>5</sup> Persistent

<sup>6</sup> Long-standing Persistent

<sup>7</sup> Permanent

تشخیص اشاره نمود. همچنین تشخیص خودکار بیماری می‌تواند به عنوان ابزاری مناسب، در خدمت دانش پزشکی درآید.

## ۱-۱- بیان مساله و ضرورت تحقیق

بیماری‌های قلبی اصلی‌ترین دلیل مرگ و میر در سراسر جهان بوده‌اند و بر اساس آمارهای ارائه شده توسط سازمان بهداشت جهانی (WHO)<sup>۱</sup> از سال ۲۰۰۰ تا ۲۰۱۶، بیماری‌های قلبی مانند بیماری قلبی ایسکمی (IHD)<sup>۲</sup> و سکته‌ی مغزی به ترتیب اولین و دومین رایج‌ترین دلیل مرگ و میر جهانی بوده‌اند. در سال ۲۰۱۶، بیماری قلبی ایسکمی و سکته‌ی مغزی جان به ترتیب  $\frac{9}{4}$  و  $\frac{5}{7}$  میلیون نفر را گرفتند. این آمار در سال ۲۰۰۰ افزایش به ترتیب  $\frac{34}{4}$  و  $\frac{12}{2}$  درصدی داشته است. مطالعات اخیر رابطه‌ی قوی بین فیبریلاسیون دهلیزی و سکته‌ی مغزی و بیماری قلبی ایسکمی را ثابت کرده‌اند. فیبریلاسیون دهلیزی به معنی بروز یک ریتم غیرطبیعی در قلب که ناشی از انقباض غیرعادی دهلیزها است که می‌تواند بدون علائم یا با علائم رخ دهد. به طور مثال  $\frac{30}{20}$ ٪ بیماران سکته‌ی ایسکمی به فیبریلاسیون دهلیزی مبتلا بوده‌اند [۳]. بر اساس یک پژوهش در سال ۲۰۱۰  $\frac{33}{5}$  میلیون نفر به فیبریلاسیون دهلیزی مبتلا بوده‌اند [۴]. شیوع جهانی و گستردگی فیبریلاسیون دهلیزی بسیار هشداردهنده است و انتظار می‌رود تا سال ۲۰۶۰ حدود  $\frac{17}{9}$  میلیون نفر از قاره‌ی اروپا در ریسک ابتلا به فیبریلاسیون دهلیزی قرار دارند [۵]. بر اساس این روند سعودی دانشمندان انتظار یک اپیدمی فیبریلاسیون دهلیزی را در ۱۰ الی ۲۰ سال آینده دارند [۵]. به خصوص در افراد بالای ۳۵ سال ریسک ابتلا به فیبریلاسیون دهلیزی بیشتر است.

علائم رایج فیبریلاسیون دهلیزی شامل تپش شدید قلب، سرگیجه، تنگی نفس و درد قفسه سینه می‌شود [۶]. اما فیبریلاسیون دهلیزی اغلب بدون علائم بارز رخ می‌دهد. این ویژگی مخفی بودن فیبریلاسیون دهلیزی موجب تشخیص دیر هنگام بیماری شده است. تحقیقات نشان می‌دهد که حدود ۲۰ درصد از ابتلا به فیبریلاسیون دهلیزی به دلیل عدم وجود علائم بارز، تشخیص داده نشده‌اند [۷، [۸] و [۹]. عدم توانایی در تشخیص زودهنگام فیبریلاسیون دهلیزی باعث افزایش ریسک عود بیماری به مراحل پیشرفته‌ی غیرقابل درمان شده و همچنین عواقبی چون ابتلا به بیماری‌های قلبی خطرونک مانند بیماری‌های دریچه‌ی قلب و نارسایی قلب و سایر بیماری‌ها مانند فشارخون و بیماری مزمن کلیوی و یا حتی مرگ بیمار خواهد داشت [۱۰] و [۱۱].

همانطور که پیش‌تر گفته شد، تشخیص فیبریلاسیون دهلیزی به ویژه در مراحل ابتدایی که بروز آن از نوع ناگهانی (PAF) است کار بسیار دشواری است، اما تشخیص بیماری در این مرحله بسیار حائز اهمیت است، زیرا بیماران در این مرحله شанс بالایی برای درمان و بهبودی دارند. در صورتی که با گذشت زمان

<sup>1</sup> World Health Organization

<sup>2</sup> Ischemic Heart Disease

و پیشرفت بیماری نوع فیبریلاسیون دهلیزی از حالت فیبریلاسیون دهلیزی به نوع دائمی و غیرقابل درمان تغییر خواهد کرد.

همچنین مطالعه‌ی بیماران مبتلا به نوع دائمی فیبریلاسیون دهلیزی می‌تواند اطلاعات مفیدی در مورد ویژگی‌های پزشکی و مشخصات کلیدی این بیماری و سیگنال الکتروکاردیوگرام در بیماران مبتلا ارائه بدهد که این اطلاعات می‌تواند کمک قابل توجهی در توسعه‌ی مدل‌های یادگیری ماشین برای تشخیص فیبریلاسیون دهلیزی ارائه دهد.

تشخیص فیبریلاسیون دهلیزی در مراحل حاد که علائم به صورت باز رخ می‌دهند، توسط متخصص و با ثبت و ارزیابی سیگنال الکتروکاردیوگرام ۱۲ لید در محیط بیمارستانی صورت می‌گیرد. اما در شرایطی که فیبریلاسیون دهلیزی پیشرفت چندانی نداشته باشد و از نوع بدون علائم باشد، به سختی توسط پزشک قابل تشخیص است. بنابراین انجام تحقیقات در مورد توسعه‌ی مدلی مبتنی بر روش‌های یادگیری ماشین به عنوان روش کمکی جهت تشخیص به موقع فیبریلاسیون دهلیزی در مراحل ابتدایی آن نقش بهسازی در انتخاب مسیر درمان بیماری و بهبود کیفیت درمان و کاهش احتمال وقوع بیماری‌های خطرناک و مرگ و میر خواهد داشت.

## ۱-۲- روش تحقیق

یادگیری ماشین شامل تکنیک‌ها و رویکردهای مختلفی برای تجزیه، تحلیل و نتیجه‌گیری از داده‌های خام است. تکنیک طبقه‌بندی<sup>۱</sup> یکی از زیر شاخه‌های اساسی یادگیری ماشین و داده‌کاوی است که براساس داده‌های قبلی که دارای برچسب هستند، مدلی برای پیش‌بینی برچسب داده‌های جدید می‌سازد. پیش‌بینی فیبریلاسیون دهلیزی با استفاده از یادگیری ماشین و بهخصوص طبقه‌بندی قابل انجام است.

در این پژوهش، از سیگنال الکتروکاردیوگرام کوتاه قلب افرادی با ریتم‌های مربوط به فیبریلاسیون دهلیزی، ریتم‌های نویدار، ریتم‌های نرمال و سایر ریتم‌ها برای آموزش و طراحی مدلی با قابلیت تشخیص این چهار دسته استفاده کرده‌ایم. روش پیشنهادی در این پژوهش ترکیبی از روش‌های سنتی یادگیری ماشین و یادگیری عمیق است. به این ترتیب که سیگنال‌های الکتروکاردیوگرام پس از پیش‌پردازش وارد یک شبکه‌ی ترکیبی عمیق شبکه عصبی کانولوشنال-شبکه‌ی عصبی حافظه طولانی کوتاه مدت می‌شوند. در این شبکه عمیق، ویژگی‌های سیگنال‌ها به صورت خودکار در شبکه عصبی کانولوشنال استخراج شده و به عنوان ورودی وارد شبکه‌ی عصبی حافظه طولانی کوتاه مدت شده تا به دلیل خصوصیات این شبکه، پویایی‌های زمانی سیگنال‌ها حفظ و ثبت شود. سپس ویژگی‌هایی که به صورت خودکار از شبکه‌ی عمیق ترکیبی استخراج شده‌اند و با ویژگی‌های مربوط به ساختار سیگنال الکتروکاردیوگرام ترکیب شده، سپس

<sup>1</sup> Classification

<sup>2</sup> Noisy

تعداد آن‌ها توسط روش تحلیل مولفه‌ی اصلی کاهش یافته است. در نهایت ویژگی‌های کاهش یافته جهت طبقه‌بندی به الگوریتم طبقه‌بند جنگل تصادفی (RF<sup>1</sup>) که توانایی زیادی در طبقه‌بندی داده‌های پزشکی از خود نشان داده است [۱۲]، وارد شده‌اند.

### ۱-۳- نوآوری تحقیق

در گذشته تحقیقات گستره‌های با هدف پیش‌بینی و تشخیص آریتمی قلبی فیبریلاسیون دهلیزی انجام شده است. اما در اکثر کارهای موجود، هدف تشخیص بیماران مبتلا به آریتمی قلبی فیبریلاسیون دهلیزی و افراد سالم یعنی یک طبقه‌بندی دو کلاسه بوده است و یا طبقه‌بندی سه کلاسه برای تشخیص سه کلاس افراد مبتلا به فیبریلاسیون دهلیزی، سایر آریتمی‌های قلبی و افراد سالم بوده است. اما از آن‌جا که اکثر روش‌های ارائه شده قادر به تشخیص سیگنال‌های نویزدار نمی‌باشند. در این پژوهش به منظور جامعیت بخشیدن به این چالش، طبقه‌بندی را از دو و سه کلاسه به طبقه‌بندی چهار کلاسه تعمیم داده شده است.

همچنین در اکثر روش‌های موجود برای حل این چالش یا از ویژگی‌های ساختاری سیگنال‌های قلبی استفاده شده است، یا از توانایی شبکه‌های عمیق در استخراج خودکار ویژگی‌های پنهان این سیگنال‌ها. اما در این پژوهش از مزیت‌های هر دو روش استخراج ویژگی در کنار بهره برده شده است تا به فرآیند استخراج ویژگی جامعیت بخشیده شود. قابل ذکر است که در چالش مطرح شده برای طبقه‌بندی سیگنال‌های الکتروکاردیوگرام تک لید کوتاه در چهار کلاس فیبریلاسیون دهلیزی، ریتم نرمال سینوسی، سایر ریتم‌ها و سیگنال‌های نویز دار (چالش ۲۰۱۷ فیزیونت<sup>۲</sup>، تمامی شرکنندگان و مقالات ارائه شده در فاز نهایی، دقیق روش‌های موجود بر اساس ارزیابی تنها سه کلاس فیبریلاسیون دهلیزی، ریتم نرمال سینوسی، سایر ریتم‌ها گزارش شده است، زیرا تشخیص سیگنال‌های نویزدار به دلیل تعداد کم داده‌های موجود و پراکندگی فرکانسی زیاد این داده‌ها با چالش‌های فراوان روبه رو می‌باشد. اما در این پژوهش دقیق به دست آمده با در نظر گرفتن داده‌های کلاس نویزدار و برای طبقه‌بندی چهار کلاسه گزارش شده است.

مجموعه داده در نظر گرفته شده برای این پژوهش (مجموعه داده معرفی شده در چالش ۲۰۱۷ فیزیونت) به شدت نامتوازن می‌باشد. این نامتوازن بودن باعث مایل شدن<sup>۳</sup> شبکه به تشخیص کلاس با تعداد داده بیشتر می‌شود. در نتیجه برای مقابله با عدم تمايل شبکه به تشخیص کلاس نادرست، از روش داده افزایی با استفاده از شبکه مولد تخاصمی (GAN) برای متوازن‌سازی تعداد داده‌ها در هر کلاس،

<sup>1</sup> Random Forest

<sup>2</sup> Physionet CinC Challenge 2017

<sup>3</sup> bias

استفاده شده است. روش پیشنهادی در این پژوهش در نتیجه‌ی همه نوآوری‌های به کار برده شده، موفق به کسب دقت بالاتر نسبت به سایر روش‌های موجود شده است.

در نتیجه نوآوری این تحقیق را می‌توان در موارد زیر خلاصه کرد:

- ۱- استفاده از ویژگی‌های ساختاری در کنار ویژگی‌های عمیق.
- ۲- تعمیم مدل طبقه‌بندی دو و سه کلاسه به یک مدل طبقه‌بندی چهار کلاسه.
- ۳- استفاده از شبکه GAN جهت متوازن‌سازی مجموعه دادگان.

## ۱-۴- ساختار پایان‌نامه

در این پژوهش ابتدا در فصل دوم آریتمی قلبی و فیبریلاسیون دهلیزی تعریف شده است و سپس مروری بر روش‌هایی که برای تشخیص فیبریلاسیون دهلیزی ارائه شده‌اند، انجام شده است. در فصل سوم پایان‌نامه به معرفی معماری طراحی شده به عنوان روش پیشنهادی خود جهت طبقه‌بندی داده‌های مورد استفاده در چهار دسته‌ی ریتم‌های نرمال، فیبریلاسیون دهلیزی، سایر ریتم‌ها و ریتم‌های نویزی پرداخته شده است. در چهارمین فصل از پایان‌نامه نیز نتایج ارزیابی روش پیشنهادی بر اساس معیارهای ارزیابی ارائه و تحلیل شده‌اند. در نهایت در فصل پنجم جمع‌بندی و پیشنهادهایی برای پژوهش‌های آتی ارائه شده است.

## فصل دوم

معرفی مبانی و مروار ادبیات

## مقدمه

سلامت جامعه تاثیر زیادی بر همه فعالیت‌های انسانی دارد. تصمیم‌گیری در پزشکی توسط کارشناسان بسیار مشکل می‌باشد، زیرا پردازش انبوهی از داده‌ها و تشخیص دقیق بیماری کار دشواری است. تشخیص بیماری دارای یک نقش بسیار مهم و حیاتی است. این اولین مرحله از مجموعه اقدامات درمانی است و خطأ در این سطح می‌تواند عواقب چشم‌گیری داشته باشد. بنابراین حضور تکنولوژی در مرحله تشخیص ضروری می‌باشد. امروزه پردازش سیگنال و روش‌های یادگیری ماشین نقش مهمی در علم پزشکی پیدا کرده است. یکی از کاربردهای مهم آن می‌تواند شناسایی خودکار بسیاری از بیماری‌ها با کمک متدهای یادگیری ماشین و هوش مصنوعی باشد که به پزشکان کمک می‌کند تا با یک روش دقیق‌تری شرایط بیمار را تشخیص داده و اقدامات بعدی را در جهت درمان بیماری صورت دهند. در فصل پیش‌رو، ابتدا به بررسی مفاهیم اصلی در یادگیری ماشین و تعاریف آریتمی قلبی پرداخته شده است و سپس روش‌های ارائه شده برای تشخیص آریتمی قلبی مورد بررسی قرار گرفته است.

## ۱-۲- تعریف آریتمی قلبی

آریتمی قلبی یا اختلال در ریتم قلب معمولاً در اثر عملکرد نامناسب پیام‌های الکتریکی هماهنگ‌کننده ضربان قلب به وجود می‌آید و منجر به افزایش یا کاهش ضربان و یا نامنظم شدن آن می‌شود [۱۳]. آریتمی قلبی ممکن است به صورت تپش قلب توصیف شود که گاهی نیز بی‌خطر هستند. با این حال برخی از آریتمی‌ها ممکن است با علائم و نشانه‌های آزار دهنده و در برخی مواقع کشنده همراه باشند.

## ۱-۱- انواع آریتمی قلبی

پزشکان آریتمی قلبی را نه تنها بر اساس محل آن‌ها بلکه بر اساس تغییری که در ضربان قلبی ایجاد می‌کنند نیز طبقه‌بندی می‌کنند. انواع آریتمی‌ها به شرح زیر هستند:

❖ تاکیکارדי<sup>۱</sup> که به معنی ضربان قلب بیش از ۱۰۰ بار در دقیقه می‌باشد.

تاکیکاردی‌ها در دهلیز: تاکیکاردی‌هایی که از دهلیز نشأت می‌گیرند شامل:

- فیبریلاسیون دهلیزی.
- فلاتر دهلیزی.<sup>۲</sup>
- تاکیکاردی فوق بطئی.<sup>۳</sup>

<sup>1</sup> Tachycardia

<sup>2</sup> Atrial Flutter

<sup>3</sup> Supraventricular Tachycardia

- سندروم ولف پارکینسون وایت.<sup>۱</sup>

تاکیکاردی‌ها در بطن: تاکی کاردی‌هایی که از بطن نشأت می‌گیرند شامل:

- تاکیکاردی بطنی.
- فیبریلاسیون بطنی.
- سندروم QT طولانی.

❖ برادیکاردی<sup>۲</sup> که به معنی ضربان قلب کمتر از ۶۰ بار در دقیقه می‌باشد.

- سندروم سینوس بیمار.<sup>۳</sup>
- انسداد هدایتی.<sup>۴</sup>
- ضربان‌های زودرس<sup>۵</sup>

## ۲-۲- تعریف فیبریلاسیون دهلیزی

فیبریلاسیون دهلیزی نوعی آریتمی قلبی است که اغلب به صورت ریتم تندر قلب بروز می‌کند. این نوع آریتمی ممکن است منجر به ایجاد لخته‌ی خون در قلب شود. نام این بیماری فیبریلاسیون دهلیزی<sup>۶</sup> است. فیبریلاسیون دهلیزی ریسک سکته مغزی، ایست قلبی و سایر بیماری‌های قلبی را افزایش می‌دهد. در فیبریلاسیون دهلیزی دهلیزها به صورت نامنظم می‌تپند و با بطن‌ها هماهنگی ندارند. در بسیاری از افراد فیبریلاسیون دهلیزی هیچ علائمی ندارد، در حالی که در بعضی افراد باعث تپش شدید و سریع قلب تنگی نفس می‌شود. فیبریلاسیون دهلیزی ممکن است گذرا یا دائمی باشد. با اینکه فیبریلاسیون دهلیزی به خودی خود خطر مرگ با بیمار ندارد، یک بیماری حساس و جدی تلقی می‌شود که نیاز به درمان مناسب دارد تا بتوان از بروز سکته‌ی قلبی در بیمار جلوگیری نمود. درمان‌های این بیماری شامل درمان دارویی و سایر درمان‌ها برای بازگشت ریتم قلب به حالت نرمال می‌باشد. هدف از این درمان‌ها کنترل ضربان قلب همراه با جلوگیری از لخته شدن خون و کاهش خطر سکته‌ی مغزی است. در روش کنترل ریتم قلب را کنترل می‌کند، آریتمی فیبریلاسیون دهلیزی پابرجاست ولی ضربان قلب با مصرف داروهای حالت نرمال می‌رسد. در روش کنترل ریتم با استفاده از داروهای ضدآریتمیک یا روش‌های تهاجمی بن با استفاده از شوک قلبی، ریتم قلب از حالت فیبریلاسیون دهلیزی به ریتم نرمال قلب تغییر می‌فرد مبتلا به

<sup>1</sup> Wolff-Parkinson-White Syndrome

<sup>2</sup> Bradycardia

<sup>3</sup> Sick Sinus Syndrome

<sup>4</sup> Conduction Block

<sup>5</sup> Premature Heartbeats

<sup>6</sup> Atrial Fibrillation

فیبریلاسیون دهليزی ممکن است به یک آریتمی مرتبط دیگر نیز به نام فلاتر دهليزی مبتلا باشد. اگرچه فلاتر دهليزی یک نوع آریتمی متفاوت است، درمان آن کاملاً مشابه فیبریلاسیون دهليزی است.

## ۲-۱-۲- درمان فیبریلاسیون دهليزی

با توجه به این که علائم فیبریلاسیون دهليزی چقدر شدید یا خفيف هستند، پزشك می‌تواند روش‌های مختلفی را برای درمان این بیماری به کار گیرد.

**درمان دارویی:** یکی از راه‌های درمان این نوع آریتمی قلبی، درمان دارویی است که پزشك با توجه به تشخیص، ممکن است این داروها تجویز شود:

- داروهایی برای کاهش ضربان قلب (مانند بتاپلوكرهای).
- داروهایی برای کاهش فشار انقباض‌ها (مانند مهارکنندهی کانال‌های کلسیم).
- داروهایی برای برگرداندن ریتم قلب به حالت طبیعی (مانند مهارکنندهی کانال‌های سدیم).
- داروهایی برای پیشگیری از ایجاد شدن لخته‌ی خونی (ضدانعقادها یا ضدپلاکت‌ها).

افرادی که از دارو برای کاهش ضربان قلب استفاده می‌کنند، ممکن است لازم باشد از دستگاه ضربان‌ساز (پیس‌میکر) هم استفاده کنند. این دستگاه که حکم باتری را دارد، داخل بدن زیر پوست کار گذاشته می‌شود و زمانی که سرعت ضربان قلب کم می‌شود، امواج الکتریکی به قلب می‌فرستد.

**شوك الکتریکی:** در بعضی موارد درمان دارویی کافی نیست. در نتیجه پزشك با شیوه‌هایی مثل شوک الکتریکی برای بازگرداندن ریتم قلب به حالت طبیعی، درمان فیبریلاسیون دهليزی را پیش می‌برد.

**جراحی:** یکی دیگر از راه‌های درمان فیبریلاسیون دهليزی سوزاندن بافت قلبی (ابلیشن) است. در این شیوه‌ی درمانی، بخش‌هایی از بافت‌های سطحی قلب سوزانده می‌شود تا عامل ایجاد مشکل از بین برود.

## ۲-۲-۲- علائم فیبریلاسیون دهليزی

بعضی از افراد مبتلا به فیبریلاسیون دهليزی متوجه هیچ علائمی نمی‌شوند. اما دسته‌ای که علائم فیبریلاسیون دهليزی را دارند ممکن است نشانه‌ها و علائمی از قبیل موارد زیر را تجربه کنند:

- احساس تپش تند، لرزشی و بسیار شدید قلب.
- درد قفسه سینه.
- سرگیجه.
- احساس خستگی.
- احساس سبکی در سر.
- توان پایین در تمرينات ورزشی.
- تنگی نفس.

- ضعف بدنی.

### ۲-۳-۱- انواع فیبریلاسیون دهليزی

- ناگهانی (فیبریلاسیون دهليزی حمله‌ای): در این نوع فیبریلاسیون دهليزی علائم معمولاً بین چند دقیقه تا چند ساعت طول می‌کشند. گاهی اوقات علائم به اندازه‌ی یک هفت‌به بروز می‌کنند و به خودی خود از بین می‌روند. برخی از افراد مبتلا به این نوع فیبریلاسیون دهليزی به درمان نیاز دارند.
- مداوم: در این نوع از فیبریلاسیون دهليزی، ریتم قلب به خودی خود به حالت نرمال باز نمی‌گردد. اگر فردی به این نوع از فیبریلاسیون دهليزی دچار باشد، برای نرمال کردن ریتم قلب از شوک الکتریکی یا درمان دارویی استفاده می‌شود.
- مداوم بلند مدت: این نوع فیبریلاسیون دهليزی پیوسته و مداوم بوده و بیشتر از ۱۲ ماه طول می‌کشد.
- دائمی: در این نوع فیبریلاسیون دهليزی بازگرداندن قلب به ریتم نرمال غیرممکن بوده و پزشکان باید جهت جلوگیری از تشکیل لخته‌های خونی ضربان قلب را کنترل کنند.

### ۲-۴-۱- علت بروز فیبریلاسیون دهليزی

به منظور توضیح علل بروز فیبریلاسیون دهليزی، بهتر است که با ریتم طبیعی قلب آشنا شویم. قلب دارای چهار حجره است، دو حجره‌ی بالایی (دهليزها) و دو حجره‌ی پایینی (بطن‌ها). درون دهليز راست گروهی از سلول‌ها به نام گره سینوسی وجود دارند. گره سینوسی ضربان‌ساز طبیعی قلب است که سیگنال آغاز‌کننده‌ی هر تپش قلب را تولید می‌کند. در یک ریتم طبیعی قلب:

سیگنال از گره سینوسی به سمت دو دهليز حرکت می‌کند. سیگنال از یک مسیر به نام گره دهليزی بطنی عبور می‌کند که بین دهليزها و بطن‌ها قرار گرفته است. حرکت سیگنال باعث فشرده شدن قلب و ارسال خون به قلب و بدن می‌شود. در فیبریلاسیون دهليزی سیگنال‌ها در حفره‌های بالایی قلب (دهليزها) نامنظم هستند. در نتیجه حفره‌های بالایی می‌لرزند. در این حالت گره دهليزی بطنی با حجم بالایی از سیگنل‌ها که در تلاشند به بطن‌ها برسند، مواجه می‌شود. این امر باعث تپش سریع و غیرمعمول قلب می‌شود. ضربان قلب در فیبریلاسیون دهليزی در بازه‌ی ۱۰۰ تا ۱۷۵ تپش در هر دقیقه قرار دارد. در حالی که ضربان قلب طبیعی در بازه‌ی ۶۰ تا ۱۰۰ تپش در هر دقیقه قرار دارد.

## ۲-۵-۲- عوامل ابتلا به فیبریلاسیون دهلیزی

raig ترین عوامل بروز این بیماری، مشکلات مرتبط با ساختار قلب است که برخی از آن‌ها شامل موارد زیر می‌شود:

- بیماری عروق کرونری.
- حمله‌ی قلبی.
- نقص مادرزادی قلبی.
- مشکلات دریچه‌ی قلب.
- فشارخون بالا.
- بیماری‌های ریوی.
- استرس فیزیکی ناشی از عمل جراحی، ذات الريه و يا ساير بیماری‌ها.
- عمل جراحی قلب پیشین.
- مشکلات در ضربان‌ساز طبیعی قلب (سندروم سینوس بیمار).
- وقفه تنفسی در خواب.
- بیماری تیروئید مانند تیروئید پرکار و سایر مشکلات مرتبط با عدم تعادل متابولیکی.
- استفاده از محرک‌ها شامل داروهای خاص، کافئین، الکل و دخانیات.
- عفونت‌های ویروسی.

بعضی از افراد مبتلا به فیبریلاسیون دهلیزی به هیچ مشکل یا آسیب قلبی خاصی مبتلا نیستند.

## ۲-۶-۲- فاکتورهای موثر در ابتلا

- عواملی که باعث افزایش ریسک ابتلا به فیبریلاسیون دهلیزی می‌شوند شامل موارد زیر هستند:
- سن: هرچه سن فرد بالاتر باشد، ریسک ابتلا به فیبریلاسیون دهلیزی در او بیشتر است.
  - بیماری قلبی: هر فردی که مبتلا به بیماری‌های قلبی مانند مشکلات دریچه قلب، بیماری قلبی مادرزاری، نارسانی احتقانی قلب، بیماری عروق کرونری باشد و یا سابقه‌ی حمله‌ی قلبی یا عمل جراحی قلب داشته باشد، ریسک ابتلا به فیبریلاسیون دهلیزی بالایی دارد.
  - فشارخون بالا: فشارخون بالا به خصوص اگر با سبک زندگی مناسب و دارو کنترل نشود، ریسک ابتلا به فیبریلاسیون دهلیزی را افزایش می‌دهد.
  - بیماری تیروئید: در بعضی افراد مشکلات تیروئیدی باعث ایجاد اختلال در ریتم قلب (آریتمی قلبی) می‌شود که شامل فیبریلاسیون دهلیزی است.

- سایر بیماری‌های مزمن: افراد مبتلا به بیماری‌های مزمن مانند دیابت، سندروم متابولیک، بیماری مزمن کلیوی، بیماری ریوی و وفقه تنفسی درخواب ریسک ابلاست به فیبریلاسیون دهلیزی بالای دارند.
- مصرف مشوربات الکلی: مصرف مشروبات الکلی در بعضی از افراد ممکن است محرک شروع فیبریلاسیون دهلیزی باشد. مصرف بیش از حد آن نیز ریسک ابلاست را افزایش می‌دهد.
- چاقی: افرادی که به چاقی دچار هستند به ریسک ابلاستی بالای دچارند.
- سابقه‌ی خانوادگی: در بعضی خانواده‌ها ریسک ابلاست به فیبریلاسیون دهلیزی بالا است.

## ۷-۲-۲- عوارض بیماری

ایجاد لخته‌های خونی از عوارض بسیار خطرناک فیبریلاسیون دهلیزی است که ممکن است منجر به سکته‌ی مغزی شود.

در فیبریلاسیون دهلیزی ریتم نامنظم قلب باعث می‌شود که خون در حفره‌های بالای (دهلیزها) جمع شود و لخته‌ی خونی ایجاد شود. اگر یک لخته‌ی خونی در حفره‌ی بالای چپ (دهلیزچپ) از ناحیه‌ی قلب خارج شد، می‌تواند به سمت مغز حرکت کرده و باعث سکته‌ی مغزی شود. ریسک ابلاست به فیبریلاسیون دهلیزی با افزایش سن بالا می‌رود. سایر بیماری‌ها نیز می‌توانند ریسک سکته‌ی مغزی ناشی از فیبریلاسیون دهلیزی را افزایش دهند. مانند:

- فشارخون بالا.
- دیابت.
- نارسایی قلبی.
- بعضی از بیماری‌های دریچه‌ی قلب.

برای جلوگیری از تشکیل لخته‌ی خون و سکته‌ی مغزی در افراد مبتلا به فیبریلاسیون دهلیزی معمولاً پزشکان داروهای رقیق‌کننده‌ی خون تجویز می‌کنند.

## ۸-۲- جلوگیری از ابلاست به فیبریلاسیون دهلیزی

انتخاب سبک زندگی سالم ریسک ابلاست به بیماری‌های قلبی را کاهش داده و می‌تواند از ابلاست به فیبریلاسیون دهلیزی جلوگیری کند. موارد زیر نمونه‌هایی از موارد اساسی برای حفظ سلامت قلب است:

- داشتن رژیم غذایی سالم و مغذی.
- انجام تمرینات ورزشی به صورت مرتب و حفظ وزن ایده‌آل و سالم.
- عدم مصرف دخانیات.

- عدم مصرف مشروبات الکلی و مصرف محدود کافئین.
- مدیریت استرس، زیرا استرس شدید و عصبانیت ممکن است باعث ایجاد مشکلات در ریتم قلب شود.
- بهبود عادات خواب.

کاهش وزن و حفظ وزن ایده‌آل و سالم بهترین تغییرات مثبت را در بهبود فیبریلاسیون دهلیزی ایجاد می‌کنند. به طوری که در ۲۲٪ بیماران مبتلا به فیبریلاسیون دهلیزی پس از کاهش ۳٪ الی ۹٪ وزن با ورزش و رژیم، بدون نیاز به دارو یا جراحی علائم فیبریلاسیون دهلیزی از بین رفته است و با کاهش ۱۰٪ یا بیشتر وزن با ورزش و رژیم نیز ۴۵٪ از مبتلایان بهبود یافته‌اند.

## ۲-۹- تشخیص فیبریلاسیون دهلیزی

بعضی از افراد از ابتلا به فیبریلاسیون دهلیزی آگاه نیستند. ممکن است هنگام که پزشک در هنگام تست ورزش برای دلایل دیگر با گوشی پزشکی به ریتم قلب گوش می‌دهد، متوجه ابتلای فرد به فیبریلاسیون دهلیزی شود. پزشک متخصص برای تشخیص فیبریلاسیون دهلیزی یا حذف سایر گزینه‌هایی که ممکن است علائم مشابه ایجاد کنند، ممکن است آزمایش‌های متعددی تجویز کند. این آزمایش‌ها شامل موارد زیر می‌باشد:

- **الکتروکاردیوگرام<sup>۱</sup>** (الکتروکاردیوگرام یا EKG): این روش سریع و بدون درد فعالیت الکتریکی قلب را اندازه‌گیری می‌کند. این فعالیت الکتریکی با فعالیت مکانیکی قلب در ارتباط مستقیم است. از این رو این سیگنال نقش به سزایی در تشخیص و مطالعه عملکرد قلب دارد. الکترودها که تکه‌هایی چسبنده هستند روی سینه و گاهی اوقات بازوها و ساق پا قرار می‌گیرند. سیم‌ها الکترودها را به یک کامپیوتر که نتایج تست را نشان می‌دهد متصل می‌کنند. سیگنال الکتروکاردیوگرام مشخص می‌کند که ضربان قلب فرد خیلی سریع، کند یا طبیعی است. سیگنال الکتروکاردیوگرام اصلی‌ترین روش و آزمایش برای تشخیص فیبریلاسیون دهلیزی است.
- آزمایش خون: این آزمایش به پزشک کمک می‌کند که به مشکلات تیروئیدی و یا سایر موادی که در خون ممکن است منجر به فیبریلاسیون دهلیزی شوند، پی ببرد.
- **مانیتور هولتر<sup>۲</sup>**: یک وسیله‌ی کوچک و قابل حمل ثبت الکتروکاردیوگرام است که می‌توان در طول فعالیت‌های روزمره آن را روی کمربند یا شانه بست و پوشید و یا داخل جیب قرار داد. این دستگاه فعالیت قلب را به صورت پیوسته برای مدت ۲۴ ساعت یا بیشتر ثبت می‌کند. این دستگاه ثبات دارای دو نوع سیستم علامت‌گذاری است. یکی علامت‌گذاری است که توسط بیمار و در هنگام بروز علائم فعال می‌شود و دیگری علامت‌گذاری است که خود دستگاه زمان وقوع هر

<sup>1</sup> Electrocardiogram

<sup>2</sup> Holter Monitor

اختلالی را ثبت می‌نماید، بنابراین، هر اختلالی می‌تواند با علائم بیمار یا زمان بروز آن در روز ثبت شود. این اطلاعات را می‌توان جهت مرور مجدد به صورت یک نوار الکتروکاردیوگرام استاندارد چپ نمود.

- **دستگاه وقایع نگاری<sup>۱</sup>:** این دستگاه که مشابه مانیتور هولتر است، تنها در زمان‌های خاصی و برای چند دقیقه الکتروکاردیوگرام را ثبت می‌کند. مدت زمان پوشیدن این دستگاه طولانی‌تر از مانیتور هولتر و معمولاً ۳۰ روز است. فرد بیمار هنگامی که علائم احساس می‌کند کمکهای را می‌فشارد تا الکتروکاردیوگرام ثبت شود. در بعضی از انواع این دستگاه نیز وقتی یک ریتم غیرعادی شناسایی می‌شود، دستگاه به صورت خودکار شروع به ثبت الکتروکاردیوگرام می‌کند.
- **اکوکاردیوگرام<sup>۲</sup>:** این آزمایش غیرتهاجمی با استفاده از امواج صوتی تصاویری از ابعاد، ساختار و حرکت قلب ایجاد می‌کند.
- **تست استرس:** تست استرس، تست ورزش هم نامیده می‌شود. این آزمایش فعالیت قلب فرد را در حالی که روی تردمیل یا دوچرخه ثابت ورزش می‌کند، اندازه‌گیری و بررسی می‌کند.
- **اشعه ایکس قفسه‌ی سینه:** تصاویر اشعه ایکس به پزشک کمک می‌کنند که وضعیت ریه‌ها و قلب را مشاهده و بررسی کند [۱۳].

همان‌طور که در بخش قبل گفته شد، تحلیل سیگنال الکتروکاردیوگرام قلب بیمار، اصلی‌ترین روش تشخیص فیبریلاسیون دهلیزی است. بنابراین در ادامه ساختار این سیگنال و نحوه تشخیص فیبریلاسیون دهلیزی در آن تشریح می‌شود.

از دیدگاه آناتومیکی قلب دارای چهار حفره (دهلیز و بطن راست و دهلیز و بطن چپ) است که خون را به اندام و شش‌ها می‌رساند. عملکرد مکانیکی قلب که موجب جابجایی خون می‌گردد، منشایی الکتریکی دارد. این فرآیند الکتریکی دوره‌ای و تکرارشونده است و موجب ارسال جریان الکتریکی در سرتاسر بدن می‌گردد. دوره‌ی الکتریکی قلب از گره سینوسی<sup>۳</sup> که فرمانده بدن بوده و مجموعه رشته‌های عصبی قرار گرفته بر روی دهلیز راست، آغاز می‌گردد.

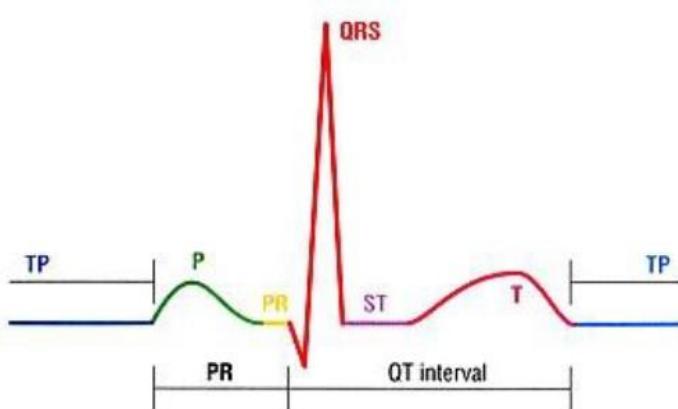
## ۲-۱-۱- اجزای تشکیل‌دهنده سیگنال الکتروکاردیوگرام

هر کدام از اجزای مشاهده شده بر روی شکل ۲-۱، نشان‌دهنده‌ی بخشی از فعالیت الکتریکی سلول‌های قلب می‌باشند. این اجزا به صورت قراردادی نام‌گذاری شده‌اند و در تمام دنیا به همین نام‌ها معروف هستند.

<sup>1</sup>Event Recorder

<sup>2</sup>Echocardiogram

<sup>3</sup>Sinoatrial Node



شکل ۱-۲. اجزای تشکیل‌دهنده سیگنال الکتروکاردیوگرام.

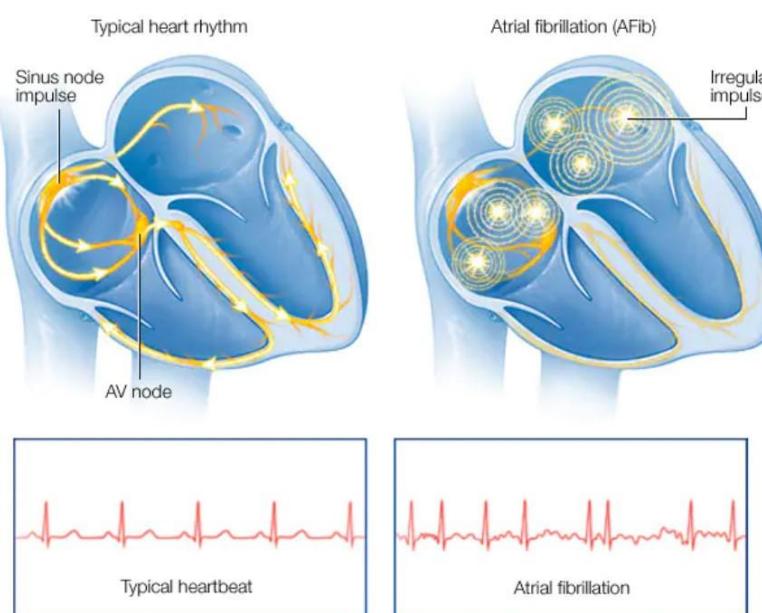
- **موج P:** جریان الکتریکی از دهليزها، اولین موج الکتروکاردیوگرام را ایجاد می‌کند. اين موج P نام دارد. موج P در حالت طبیعی گرد، صاف و قرینه بوده و نشان‌دهنده‌ی دپولاریزاسیون (یک تغییر الکتریکی در قلب که باعث انقباض آن می‌شود) دهليزهاست [۱۳].
- **فاصله‌ی PR:** از ابتدای موج P تا شروع کمپلکس QRS به این نام خوانده می‌شود. این فاصله نشان‌دهنده‌ی زمان سپری شده برای رسیدن موج دپولاریزاسیون از دهليزها به بطن‌ها است. قسمت عمده‌ی این فاصله به علت وقفه‌ی ایمپالس در گرهی دهليزی بطنی شکل می‌گیرد.
- **کمپلکس QRS:** از مجموع سه موج تشکیل شده است و مجموعاً نشان‌دهنده‌ی دپولاریزاسیون بطن‌ها است. انقباض بطن‌ها موجب پمپاژ خون در بدن شده و کمپلکس QRS را در موج الکتروکاردیوگرام تولید می‌کند. اولین موج منفی بعد از P، موج Q نام دارد. اولین موج مثبت بعد از P را موج R، و اولین موج منفی بعد از R را S می‌نامند. چون هر سه موج ممکن است با هم دیده نشوند، مجموع این سه موج را با هم یک کمپلکس QRS می‌نامند.
- **قطعه‌ی ST:** از انتهای کمپلکس QRS تا ابتدای موج T را قطعه‌ی ST نام‌گذاری کرده‌اند. این قطعه نشان‌دهنده‌ی مراحل ابتدایی رپولاریزاسیون بطن‌ها است.
- **موج T:** موجی گرد و مثبت می‌باشد که بعد از QRS ظاهر می‌شود. این موج نشان‌دهنده‌ی مراحل انتهایی رپولاریزاسیون بطن‌ها است.
- **فاصله‌ی QT:** از ابتدای کمپلکس QRS تا انتهای موج P می‌باشد و نشان‌دهنده‌ی زمان لازم برای مجموع فعالیت بطن‌ها در طی یک چرخه‌ی قلبی است.
- **موج U:** موجی گرد و کوچک می‌باشد که بعد از T ظاهر می‌شود. این موج همیشه دیده نمی‌شود [۱۳].
- **فاصله‌ی TP:** نشان‌دهنده‌ی کامل شدن رپولاریزاسیون بطنی است.

## ۱۱-۲-۲- تعریف ویژگی‌های فیبریلاسیون دهلیزی در سیگنال الکتروکاردیوگرام

یک ریتم سینوسی نرمال دارای لگویی ثابت است و به طور منظم تکرار می‌شود، دامنه و مدت زمان اجزای موج سینوسی ثابت هستند. اگر این اجزا تغییر کنند، موج ریتم سینوسی نرمال نیست. موج P در ریتم سینوسی نرمال همیشه شکلی گرد دارد که تغییر نمی‌کند. به دنبال موج P، کمپلکس QRS وجود دارد و مدت زمان بین هر دو قله‌ی R ثابت و یکسان باقی می‌ماند. ویژگی‌های اصلی تشخیص فیبریلاسیون دهلیزی در الکتروکاردیوگرام، برخی از ویژگی‌های برجسته‌ی الکتروکاردیوگرام فرد مبتلا به فیبریلاسیون دهلیزی، عبارتند از:

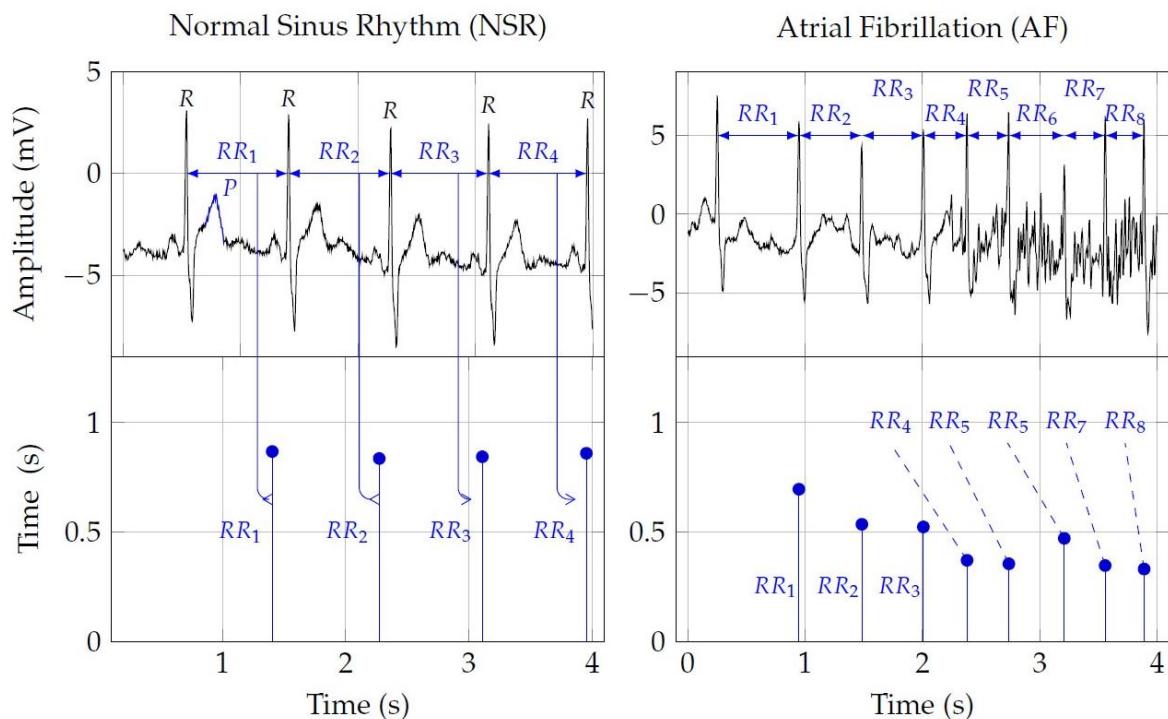
- موج P وجود ندارد.
- فاصله‌ی بین قله‌های R متوالی ثابت نیست.
- کمپلکس QRS در بعضی موارد عریض‌تر یا کوتاه‌تر از حالت طبیعی می‌شود.

در بین موارد ذکر شده، عدم وجود موج P نشان‌گر اصلی فیبریلاسیون دهلیزی در سیگنال الکتروکاردیوگرام است. همانطور که در شکل ۲-۲ مشخص است، در الکتروکاردیوگرام سمت چپ که مربوط به ریتم سینوسی نرمال است، موج P وجود دارد. اما در الکتروکاردیوگرام سمت راست هیچ موج P واضحی قابل رویت نبوده و در عوض تعداد نواسانات تصادفی متعددی دیده می‌شود. یک متخصص با مشاهده‌ی عدم وجود موج P به احتمال وجود فیبریلاسیون دهلیزی پی می‌برد.



شکل ۲-۲. مقایسه قلب فرد سالم و قلب فرد مبتلا به فیبریلاسیون دهلیزی.

قلهی R در سیگنال الکتروکاردیوگرام نشان‌دهنده‌ی دپولاریزاسیون بطنی (زمان تپیدن قلب) است. فاصله‌ی زمانی بین دو تپش قلب را فاصله‌ی RR می‌نامند. فاصله‌ی RR غیرعادی و متغیر نیز می‌تواند نشانی از وجود فیبریلاسیون دهیزی باشد، اما این مورد در بعضی از انواع دیگر آریتمی‌های قلبی نیز مشترک است [۱۱]. در شکل ۲-۳ ردیف اول دو سیگنال الکتروکاردیوگرام و ردیف دوم فاصله‌ی RR مشترک است. در نمودار رسم شده در ستون اول مربوط به ریتم سینوسی نرمال با منتظر با آن‌ها را نشان می‌دهد. دو نمودار ستون دوم نشان‌دهنده‌ی علائم فیبریلاسیون دهیزی با فواصل RR متغیر و نامنظم هستند [۱۴].



شکل ۲-۳. نمایش دو سیگنال الکتروکاردیوگرام در ردیف اول و ردیف دوم فاصله‌ی RR منتظر با آن‌ها.

پس از معرفی و شناخت انواع آریتمی‌های قلبی، علائم و علل ابتلا به این آریتمی‌های قلبی می‌توان وارد فرآیند تشخیص خودکار این گونه آریتمی‌ها شد. برای آشنایی با روش‌های تشخیص خودکار آریتمی نیاز است تا ابتدا با علم هوش مصنوعی و زیر شاخه‌های آن مانند یادگیری ماشین و یادگیری آشنا شد. که در ادامه تعاریف هر یک شرح داده شده است.

### ۳-۲- هوش مصنوعی

هنوز هیچ تعریف دقیقی از هوش مصنوعی که تمامی دانشمندان بر روی آن توافق داشته باشند ارائه نشده است، ولی اکثر تعریف‌ها را می‌توان به شکل زیر دسته‌بندی کرد.

- مانند انسان فکر می‌کند.
- منطقی فکر می‌کند.
- مانند انسان عمل می‌کند.
- منطقی عمل می‌کند.

دو تعریف اول مربوط به فرآیندهای تفکر و استدلال است. در حالی دو تعریف دیگر با رفتار سر و کار دارند. می‌توان گفت هوش مصنوعی<sup>۱</sup> شاخه‌ای از علوم رایانه است که هدف اصلی آن تولید ماشین‌های هوشمندی است که توانایی انجام وظایفی که نیازمند به هوش انسانی است را داشته باشد [۱۵]. هوش مصنوعی در حقیقت نوعی شبیه‌سازی هوش انسانی برای کامپیوتر است و منظور از هوش مصنوعی در واقع ماشینی است که به گونه‌ای برنامه‌نویسی شده که همانند انسان فکر کند و توانایی تقلید از رفتار انسان را داشته باشد. این تعریف می‌تواند به تمامی ماشین‌هایی اطلاق شود که به گونه‌ای همانند ذهن انسان عمل می‌کنند و می‌توانند کارهایی مانند حل مسئله و یادگیری داشته باشند.

هدف هوش مصنوعی آن است که هوش انسان و طریق کار آن به گونه‌ای تعریف شود که یک ماشین بتواند آن را به راحتی اجرا کند و وظایفی که بر آن محول می‌شود را به درستی اجرا کند. هدف هوش مصنوعی در حقیقت بر سه پایه استوار است:

- یادگیری.
- استدلال.
- درک.

هوش مصنوعی شاخه گسترده‌ای از علوم رایانه است که مربوط به ساخت ماشین‌های هوشمند با توانایی انجام وظایفی است که معمولاً به هوش انسان نیاز دارند. هوش مصنوعی یک علم میان رشته‌ای با چندین رویکرد است، اما پیشرفت در یادگیری ماشین و یادگیری عمیق باعث ایجاد تغییر الگوی تقریباً در هر بخش از صنعت فناوری می‌شود. یکی از شاخه‌های اصلی هوش مصنوعی یادگیری ماشین است.

<sup>1</sup> Artificial Intelligence - AI

## ۴-۲- یادگیری ماشین

یادگیری ماشین، مطالعه‌ی علمی الگوریتم‌ها و مدل‌های آماری مورد استفاده‌ی سیستم‌های کامپیوتروی است که به جای استفاده از دستورالعمل‌های واضح از الگوها و استنباط برای انجام وظایف سود می‌برند. به عبارت دیگر، در یادگیری ماشین، به جای برنامه‌نویسی جزئیات فرآیند، داده‌ها به یک الگوریتم عمومی داده می‌شوند و این الگوریتم است که براساس داده‌هایی که به آن داده شده منطق خود را می‌سازد [۱۶].

ساختار داده‌های استفاده شده در یادگیری ماشین، متشکل از سطرها و ستون‌هایی است. سطرها که از آن‌ها با عنوان رکورد یا نمونه‌ی داده نیز یاد می‌شود، نماینده نمونه‌ی داده‌ها هستند. ستون‌ها که از آن‌ها با عنوان خصیصه، ویژگی یا مشخصه نیز یاد می‌شود، در واقع ویژگی‌هایی هستند که هر نمونه از داده را توصیف می‌کنند. در یادگیری ماشین، از مجموعه‌ای از داده‌های نمونه که‌های نمونه با عنوان داده‌های آموزش نیز شناخته می‌شوند، برای آموزش مدل استفاده می‌شود. پس از اتمام فرآیند یادگیری، عملکرد مدل بر روی مجموعه‌ای از داده‌های نمونه که پیشتر در فرآیند آموزش حضور نداشته‌اند یا به عبارت دیگر مدل قبلاً با این نمونه‌ها برخورد نداشته، آزمایش می‌شود. این مجموعه از نمونه‌ها، با عنوان داده‌های تست نیز شناخته می‌شوند.

یادگیری ماشین روش‌های گوناگونی دارد که از آن جمله می‌توان به یادگیری با ناظر<sup>۱</sup>، بدون ناظر<sup>۲</sup> و یادگیری تقویتی<sup>۳</sup> اشاره کرد [۱۷].

### ۴-۱- یادگیری با ناظر

در این روش الگوریتم با دریافت داده‌های آموزش برچسب زده شده آموزش می‌بیند و در نتیجه می‌تواند در هنگام دریافت داده‌های جدید (داده‌های تست) در مورد آن‌ها تصمیم‌گیری کند. این امر به این طریق میسر می‌شود که الگوریتم با دریافت جفت‌های ورودی-خروجی، X و Y تابعی برای نگاشت ورودی به خروجی ایجاد می‌کند. که این تابع به شکل  $Y=f(X)$  نشان داده می‌شود [۱۸].

یادگیری با نظارت به دو گروه طبقه‌بندی<sup>۴</sup> و رگرسیون<sup>۵</sup> تقسیم می‌شود [۱۹] و [۲۰]. الگوریتم‌های طبقه‌بندی وظیفه‌ی تعیین کلاس نمونه‌های جدید را داشته و متغیر خروجی یک دسته یا گروه است. در حالی که الگوریتم‌های رگرسیون وظیفه‌ی تخمین یک یا چند مقدار حقیقی برای نمونه‌های جدید را دارد.

<sup>1</sup> Supervised learning

<sup>2</sup> Unsupervised Learning

<sup>3</sup> Reinforcement Learning

<sup>4</sup> Classification

<sup>5</sup> Regression

متغیر خروجی در مسائل رگرسیون پیوسته است. الگوریتم‌های ماشین بردار پشتیبان<sup>۱</sup> [۲۱]، رگرسیون لجستیک<sup>۲</sup> [۲۲] و شبکه‌های عصبی مصنوعی<sup>۳</sup> [۲۳] نمونه‌هایی از الگوریتم‌های طبقه‌بندی هستند.

#### ۴-۲- یادگیری بدون ناظر

در یادگیری بدون ناظر، الگوریتم باید خود به تنها‌یی به دنبال ساختارهای موجود در داده‌ها باشد. به بیان ریاضی، یادگیری بدون ناظر مربوط به زمانی است که در مجموعه داده فقط متغیرهای ورودی ( $X$ ) وجود داشته باشند و هیچ متغیر داده خروجی موجود نباشد. به این نوع یادگیری، بدون ناظر گفته می‌شود، زیرا برخلاف یادگیری با ناظر، هیچ پاسخ صحیح داده شده‌ای وجود ندارد و ماشین خود باید به دنبال پاسخ باشد [۲۴].

۱. به بیان دیگر، هنگامی که الگوریتم برای کار کردن از مجموعه داده‌ای بهره گیرد که فاقد داده‌های برچسب‌دار (متغیرهای خروجی) است، از مکانیزم دیگری برای یادگیری و تصمیم‌گیری استفاده می‌کند. به چنین نوع یادگیری، بدون ناظر گفته می‌شود که قابل تقسیم به مسائل خوشبندی و انجمنی است.

۲. قوانین انجمنی: یک مساله یادگیری هنگامی قوانین انجمنی محسوب می‌شود که هدف کشف کردن قواعدی باشد که بخش بزرگی از داده‌ها را توصیف می‌کنند. مثلاً، «شخصی که کالای الف را خریداری کند، تمایل به خرید کالای ب نیز دارد».

۳. خوشبندی: یک مساله هنگامی خوشبندی محسوب می‌شود که قصد کشف گروههای ذاتی (داده‌هایی که ذاتاً در یک گروه خاص می‌گنجند) در داده‌ها وجود داشته باشد. مثلاً، گروه‌بندی مشتریان بر اساس رفتار خرید آن‌ها.

#### ۴-۳- یادگیری تقویتی

این رویکرد بر اساس رابطه‌ی علت و معلولی عمل می‌کند، به طوری که در آن با یک عامل یادگیری هوشمند رو به رو هستیم که از طریق سعی و خطا عملی را انجام می‌دهد و کوشش می‌کند آن را بهبود بخشد. برای بهبود بخشیدن به نتیجه‌ی عمل توجه می‌کند، اگر نتیجه در قالب پاداش باشد، عمل انجام شده مطلوب بوده و عامل به هدفی که در آن محیط دارد نزدیک شده است. ولی اگر نتیجه در قالب تنبیه باشد، عمل انجام شده نامطلوب بوده و عامل از هدفش دور شده است. بنابراین الگوریتم‌های یادگیری تقویتی با در نظر گرفتن نتیجه‌ی کیفیت تصمیم اتخاذ شده پیوسته در حال یادگیری هستند [۲۵].

<sup>1</sup> Support Vector machine- SVM

<sup>2</sup> Logistic Regression

<sup>3</sup> Artificial Neural Networks- AN

مدل‌های پنهان مارکف<sup>۱</sup> و شبکه مولد متخاصم<sup>۲</sup> مثال‌هایی برای الگوریتم‌های یادگیری تقویتی محسوب می‌شوند [۲۶].

## ۴-۵- یادگیری عمیق

یادگیری عمیق<sup>۳</sup> زیرمجموعه‌ای از یادگیری ماشین است که در آن از الگوریتم‌هایی استفاده می‌شود که مغز انسان را شبیه‌سازی می‌کند. این الگوریتم شبکه‌های عصبی مصنوعی<sup>۴</sup> نام دارند. شبکه‌های عصبی مصنوعی از پردازش اطلاعات و گره‌های ارتباطی توزیع شده در سیستم‌های بیولوژیکی الهام گرفته‌اند. می‌توان گفت شبکه‌های عصبی تمایل به حالت ایستا و نمادین دارند. واژه عمیق به این معنی است که شما با یک شبکه بزرگ عصبی سروکار دارید. این کلمه به تعداد لایه‌های پنهان در شبکه‌های عصبی اشاره می‌کند. شبکه‌های عصبی سنتی فقط شامل ۲ یا ۳ لایه پنهان هستند، در صورتی که شبکه‌های عمیق می‌توانند تا ۱۵۰ لایه داشته باشند. به همین دلیل، اغلب مدل‌های یادگیری عمیق را شبکه‌های عصبی عمیق می‌نامند [۲۶].

یادگیری عمیق، به حل مسائلی می‌پردازد که دارای ورودی و خروجی آنالوگ هستند. به این معنی که شما با حجم زیادی از اطلاعات سر و کار دارید، همانند سیگنال‌های دیجیتال، تصاویر با داده‌های پیکسلی، نوشته با داده‌های متنی، فایل با داده‌های صوتی و غیره. یادگیری عمیق یکی از اشکال تخصصی یادگیری ماشین است. در یادگیری ماشین، فرآیند گردش کار با ویژگی مربوط به خود، یعنی استخراج از تصاویر به شکل دستی، آغاز می‌شود. سپس از این ویژگی‌ها برای ایجاد مدلی استفاده می‌شود که قادر است اشیا و وسایل موجود در تصاویر را طبقه‌بندی کند. اما در سیستم یادگیری عمیق، با یک گردش کار، ویژگی‌های مربوطه از داده‌ها مانند سیگنال دیجیتال یا تصاویر استخراج می‌شود. علاوه بر این، در الگوریتم یادگیری عمیق، جایی که به یک شبکه داده‌های خام داده شود، وظیفه طبقه‌بندی داده‌ها را نیز به صورت خودکار یاد می‌گیرد و انجام می‌دهد.

## ۶-۲- مروری بر روش‌های ارائه شده برای تشخیص فیبریلاسیون

### دھلیزی

فیبریلاسیون دھلیزی<sup>۵</sup> یک بیماری قلبی است که در آن انقباض دھلیزها و بطن‌ها با هم هماهنگ نبوده و در نتیجه ضربان قلب سریع و نامنظم می‌شود. این بی‌نظمی در ضربان قلب در گردش خون در

<sup>1</sup> Hidden Markov Models

<sup>2</sup> Generative Adversarial Networks

<sup>3</sup> Deep Learning

<sup>4</sup> Artificial Neural Network - ANN

<sup>5</sup> Atrial Fibrillation

بدن اختلال ایجاد کرده و ممکن است موجب سکته مغزی شود. فیبریلاسیون دهلیزی رایج‌ترین آریتمی قلبی، به خصوص در دنیای غرب است به طوری که پیش‌بینی‌ها نشان می‌دهد تا سال ۲۰۵۰ حدود ۱۲-۶ میلیون شهروند آمریکایی و ۱۸ میلیون شهروند اروپایی تا سال ۲۰۶۰ دچار این بیماری خواهند شد [۲۷]. فیبریلاسیون دهلیزی با سایر اختلالات قلبی-عروقی مانند حملات ایسکمیک گذرا و ایست قلبی ارتباط نزدیکی دارد. عواملی که احتمال ابتلا به این بیماری را افزایش می‌دهند؛ شامل فشارخون، بیماری عروق کرونر، دیابت، چاقی، مصرف بیش از حد مشروبات الکلی و سابقه‌ی فردی سایر بیماری‌های قلبی می‌شوند. علاوه بر این عواملی مانند سن و سابقه‌ی پزشکی خوانوادگی نیز در پیشرفت این بیماری تاثیرگذار هستند [۲۸].

تشخیص آریتمی‌های قلبی بر اساس سیگنال الکتروکاردیوگرام یکی از موضوعات حیاتی و مهم در سال‌های اخیر بوده است. به همین دلیل تحقیقات بسیاری در زمینه‌ی تشخیص و طبقه‌بندی خودکار آریتمی‌های قلبی انجام شده است. این تحقیقات در سه جنبه متفاوت مدل‌های آماری، روش‌های یادگیری ماشین و مدل‌های یادگیری عمیق انجام شده‌اند. برخی از معروف‌ترین الگوریتم‌های طبقه‌بندی استفاده شده عبارتند از K نزدیکترین همسایه<sup>۱</sup> (KNN)، درخت تصمیم<sup>۲</sup> (DT)، ماشین بردار پشتیبان<sup>۳</sup> (SVM) و جنگل تصادفی [۲۹] و [۳۰].

دش و همکاران یک الگوریتم پایدار برای تشخیص خودکار فیبریلاسیون دهلیزی بر اساس تصادفی بودن، متغیر بودن و پیچیدگی سری زمانی RR طراحی کرده‌اند. در این تحقیق از ترکیبی از سه روش آماری برای تشخیص تغییرپذیری ضربان قلب استفاده شده است. یک آماره‌ی جدید به نام نسبت نقاط چرخش<sup>۴</sup> معرفی شده است که با جذر میانگین مربعات اختلافات پی در پی<sup>۵</sup> RR و آنتروپی شانون ترکیب شده و به طبقه‌بندی فیبریلاسیون دهلیزی پرداخته است. این الگوریتم روی دو پایگاه داده‌ی MIT-BIH AF و MIT-BIH Arrhythmia آزمایش شده است و حساسیت و اختصاصیت ۹۴٪ و ۹۵٪ دست یافته است [۳۱].

الگوریتم‌های یادگیری ماشین زمان محاسباتی مورد نیاز برای آموزش کامپیوتر را کاهش می‌دهند و از این طریق باعث آسان شدن فعالیتها و مراحل کار دانشمندان می‌شوند. این الگوریتم‌ها از سه روش یادگیری با ناظر<sup>۶</sup>، بدون ناظر<sup>۷</sup> و یادگیری تقویتی<sup>۸</sup> الگوها را از داده‌ها استنباط کرده و به پیش‌بینی خروجی داده‌های جدید می‌پردازنند.

<sup>1</sup> K-Nearest Neighbor

<sup>2</sup> Decision Tree

<sup>3</sup> Support Vector Machine

<sup>4</sup> Turning Points Ratio

<sup>5</sup> Root Mean Square of Successive RR Differences

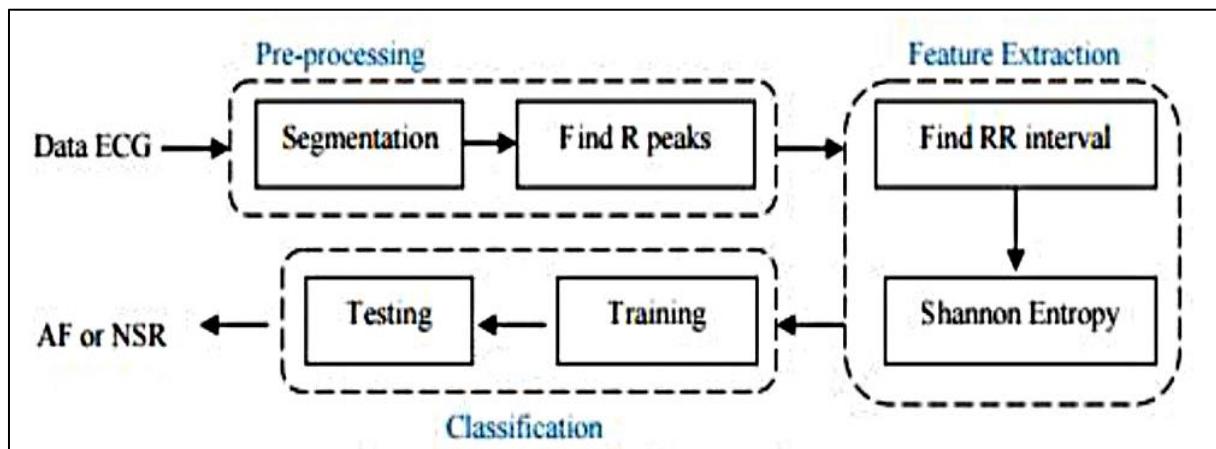
<sup>6</sup> Supervised Learning

<sup>7</sup> Unsupervised Learning

<sup>8</sup> Reinforcement Learning

لون و همکاران یک مدل جدید برای تشخیص فیبریلاسیون دهلیزی با استفاده از روش چاپ لورنژ، ۶۰ بازه‌ی RR متوالی طراحی کرده‌اند. برای کاهش حجم داده‌ها، تصاویر به دست آمده با روش تبدیل موجک فشرده شدند و به عنوان داده‌ی ورودی به یک الگوریتم طبقه‌بندی SVM داده شده‌اند. از پایگاه داده‌ی MIT-BIH Arrhythmia و MIT-BIH Atrial Fibrillation برای صحه‌گذاری مدل از بازه‌های RR ثبت شده توسط یک نمایشگر مقرر به صرفه به نام Polar-H7 در یک مطالعه محلی استفاده شده است. حساسیت و اختصاصیت مدل به ترتیب ۹۵٪ و ۹۷/۶٪ گزارش شده است [۳۲].

افدالا و همکاران یک ویژگی جدید برای تشخیص فیبریلاسیون دهلیزی معرفی کرده‌اند. این ویژگی اختلاف آنتروپی شانون بازه‌های RR است. فرآیند استخراج این ویژگی شامل سه مرحله است، یافتن پیک‌های R، محاسبه‌ی بازه‌های RR و یافتن بیشینه آنتروپی رخ داده در هر بخش. همچنین پس از قسمت‌بندی سیگنال الکتروکاردیوگرام، از روش تحلیل مولفه‌ی اصلی برای مشخص کردن همبستگی ویژگی‌های هر قسمت از سیگنال، استفاده شده است. در نهایت طبقه‌بندی دو کلاسه با استفاده از شبکه‌ی عصبی مصنوعی<sup>۱</sup> (ANN) انجام شده است. برای صحه‌گذاری<sup>۲</sup> مدل نیز از پایگاه داده‌ی Physionet Atrial Fbirillation استفاده شده است [۳۳]. معما ری روشن پیشنهادی توسط این گروه در شکل ۲-۴ نشان داده شده است.



شکل ۲-۴. معما ری روشن پیشنهادی افدا و همکاران.

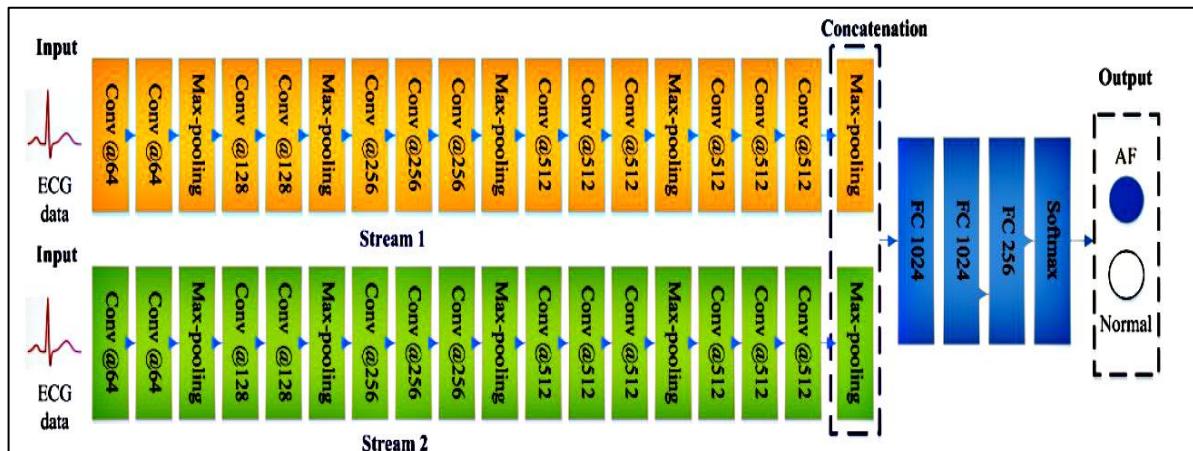
روش‌های سنتی یادگیری ماشین، نیازمند استخراج ویژگی‌ها به صورت دستی هستند که این فرآیند بسیار چالش برانگیز بوده و به داشت زمینه‌ای در مورد آن بیماری خاص و داده‌های ورودی نیاز دارد. روش‌های یادگیری عمیق مشکل استخراج ویژگی را رفع نموده‌اند، زیرا این روش‌ها نیاز به انتخاب دستی

<sup>1</sup> Artificial Neural Network

<sup>2</sup> Verification

ویژگی‌ها نداشته و به صورت خودکار مهمترین ویژگی‌ها را از داده‌های ورودی استخراج می‌کنند. باید به این موضوع توجه داشت که این شبکه‌ها برای یادگیری به تعداد داده‌های وسیعی نیاز دارند که با توجه به وجود مجموعه داده‌های وسیع برای سیگنال الکتروکاردیوگرام، مدل‌های یادگیری عمیق برای انجام تحقیقات در زمینه‌ی تشخیص خودکار آریتمی‌های قلبی روش‌های مناسب‌تری به شمار می‌روند. یک مدل عمیق معمولاً از تعدادی لایه‌ی پردازنده تشکیل شده‌اند که می‌تواند ویژگی‌ها را در مراحل متعدد و متوالی یاد بگیرند. بنابراین در طول چند سال اخیر، دانشمندان تحقیقات خود را بر طراحی مدل‌های یادگیری عمیق مانند شبکه‌ی عصبی کانوشنال<sup>۱</sup> و حافظه‌ی طولانی کوتاه مدت<sup>۲</sup> برای طبقه‌بندی آریتمی‌های قلبی متوجه کرده‌اند.

به منظور از بین بردن دشواری‌های استخراج ویژگی در مدل‌های سنتی آماری و یادگیری ماشین، در سال‌های اخیر شبکه‌ی عصبی کانوشنال به طور گسترده‌ای برای طبقه‌بندی سیگنال الکتروکاردیوگرام و شناسایی آریتمی‌ها به کار رفته است. به عنوان مثال، فن و همکاران در سال ۲۰۱۸ یک مدل تلفیقی چند مقیاسه از DCNN برای پایش فیبریلاسیون دهلیزی از سیگنال الکتروکاردیوگرام کوتاه تک لید ارائه داد. این مدل از دو رشته‌ی ۱۳ لایه‌ای CNN و سه لایه‌ی کاملاً متصل تشکیل شده است و روی سیگنال الکتروکاردیوگرام ۵ ثانیه‌ای، دقت ۹۶/۹۹٪ و روی سیگنال ۲۰ ثانیه‌ای دقت ۹۸/۱۳٪ که بالاترین دقت به دست آمده است را ارائه کرده است [۳۴]. معماری روش پیشنهادی این گروه در شکل ۲-۵ نشان داده شده است.



شکل ۲-۵. معماری روش پیشنهادی فن و همکاران در سال ۲۰۱۸.

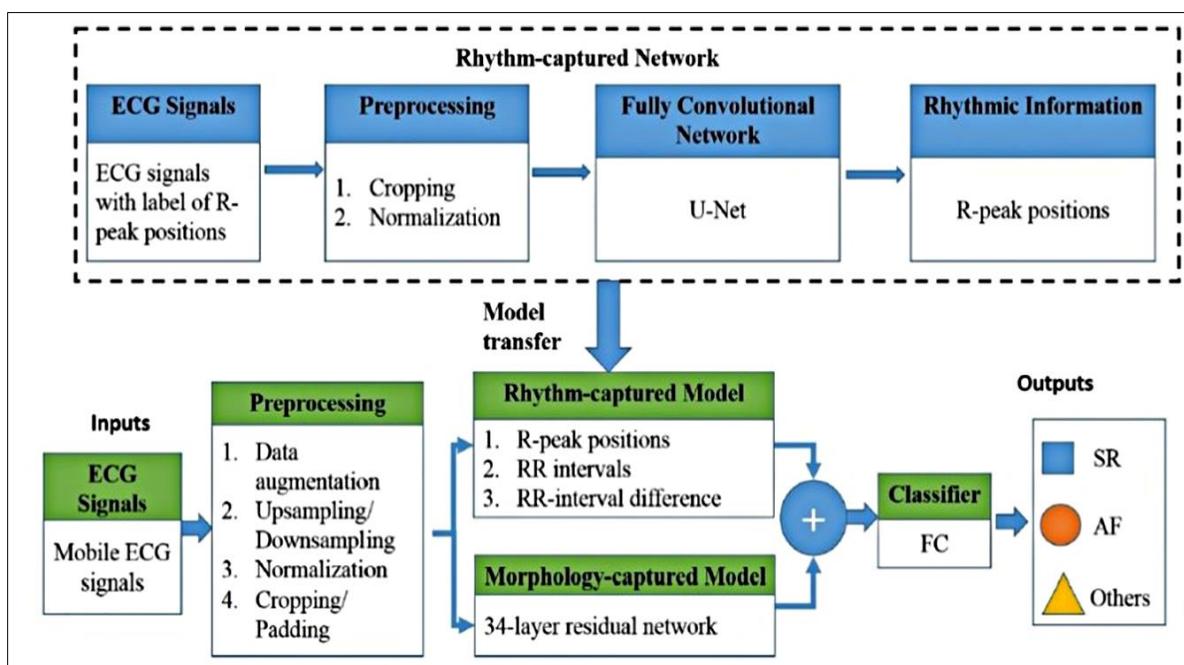
همچنین پس از دو سال در سال ۲۰۲۰ این گروه از پژوهشگران، از یک شبکه U-Net برای گرفتن اطلاعات مربوط به ریتم قلب با تعیین موقعیت قله‌های R و همچنین محاسبه بازه‌های RR و یک شبکه باقی‌مانده<sup>۳</sup> ۳۴ لایه برای استخراج ویژگی‌های مربوط به شکل موج، طراحی نمودند. در نهایت این دو دسته

<sup>1</sup> Convolutional Neural Network

<sup>2</sup> Long Short-Term Memory

<sup>3</sup> Residual Network

ویژگی با هم ترکیب شده و توسط دولایه کاملاً متصل در سه کلاس فیبریلاسیون دهلیزی، ریتم نرمال سینوسی و سایر ریتم‌های غیرعادی طبقه‌بندی شده‌اند. نتایج به دست آمده برای مدل طرحی شده نشان می‌دهد که این مدل قادر به طبقه‌بندی سیگنال‌ها با دقت  $87/22$  و  $f\text{-score}$   $85/0.8$  می‌باشد [۳۵]. عماری روش پیشنهادی توسط این گروه در شکل ۲-۶ نشان داده شده است.

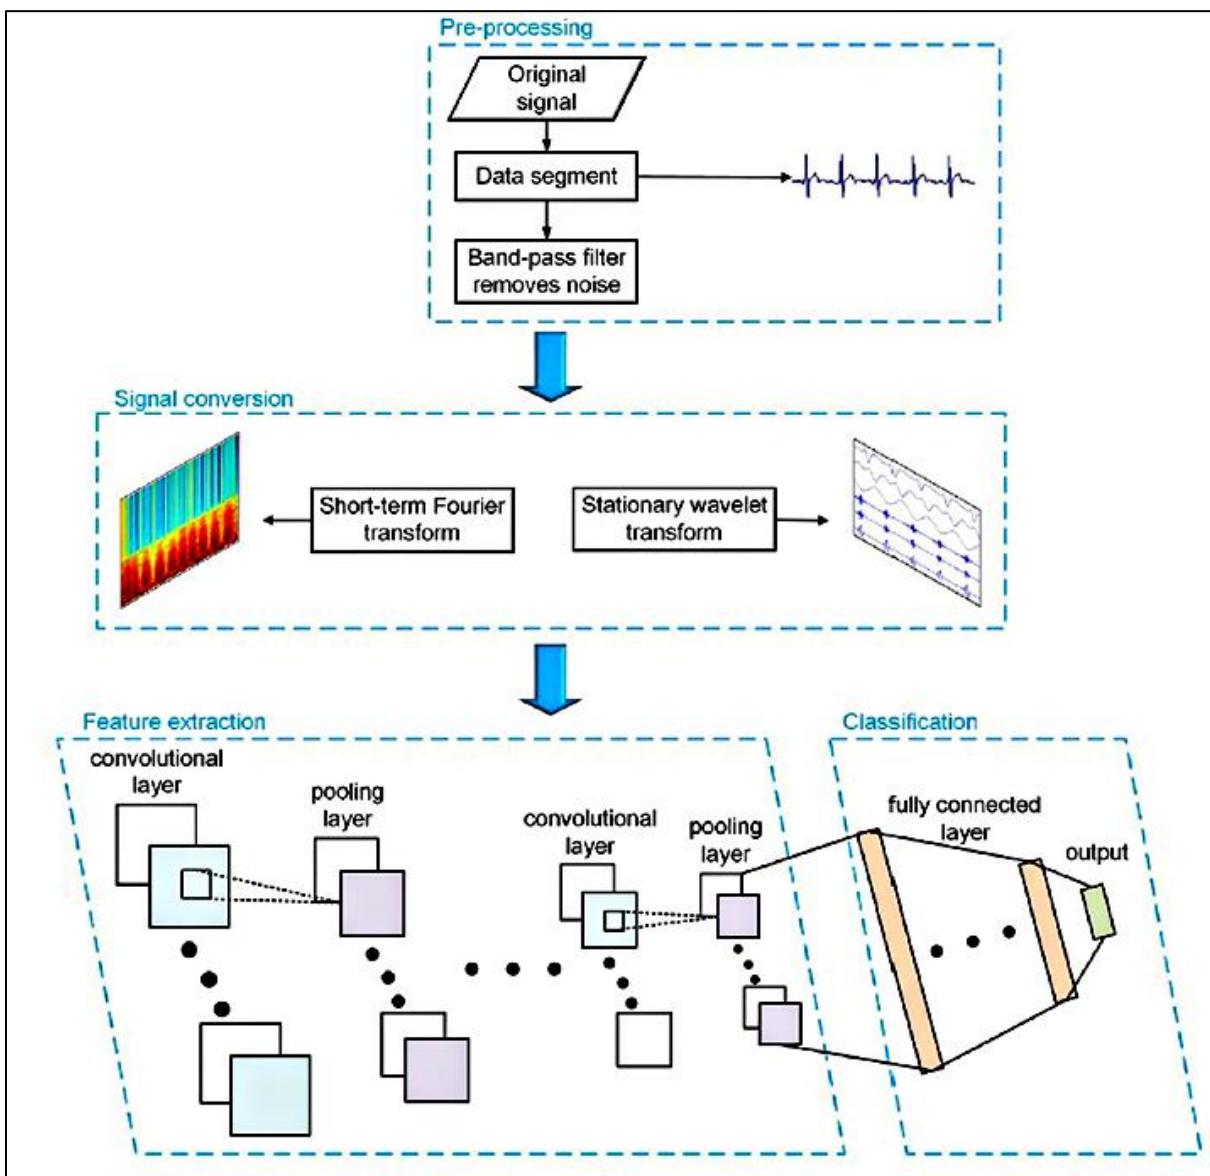


شکل ۲-۶. عماری روش پیشنهادی فن و همکاران در سال ۲۰۱۹.

شیا و همکاران با استفاده از تبدیل فوریه کوتاه مدت<sup>۱</sup> (STFT) و تبدیل موجک استاتیک<sup>۲</sup> (SWT) بخش‌های سیگنال الکتروکاردیوگرام به ماتریس دو بعدی به عنوان ورودی مناسب برای شبکه عصبی کانولوشن دست یافته‌اند. برای ارزیابی نیز دو مدل DCNN متناسب با خروجی‌های STFT و SWT طراحی کرده‌اند. مدل طراحی شده در این پژوهش نیازی به شناسایی پیک‌های R یا P نداشته و همچنین نیازی به طراحی ویژگی‌ها برای طبقه‌بندی ندارد. آن‌ها اعتبارسنجی الگوریتم‌های ارائه شده را با استفاده از پایگاه داده‌ی MIT-BIH Atrial Fibrillation انجام داده‌اند [۳۶]. عماری روش پیشنهادی توسط این گروه در شکل ۲-۷ نشان داده شده است.

<sup>۱</sup> Short-Term Fourier Transform

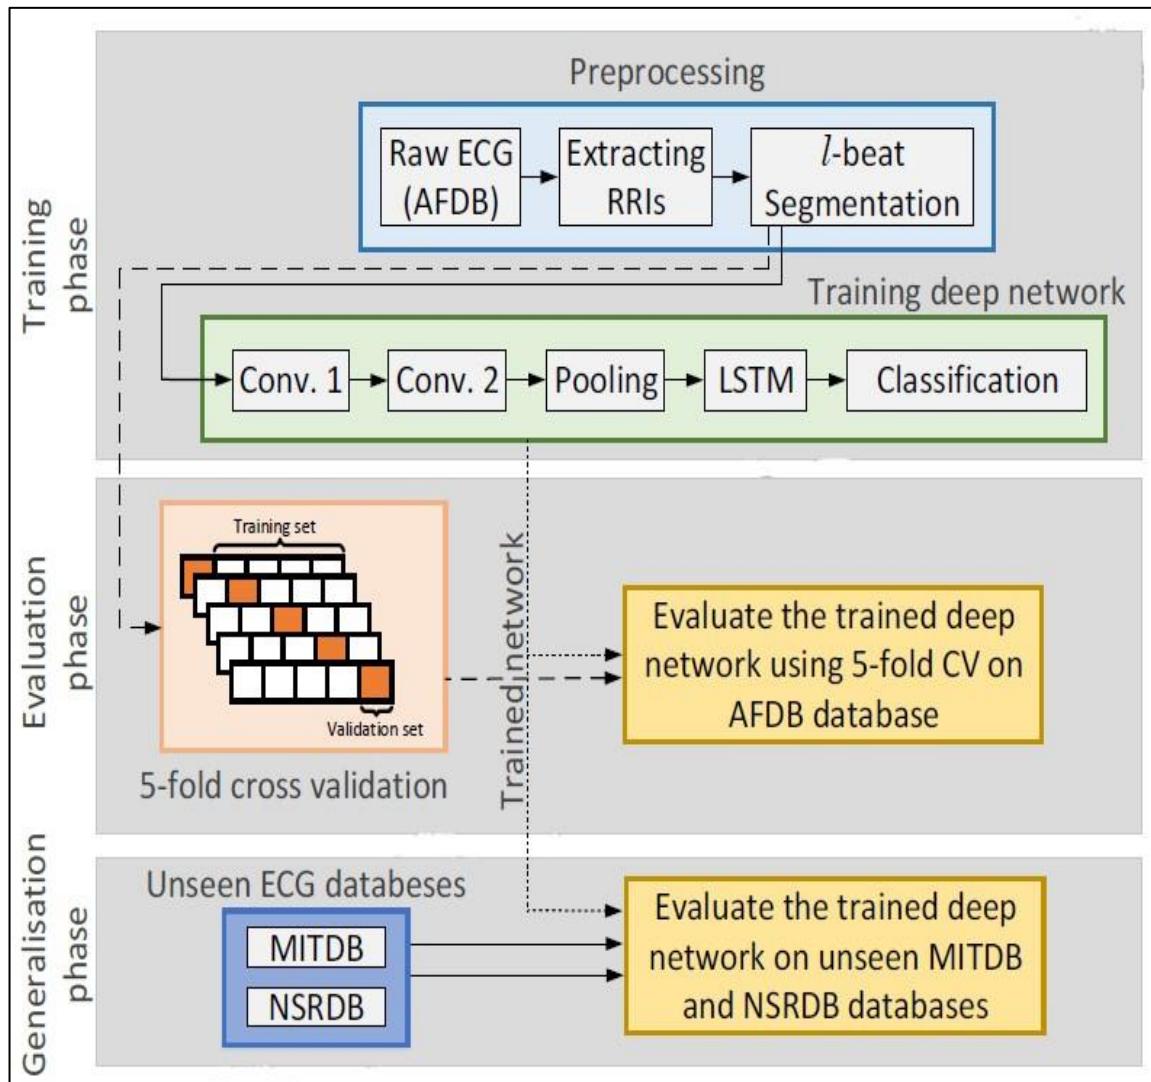
<sup>۲</sup> Stationary Wavelet Transform



شکل ۷. معماری روش پیشنهادی شیا و همکاران.

برخی از محققین نیز به منظور بهره بردن از مزایای ساختاری مدل‌های مختلف یادگیری عمیق، مدل‌های ترکیبی برای تشخیص فیبریلاسیون دهلیزی طراحی نموده‌اند. به عنوان مثال، اندرسن و همکارانش یک مدل ترکیبی از شبکه‌ی عصبی کانولوشنال و شبکه‌ی عصبی بازگشتی برای استخراج ویژگی‌ها از بازه‌های RR جهت طبقه‌بندی آن‌ها در دو کلاس نرمال و فیبریلاسیون دهلیزی ارائه داد. مدل MIT- MIT-BI H Arrhythmia ، MIT-BIH Atrial Fibrillation آموزش و تست شده است و به حساسیت ۹۸/۹۸ و اختصاصیت ۹۶/۹۵ رسیده است و روش BIH NSR

اعتبارسنجی متقابل ۵ برابری<sup>۱</sup> اجرا شده است [۳۷]. معماری روش پیشنهادی توسط این گروه در شکل ۲-۸ نشان داده شده است.

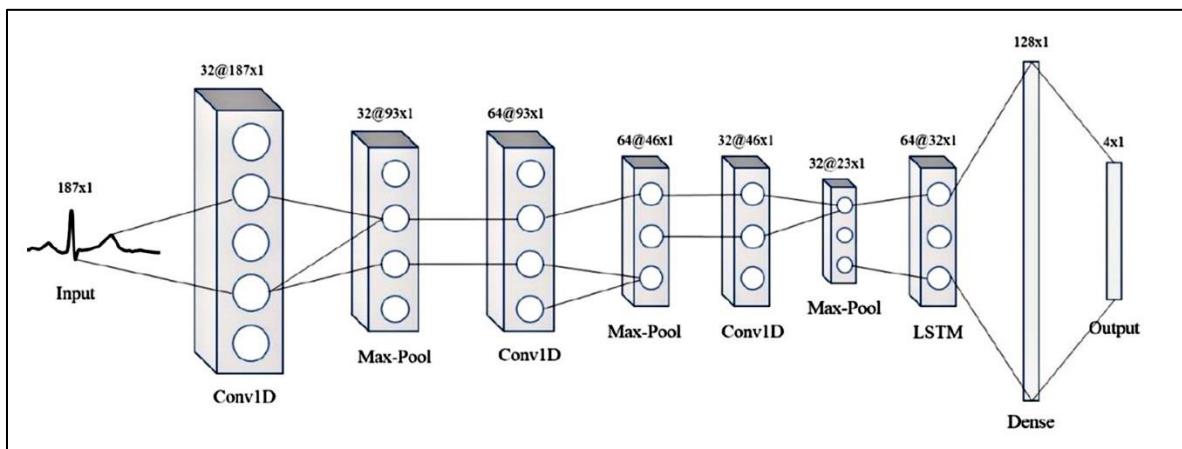


شکل ۲-۸. معماری روش پیشنهادی اندرسن و همکاران.

پتمzas و همکاران یک مدل یادگیری عمیق ترکیبی شبکه‌ی عصبی کانولوشنال-حافظه‌ی طولانی کوتاه مدت طراحی کردند که در آن ویژگی‌های سیگنال الکتروکاردیوگرام در شبکه‌ی عصبی کانولوشنال استخراج شده و عنوان ورودی به شبکه‌ی حافظه‌ی طولانی کوتاه مدت داده می‌شود و درنهایت داده‌های ورودی در چهار کلاس نرمال، فیبریلاسیون دهلیزی، فلاتر دهلیزی و ریتم پیوندگاهی طبقه‌بندی شده‌اند. جهت رفع مشکل داده‌ای نامتوابن از تابع زیان مرکزی استفاده شده است. با استفاده از پایگاهی MIT

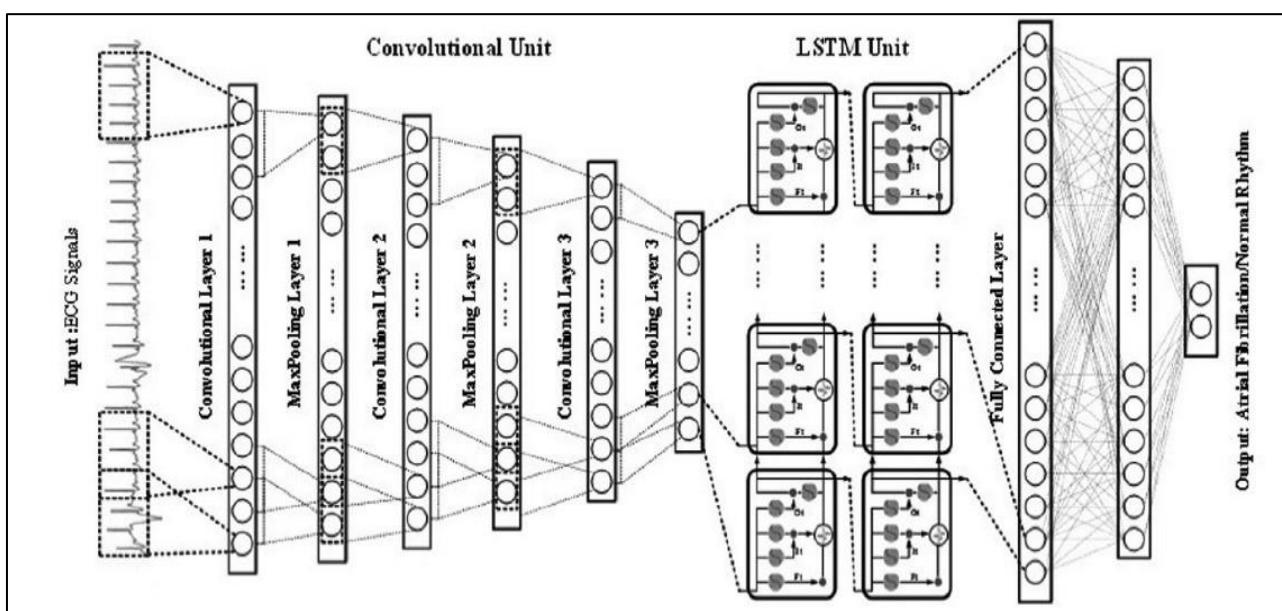
<sup>۱</sup> 5-Fold Cross Validation

BIH Atrial Fibrillation به حساسیت و اختصاصیت ۹۷/۸۷ و ۹۹/۲۹ دست یافته است [۳۸]. معماری روش پیشنهادی توسط این گروه در شکل ۲-۹ نشان داده شده است.



شکل ۲-۹. معماری روش پیشنهادی پتمzas و همکاران.

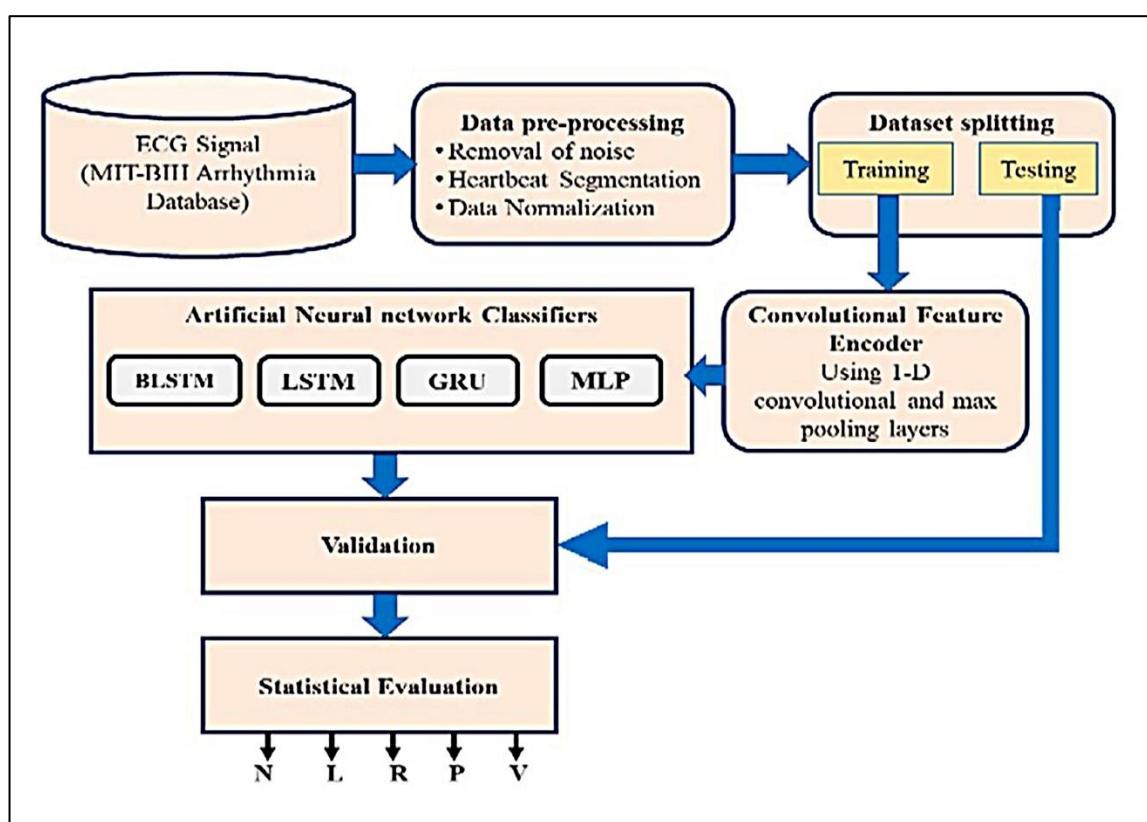
و و همکاران یک مدل ترکیبی شبکه‌ی عصبی کانولوشنال-حافظه‌ی طولانی کوتاه مدت به منظور حذف فرآیند پیچیده‌ی استخراج ویژگی طراحی کردند و عملکرد این مدل ترکیبی را با عملکرد شبکه‌های عمیق شبکه‌ی عصبی کانولوشنال و حافظه‌ی طولانی کوتاه مدت و چهار الگوریتم یادگیری ماشین سنتی K-نزدیکترین همسایه، ماشین بردار پشتیبان، جنگل تصادفی و درخت تصادفی مقایسه کرده است. طبق نتایج به دست آمده در این تحقیق، الگوریتم‌های یادگیری عمیق شبکه‌ی عصبی کانولوشنال و ترکیبی شبکه‌ی عصبی کانولوشنال-حافظه‌ی طولانی کوتاه مدت بسیار بهتر از روش‌های سنتی یادگیری ماشین بوده است. بهترین عملکرد را مدل ترکیبی شبکه‌ی عصبی کانولوشنال-حافظه‌ی طولانی کوتاه مدت با دقت ۹۷/۰۸ و حساسیت ۹۵/۵۲ و اختصاصیت ۹۸/۵۷ داشته است [۳۹]. معماری روش پیشنهادی توسط این گروه در شکل ۲-۱۰ نشان داده شده است.



شکل ۲-۱۰. معماری روش پیشنهادی وو و همکاران.

در سال ۲۰۲۱ روش دیگری برای طبقه‌بندی سیگنال‌های الکتروکاردیوگرام توسط کومار و همکاران ارائه شد. در این روش، ابتدا از یک شبکه رمزگذار کانولوشنال عمیق<sup>۱</sup> (CEF) برای استخراج ویژگی‌های سیگنال الکتروکاردیوگرام استفاده شده است. سپس، شبکه‌های حافظه کوتاه‌مدت دو جهته (BLSTM)، شبکه حافظه کوتاه‌مدت یک طرفه (ULSTM)، واحد بازگشتی دروازه‌ای (GRU) و پرسپترون چند لایه (MLP) به عنوان طبقه‌بند در نظر گرفته شده‌اند. روش پیشنهادی در این پژوهش آریتمی‌های موجود در پایگاه داده MIT-BIH Arrhythmia را به پنج کلاس مختلف ضربان قلب شناسایی و طبقه‌بندی می‌کند. این کلاس‌های ضربان قلب طبیعی (N)، بلوک شاخه چپ (L)، بلوک شاخه راست (R)، ضربان (P) و انقباض زودرس بطنی (V) هستند. نتایج به دست آمده نشان می‌دهد که شبکه BLSTM با زمان پردازش تنها ۶۰۴۳ ثانیه به دقت کلی ۹۹٪/۵۲٪ دست یافته است. که توانسته نسبت به سه روش دیگر عملکرد بهتری از خود نشان دهد [۴۰]. معماری روش پیشنهادی توسط این گروه در شکل ۲-۱۱ نشان داده شده است.

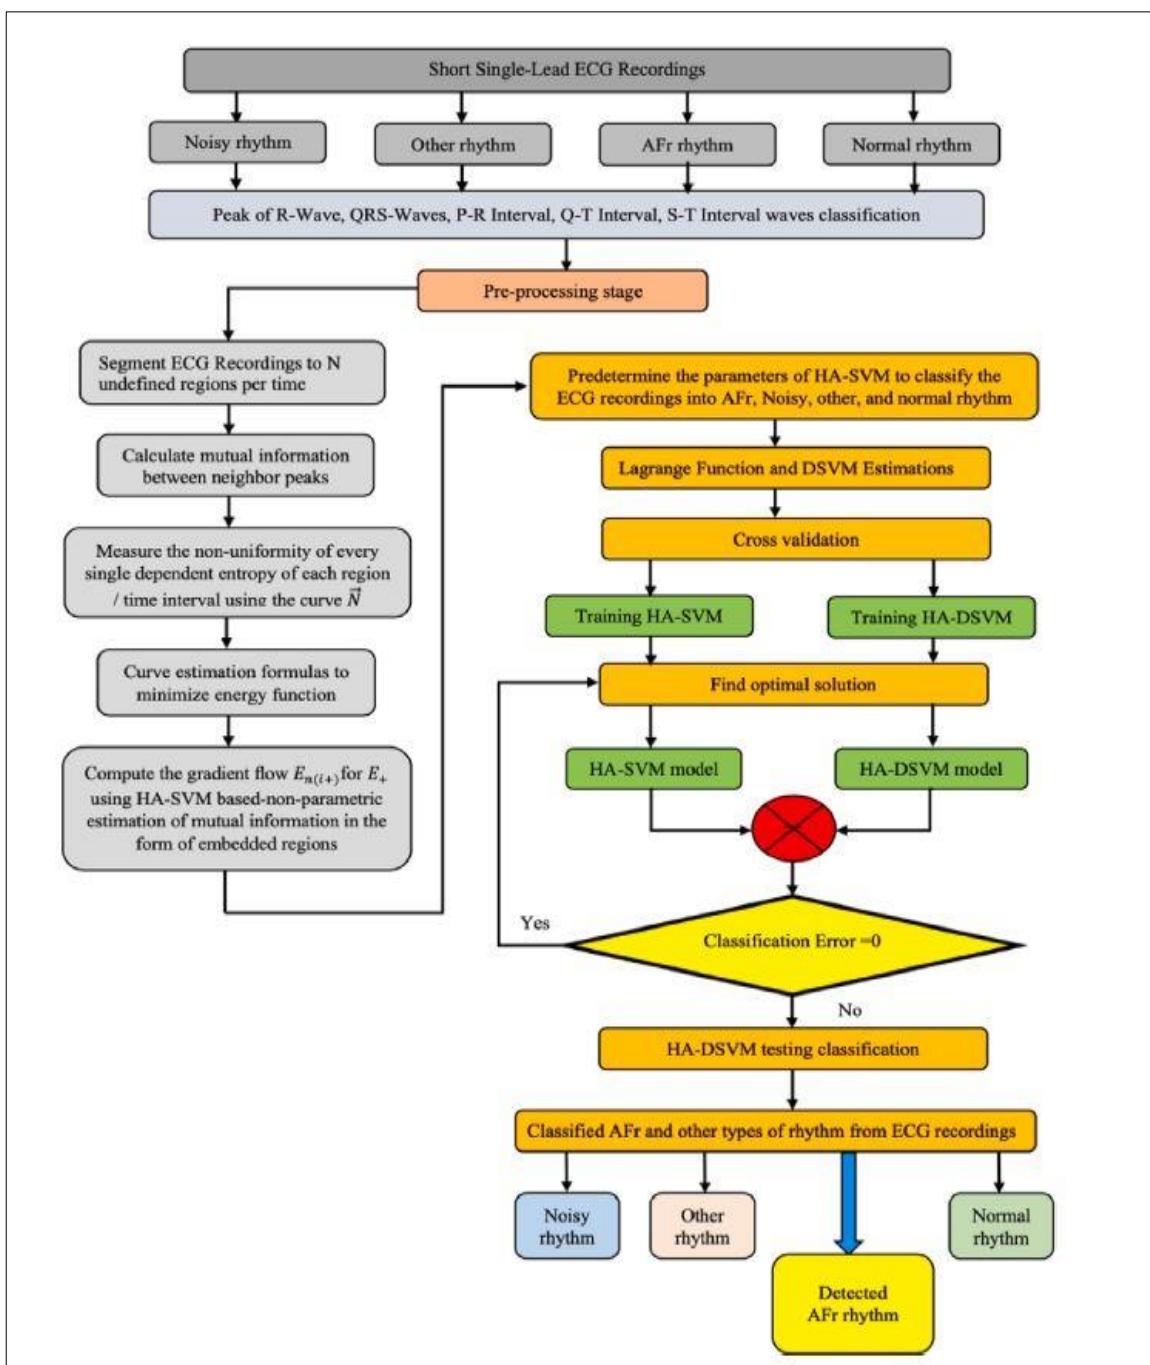
<sup>۱</sup> Deep Convolutional Encoder



شکل ۲-۱۱. معماری روش پیشنهادی کومار و همکاران.

گمال و همکاران<sup>۵</sup> روش برتر ارائه شده در زمینه‌ی تشخیص فیبریلاسیون دهلیزی در چالش ۲۰۱۷ فیزیونت را با روش جدید خود، مقایسه نموده‌اند. در این پژوهش، از هر دو روش ماشین بردارپشتیبان و رویکرد ترکیبی ماشین بردارپشتیبان دوگانه<sup>(۱)</sup> (HA-DSVM) جهت طبقه‌بندی سیگنال‌های الکتروکاردیوگرام استفاده شده‌است و با روش گرادیان نزولی تصادفی وتابع هزینه آنتروپی متقطع پیاده‌سازی شده‌است به این ترتیب که تعداد ۵۵ ویژگی مربوط به شکل موج از سیگنال‌ها استخراج شده و سپس با استفاده از روش تحلیل تشخیصی خطی<sup>(۲)</sup> (LDA<sup>۲</sup>) به ۳۰ ویژگی کاهش یافته‌اند و در نهایت ویژگی‌های انتخاب شده در یک روش با الگوریتم ماشین بردار پشتیبان دوگانه و در روش دیگر با الگوریتم ماشین بردارپشتیبان در چهار کلاس طبقه‌بندی شده‌اند. در نهایت با مقایسه‌ی عملکرد دو روش، به این نتیجه رسیده شده‌است که روش دوگانه با دقیق ۹۹/۲۷٪ و F-score ۹۵٪ بهتری داشته‌است.<sup>[۴۱]</sup>

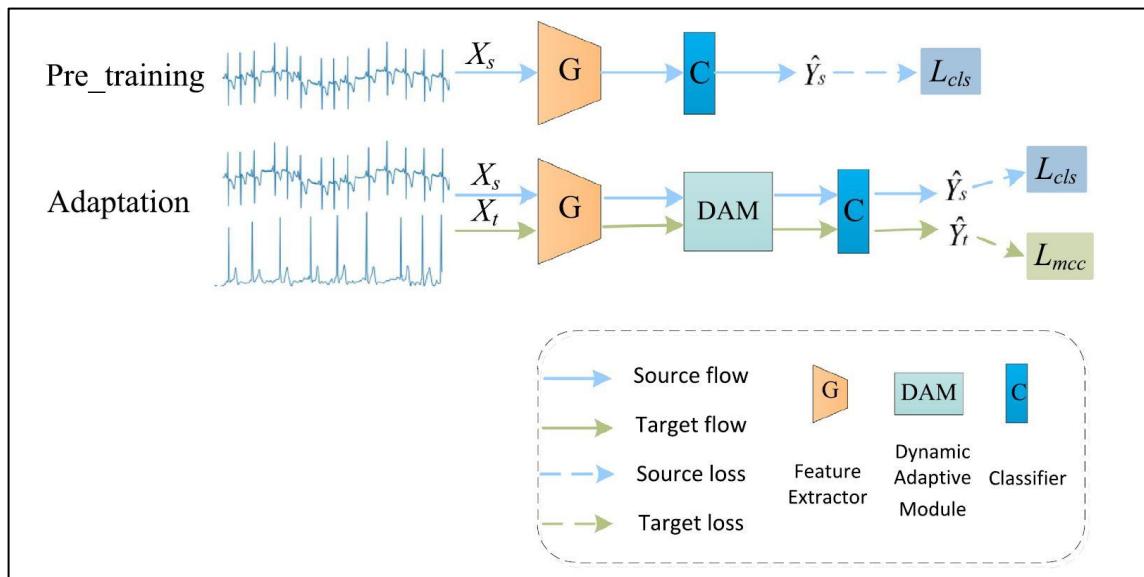
<sup>1</sup> Hybrid Approach of Dual Support Vector Machine<sup>2</sup> Linear Discriminant Analysis



شکل ۲-۱۲. معماری روش پیشنهادی گمال و همکاران.

سیگنال‌های الکتروگارديوگرام توسط دستگاهها و در شرایط متفاوتی ثبت و ضبط می‌شوند. به همین دلیل اغلب مدل‌های آموزش‌دهنده بر اساس یک پایگاهداده‌ی خاص، زمانی که مستقیماً روی یک مجموعه داده جدید اعمال می‌شوند عملکرد مطلوبی نخواهند داشت. جهت رفع این مساله هووفانگ شو و همکاران

یک شبکه انتقال پویا (DTN<sup>1</sup>) طراحی نموده اند که در دو فاز آموزش می‌بینند. به این ترتیب که ابتدا در فاز پیش‌آموزش، ۳ شبکه‌ی عصبی کانولوشنی به عنوان مدل‌های پیش‌آموخته توسط داده‌های پایگاه مرجع آموزش می‌بینند و سپس در فاز انطباق، یک مژول انطباقی پویا (DAM<sup>2</sup>) جهت کاهش اختلاف بین توزیع داده‌ها از طریق یادگیری‌های داده‌های مرجع و داده‌های هدف طراحی شده است. در نهایت ازتابع هزینه‌ی حداقل درهم ریختگی کلاس (MCC<sup>3</sup>) برای افزایش قابلیت تشخیص فیبریلاسیون دهلیزی در داده‌های هدف استفاده شده است. ۶ عملیات انتقال را بر روی ۳ پایگاه داده‌ی فیبریلاسیون دهلیزی ۲۰۱۸ AFDB (MIT-BIH)، پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت (Phy2017) و پایگاه داده‌ی چالش ۲۰۱۸ سیگنال‌های فیزیولوژیکی چین (CPSC2018) انجام شده است. شبکه‌ی DTN-VGG11 در عملیات انتقال از AFDB به CPSC2018 به دقت ۹۳٪/۳۸ F-score و شبکه‌ی DTN-AlexNet در عملیات انتقال از AFDB به Phy2017 به دقت ۹۱٪/۳۵ F-score و شبکه‌ی ۸۷٪/۹۲ F-score در عملیات انتقال از AFDB به Phy2017 به دقت ۹۶٪/۸۳ F-score و ۹۷٪/۵۸ F-score دست یافته است. نتایج تجربی نشان می‌دهد که شبکه انتقال پویا پیشنهادی تأثیر تغییرات داده را کاهش می‌دهد و عملکرد مطلوبی در طبقه‌بندی داده‌های منابع متفاوت دارد [۴۲].



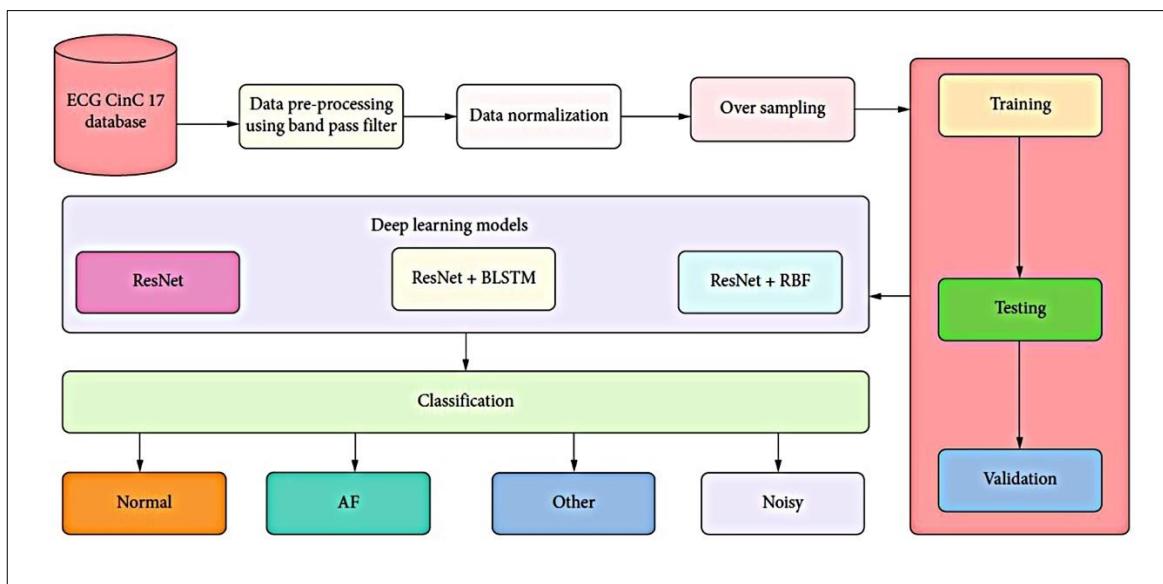
شکل ۲-۱۳. معماری روش پیشنهادی هووفانگ شو و همکاران.

<sup>1</sup> Dynamic Transfer Network

<sup>2</sup> Dynamic Adaptive Module

<sup>3</sup> Minimum Class Confusion

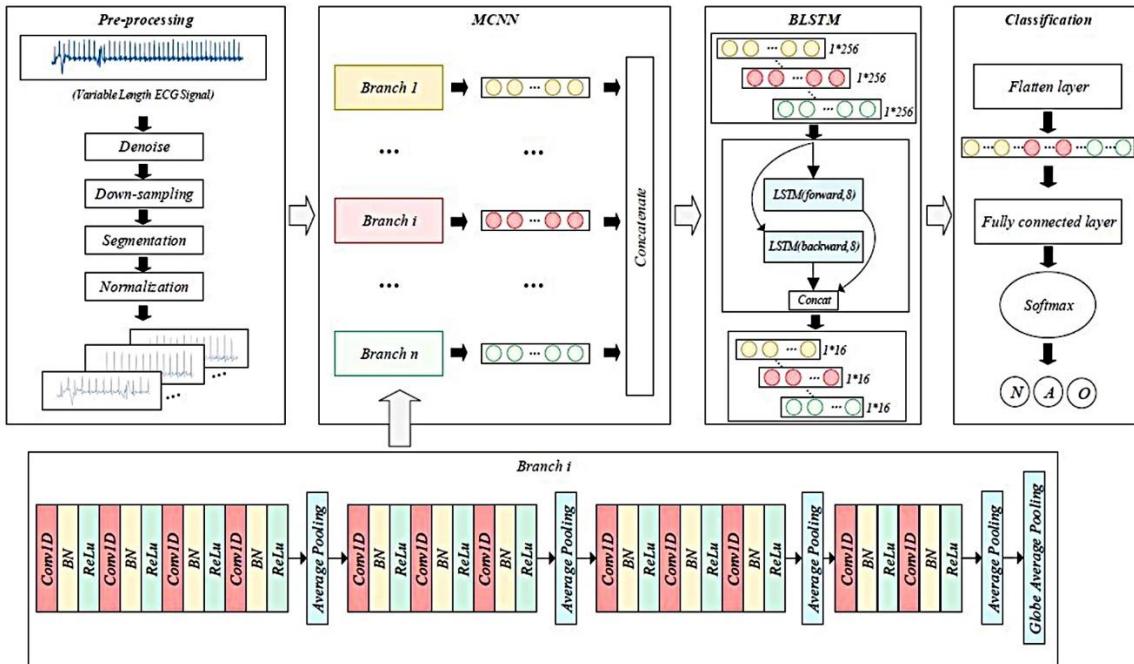
ساروج کومار پاندی و همکاران مدلی هایی ارائه نمودند که سیگنال های الکتروکاردیوگرام پایگاه داده چالش ۲۰۱۷ فیزیونت را در ۴ چهار کلاس طبقه بندی می نماید. این مدل ها از ترکیب یک شبکه عصبی باقیمانده(ResNet) و شبکه عصبی حافظه طولانی کوتاه مدت(LSTM) و شبکه عصبی شعاعی پایه(RBF) طراحی شده است. به این ترتیب که در یک مدل، شبکه عصبی باقیمانده و شبکه عصبی حافظه طولانی کوتاه مدت دو جهته ترکیب شده است و دیگری از ترکیب شبکه عصبی باقیمانده و شبکه عصبی شعاعی پایه تشکیل شده است. در نهایت F1-score به دست آمده برای دو مدل به ترتیب ۸۰/۵۸٪ و ۸۰٪ است [۴۳].



شکل ۲-۱۴. معماری روش پیشنهادی ساروج کومار پاندی و همکاران.

هونگپو جانگ و همکاران از ترکیب یک شبکه عصبی کانولوشنال چند شاخه ای(MCNN) و شبکه عصبی حافظه طولانی کوتاه مدت دو جهته(BLSTM) به منظور طبقه بندی سیگنال های الکتروکاردیوگرام پایگاه داده ی چالش ۲۰۱۷ فیزیونت استفاده نموده اند. مدل ترکیبی پیشنهادی، داده ها را در سه کلاس ریتم های نرمال سینوسی، فیبریلاسیون دهلیزی و سایر ریتم ها طبقه بندی می نماید. در این مدل ابتدا جهت استخراج ویژگی های بیشتر، از شبکه عصبی کانولوشنال چند شاخه ای استفاده شده است. این شبکه به صورت پویا شاخه هایی بر اساس تعداد قطعه های سیگنال های الکتروکاردیوگرام ایجاد می نماید. سپس شبکه عصبی حافظه طولانی کوتاه مدت دو جهته برای بهبود ویژگی های استخراج شده از هر شاخه طراحی شده است. مدل ارائه شده با پایگاه داده ی چالش ۲۰۱۷ فیزیونت اعتبارسنجی شده و تعمیم پذیری آن نیز با پایگاه داده ی چالش ۲۰۱۸ سیگنال های فیزیولوژیکی چین بررسی شده است. نتایج نشان می دهد که دقت و F-score مدل بر روی داده های فیزیونت به ترتیب ۸۷/۵۷٪ و ۸۴/۵۶٪ می باشد. همچنین

در دقت و F-score مدل بر روی پایگاه داده‌ی سیگنال‌های فیزیولوژیکی چین٪۸۷/۵۰ و٪۸۲/۰۱ می‌باشد [۴۴].



شکل ۲-۱۵. معماری روش پیشنهادی هونگپو جانگ و همکاران.

خلاصه‌ای از تحقیقات ارائه شده در زمینه‌ی تشخیص فیبریلاسیون دهلیزی در جدول ۲-۱ گزارش شده است.

جدول ۲-۱. خلاصه‌ای از تحقیقات ارائه شده در زمینه‌ی تشخیص فیبریلاسیون دهلیزی.

نویسنده	سال	تعداد کلاس‌ها	روش	پایگاه داده	دقت	اختصاصیت	حساسیت
دش و همکاران [31]	۲۰۰۹	۲	RMSSD TPR SE	MIT-BIH AF MIT-BIH Arrhythmia	٪۹۹/۱	٪۹۵/۱	٪۹۴/۴
افدلا و همکاران [۳۳]	۲۰۱۷	۲	ANN	PhysioNet AFDB	٪۸۹/۷۹	٪۸۹/۰۱	٪۹۱/۰۴
فن و همکاران [34]	۲۰۱۸	۲	MS-CNN	PhysioNet/CinC Challenges 2017	٪۹۸/۱۳	٪۹۸/۷۷	٪۹۳/۷۷
فن و همکاران	۲۰۲۰	۲	U-Net	MIT-BIH Arrhythmia	٪۸۷/۲۲	-	-

[۳۵]			ResNet	PhysioNet/CinC Challenges 2017			
شیا و همکاران [۳۶]	۲۰۱۸	۲	DCNN	MIT-BIH AF	.۹۸/۶۳	.۹۸/۲۴	.۹۸/۳۴
اندرسن و همکاران [۳۷]	۲۰۱۹	۲	CNN-BLSTM	MIT-BIH AF MIT-BIH Arrhythmia MIT-BIH NSR	-	.۹۶/۹۵	.۹۸/۹۸
وو و همکاران [۳۹]	۲۰۱۹	۲	CNN-LSTM	PhysioNet/CinC Challenges 2017	.۹۷/۰۸	.۹۸/۵۷	.۹۵/۵۲
لون و همکاران [۴۰]	۲۰۲۰	۲	SVM	MIT-BIH AF MIT-BIH Arrhythmia	-	.۹۷/۶	۹۵
کومار و همکاران [۴۱]	۲۰۲۱	۵	BLSTM	MIT-BIH Arrhythmia	.۹۹/۵۲	-	.۹۹/۴۱
پتمزاس و همکاران [۴۲]	۲۰۲۱	۴	CNN-LSTM	MIT-BIH AF	-	.۹۹/۲۹	.۹۷/۸۷
گمال و همکاران [۴۳]	۲۰۲۲	۲	HA-SVM HA-DSVM	PhysioNet/CinC Challenges 2017	.۹۹/۲۷	-	-
هورویانگ شو و همکاران [۴۴]	۲۰۲۳	۲	DTN-AlexNet DTN-VGG1 DTN-ResNet	PhysioNet/CinC Challenges 2017 MIT-BIH AF CPSC 2018	.۹۱/۳۵ .۹۳/۳۸ .۹۷/۵۸	-	-
ساروج کومار پاندی و همکاران [۴۵]	۲۰۲۲	۴	ResNet+BLSTM ResNet+RBF	PhysioNet/CinC Challenges 2017	.۸۲/۸۷ .۸۴/۵۶	-	-
هونگپو جانگ و همکاران [۴۶]	۲۰۲۲	۳	MCNN+BLSTM	PhysioNet/CinC Challenges 2017 CPSC 2018	.۸۷/۵۷ .۸۷/۵۰	-	-

فیزیونت<sup>۱</sup> نام یک بانک داده‌ای برای سیگنال‌های دیجیتال است که سالانه با مشارکت کنفرانس سالانه محاسبات قلب و عروق<sup>۲</sup> رشتۀ‌ای از چالش‌ها را برگزار می‌کند. این چالش‌ها عمدهاً متمرکز بر مسائل حل نشده در علوم پزشکی و علوم پایه هستند که در آن‌ها از محققین و دانشجویان دعوت می‌شود که با استفاده از مجموعه داده‌های ارائه شده توسط فیزیونت به حل مسائل پزشکی بپردازنند [۴۵]. چالش ۲۰۱۷ CinC فیزیونت (Physionet/CinC Challenge 2017) با هدف تشویق محققین به طراحی

<sup>1</sup> Physionet<sup>2</sup> Computing in Cardiology

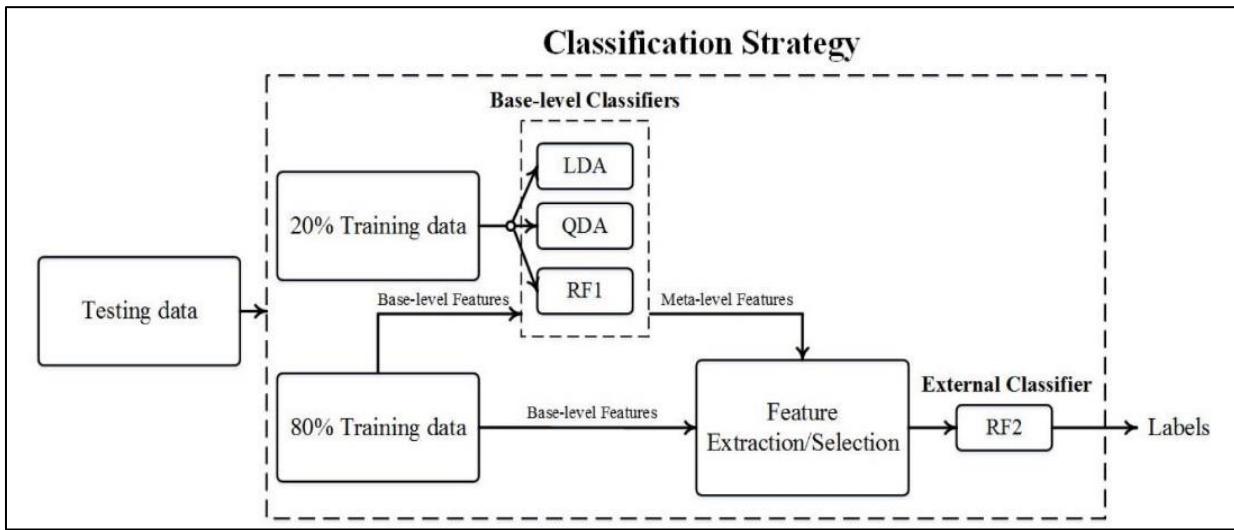
الگوریتم‌هایی برای طبقه‌بندی سیگنال‌های کوتاه الکتروکاردیوگرام تک لید با طول ۳۰ تا ۶۰ ثانیه برگزار گردید. این سیگنال‌ها در چهار کلاس ریتم سیونسی نرمال، فیبریلاسیون دهلیزی، سایر ریتم‌ها و سیگنال‌های نویزی قرار گرفته‌اند [۴۶]. با توجه به این که پایگاه داده‌ی مورد استفاده در این پژوهش پایگاه داده‌ی چالش ذکر شده است، در ادامه به بررسی مطالعات صورت گرفته روی این دادگان پرداخته شده است. ابتدا پژوهش‌های انجام شده روی این دادگان با رویکرد طبقه‌بندی چهار کلاسه که ۳ پژوهش رتبه‌ی اول مسابقات این چالش بوده‌اند، مورد بررسی قرار گرفته است. سپس مقاله‌های دیگر که در سال‌های بعد از مسابقه‌ی چالش نتایج بهتری از رتبه‌های اول در طبقه‌بندی چهار کلاسه کسب کرده‌اند، مورد بررسی قرار گرفته است.

قابل ذکر است که طبق قوانین محاسباتی چالش برای شرکت‌کنندگان، طبقه‌بندی داده‌ها باید چهار کلاسه باشد و معیار انتخابی برای گزارش عملکرد مدل F-score است که در محاسبه‌ی این امتیاز باید صرفاً از F-score مربوط به سه کلاس نرمال، فیبریلاسیون دهلیزی و سایر ریتم‌ها میانگین گرفته شود و نیازی به احتساب F-score مربوط به کلاس نویزدار در میانگین نیست. بنابراین امتیاز گزارش شده برای سه برنده‌ی این چالش به این ترتیب محاسبه شده است. اما در روش‌های مربوط به سال‌های اخیر و با توجه به ارتقای عملکرد مدل‌های پیشنهادی، F-score کل از میانگین این معیار برای هر چهار کلاس به دست آمده است. در ادامه ابتدا به بررسی روش‌های پیشنهادی توسط سه برنده‌ی این چالش و سپس پژوهش‌های تکمیلی در سال‌های بعد از چالش پرداخته شده است.

روش تحقیق ذبیحی و همکاران شامل سه بخش پیش‌پردازش، استخراج ویژگی‌ها، انتخاب ویژگی و طبقه‌بندی می‌شود [۴۷]. آن‌ها در مجموع ۴۹۱ ویژگی را استخراج کرده و سپس در یک فرآیند رتبه‌بندی ۱۵۰ ویژگی را انتخاب کرده‌اند. ویژگی‌های انتخاب شده از حوزه‌ی فرکانس، زمان و زمان-فرکانس و PSR<sup>۱</sup> سیگنال‌های ECG می‌باشند. در مرحله‌ی نهایی یک الگوریتم طبقه‌بند جنگل تصادفی (RF<sup>2</sup>) جهت طبقه‌بندی ویژگی‌های انتخاب شده در یکی از چهار کلاس سیگنال‌های الکتروکاردیوگرام طراحی شده است. الگوریتم RF از ۵۰۰ درخت تصمیم تشکیل شده است. برای هر گره ۳۰ ویژگی به صورت تصادفی انتخاب شده است. با استفاده از روش امتیازدهی چالش ۲۰۱۷ فیزیونت، امتیاز کلی به دست آمده با روش اعتبارسنجی متقابل ۱۰ برابری روی داده‌های آموزش  $\pm 81/9\%$  است. الگوریتم پیشنهاد شده در این تحقیق با امتیاز  $82/6\%$  گرد شده به  $83\%$  روی داده‌های آزمایشی رتبه‌ی اول در چالش ۲۰۱۷ فیزیونت را کسب کرده است. در شکل ۲-۱۶ استراتژی طبقه‌بندی تحقیق ارائه شده توسط آن‌ها نشان داده شده است.

<sup>1</sup> Phase Space Reconstruction

<sup>2</sup> Random Forest



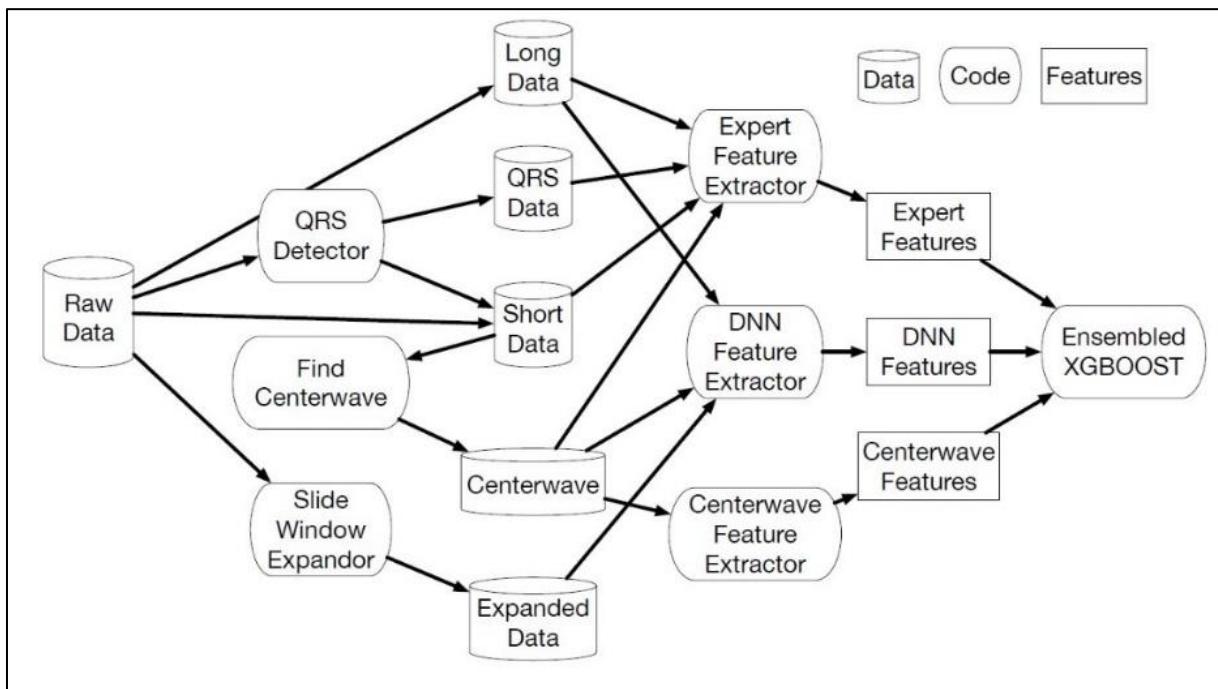
شکل ۲-۱۶. معماری روش پیشنهادی ذبیحی و همکاران (رتبه اول کسب شده در چالش فیزیونت).

هانگ و همکارانش مدلی به نام ENCASE معرفی کردند که ویژگی‌های تخصصی و ویژگی‌های استخراج شده از شبکه‌های عصبی عمیق (DNN<sup>۱</sup>) را برای طبقه‌بندی سیگنال‌های الکتروکاردیوگرام ترکیب می‌کند [۴۸]. آن‌ها ابتدا ویژگی‌های تخصصی از حوزه‌ی آماری، پردازش تصویر و پزشکی را جستجو و پیاده‌سازی کرده‌اند. سپس با طراحی شبکه‌ی عصبی عمیق ویژگی‌های عمیق را به صورت خودکار استخراج کرده‌اند. علاوه بر آن الگوریتمی پیشنهاد داده‌اند که بخشی از سیگنال که حاوی بیشترین اطلاعات است (موج مرکزی) را می‌یابد و ویژگی‌ها را از آن استخراج می‌کند. در نهایت این ویژگی‌های به دست آمده باهم ترکیب شده و به یک الگوریتم طبقه‌بند گروهی<sup>۲</sup> داده شده‌اند. برای طبقه‌بندی سیگنال الکتروکاردیوگرام چهار کلاسه مقدار F-score برابر با ۰.۸۴٪ به دست آمده است. مدل ENCASE ترکیب گروهی<sup>۳</sup> ۵ XGBoost است و هر ۳۰۰۰ درخت تصمیم با ماکریزم عمق ۹ و مینیم وزن ۳ است. شکل ۲-۱۳ نشان‌دهنده‌ی معماری روش پیشنهاد شده توسط هانگ و همکارانش است.

<sup>۱</sup> Deep Neural Network

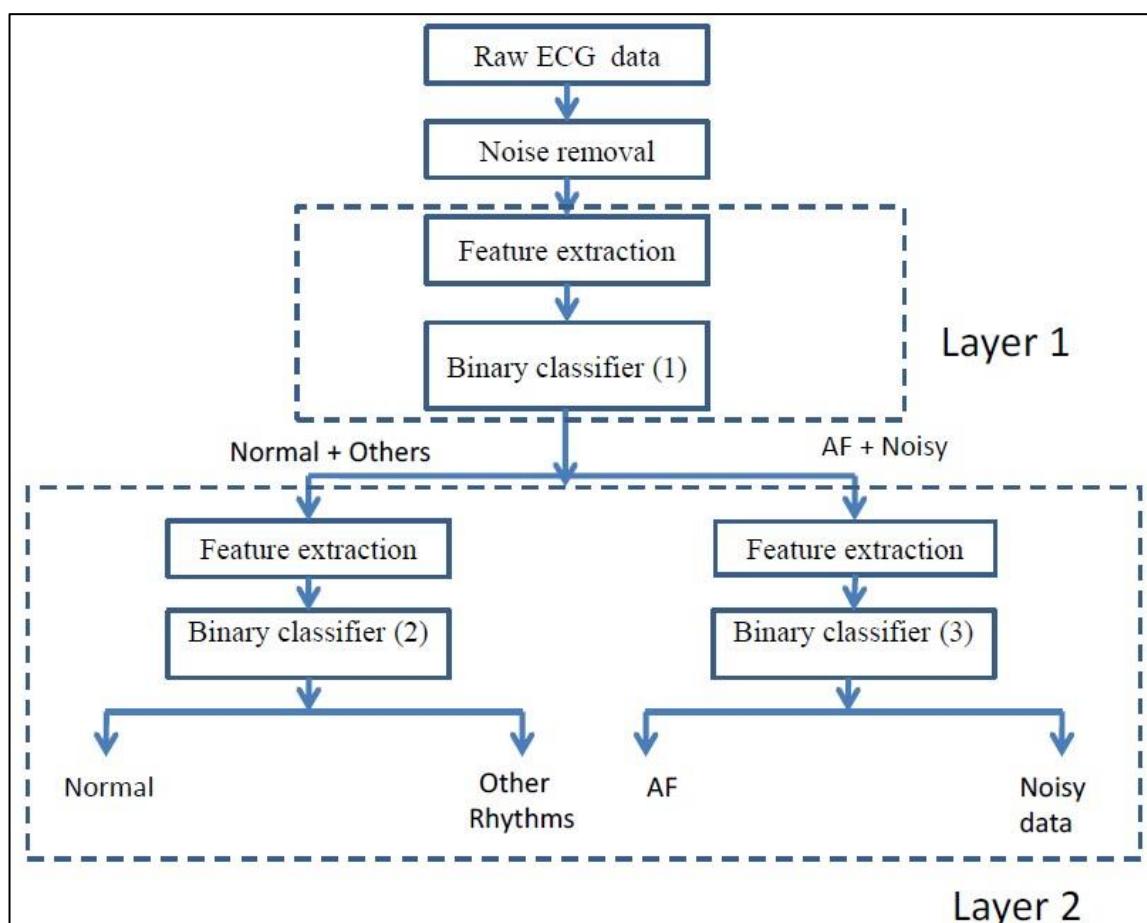
<sup>۲</sup> Ensemble Classifier

<sup>۳</sup> Extreme Gradient Boosting of Decision Trees



شکل ۲-۱۷. معماری پیشنهادی هانگ و همکارانش به نام ENCASE

در مدل پیشنهادی دادا و همکارانش از یک رویکرد دو لایه‌ای باینری استفاده شده است. به این ترتیب که در الگوریتم طبقه‌بندی لایه‌ی اول، سیگنال‌ها به دو کلاس کلی ('نرمال و سایر ریتم‌ها' و 'AF و نویزدار') طبقه‌بندی می‌شوند. سپس در لایه‌ی دوم داده‌های کلاس‌های کلی از یکدیگر تفکیک می‌شوند. که به این رویکرد، رویکرد طبقه‌بندی آبشاری چندلایه باینری گفته می‌شود [۴۹]. تحقیقات گذشته نشان می‌دهند که اغلب برای داده‌های نامتوازن چند کلاسه، استفاده از طبقه‌بندهای آبشاری باینری مناسب به صورت سری بهتر از یک طبقه‌بند چندکلاسه به تنها می‌باشد [۵۰] و [۵۱]. در لایه‌های طبقه‌بندی از الگوریتم Adaboost که یک الگوریتم یادگیری گروهی مت Shank از چند الگوریتم ضعیف است، استفاده شده است. به این ترتیب که طبقه‌بندهای ضعیف در هر تکرار به چرخه‌ی یادگیری اضافه شده و برداری از اوزان جهت کاهش خطأ به روزرسانی می‌شود. پارامترهای هر سه طبقه‌بند گروهی شامل تعداد چرخه‌های یادگیری و نرخ یادگیری با استفاده ازتابع بهینه‌سازی بیزین تعیین شده‌اند. در نهایت نتیجه‌ی این تحقیق با رسیدن به  $f\text{-score} = 0.83$  به رتبه‌ی اول در چالش ۲۰۱۷ فیزیونت دست یافته است. شکل ۲-۱۸ نشان‌دهنده‌ی معماری روش پیشنهاد شده توسط دادا و همکارانش است.



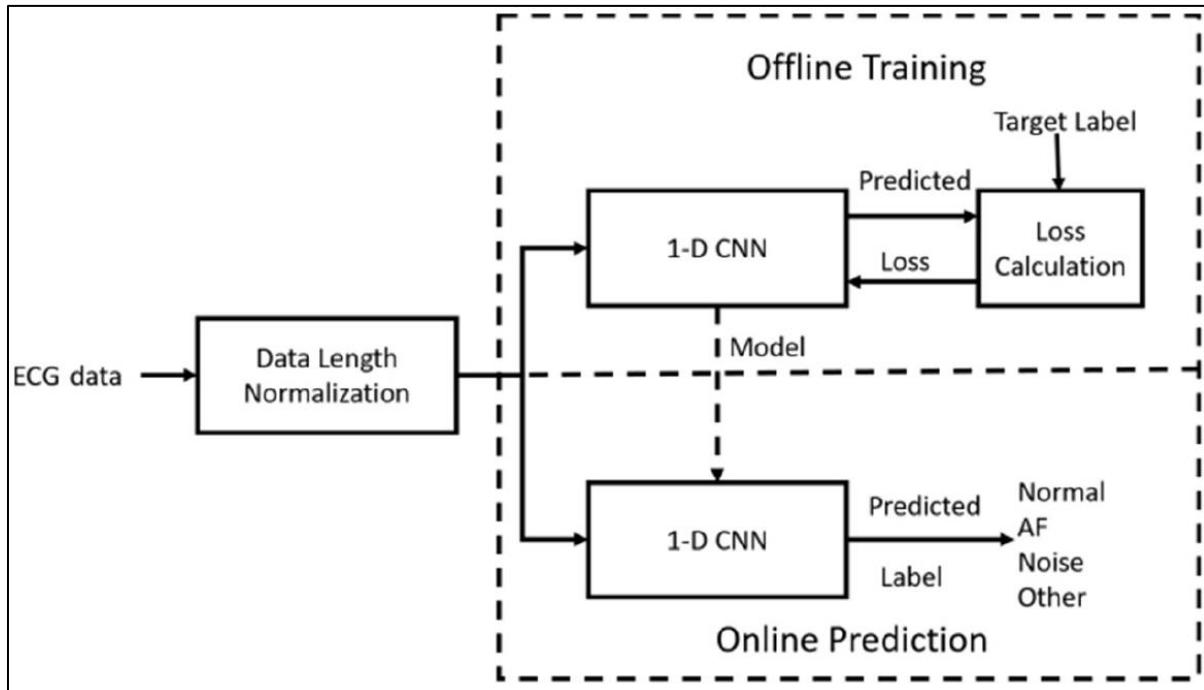
شکل ۲-۱۸. معماری روش پیشنهاد شده توسط داتا و همکارانش.

در ادامه چهار نمونه از پژوهش‌های ارائه شده در سال‌های بعد از ۲۰۱۷ که به صورت تکمیلی جهت بهبود نتایج قبلی صورت گرفته‌اند، مورد بررسی قرار گرفته است. این پژوهش‌ها به بهترین نتایج در زمینه‌ی طبقه‌بندی چهار کلاسی داده‌های چالش فیزیونت دست یافته‌اند.

چور هی شی و همکاران برای تشخیص فیبریلاسیون دهلیزی یک معماری پیشنهاد دادند که با استفاده از شبکه‌ی عصبی کانولوشنال، علاوه بر افزایش دقیق تحلیل، پیچیدگی شبکه را کاهش می‌داد. این گروه برای رسیدن به بهترین دقیق و بهینه‌سازی ابرپارامترهای شبکه‌ی عصبی کانولوشنال از روش جستجوی گرید<sup>۱</sup> استفاده کردند. همچنین یک الگوریتم نرمال‌سازی طول سیگنال ارائه کردند که سیگنال‌هایی با طول برابر تولید می‌کند تا با نیازهای شبکه‌ی عصبی کانولوشنال که ورودی با طول ثابت است، هماهنگ باشد. آستانه‌ی طول سیگنال محاسبه شده با این الگوریتم برابر با ۳۰ ثانیه است که چون نرخ نمونه‌برداری ۹۰۰۰ نمونه در ثانیه است، معادل با ۹۰۰۰ نمونه برای هر سیگنال می‌باشد. معادل با ۹۰۰۰ نمونه در این تحقیق برای محاسبه‌ی F-score کل، برخلاف مدل‌های پیشین که در چالش شرکت کرده بودند، از score هر چهار کلاس نرمال، فیبریلاسیون دهلیزی، سایر ریتم‌ها و نویزی میانگین گرفته شده است.

<sup>۱</sup> Grid Search

درنهایت مقدار میانگین به دست آمده برای این معیار برابر با  $78/2$  می باشد [۵۲]. روش ارائه شده در این تحقیق در شکل ۲-۱۹ نشان داده شده است.

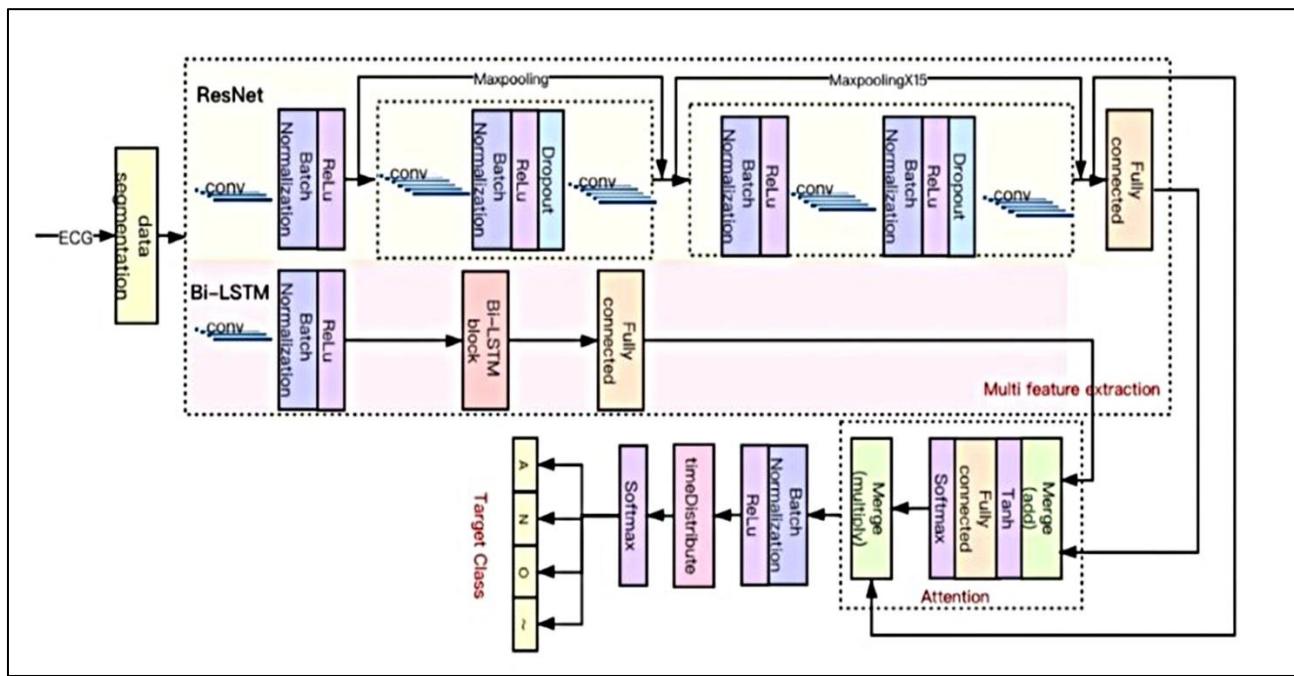


شکل ۲-۱۹. معماری ارائه شده توسط چوره‌ی شی و همکاران برای تشخیص AF

در سال‌های اخیر با پیشرفت هوش مصنوعی، استفاده از مدل‌های یادگیری عمیق به موفقیت ابتدایی در تحلیل سیگنال‌های الکتروکاردیوگرام دست یافته است. اما این شبکه‌ها با مشکل عدم توجه به مشکل پراکندگی گرادیان مواجه بودند. مین فنگ چانگ و همکاران به منظور حل این مشکل روش ترکیبی یادگیری عمیق مبتنی بر توجه (HADLN<sup>1</sup>) را برای طبقه‌بندی آریتمی قلبی ارائه کردند. HADLN از مزایای هر دو شبکه‌ی باقی‌مانده و حافظه‌ی طولانی کوتاه مدت دو طرفه (Bi-LSTM) استفاده کرده و به ویژگی‌های تلفیقی دست می‌یابد. این ویژگی‌ها حاوی اطلاعات کامل در سطح محلی و سراسری می‌باشند و تفسیرپذیری مدل را با استفاده از مکانیزم توجه<sup>2</sup> ارتقا می‌دهند. مفهوم اصلی این مکانیزم، شبیه‌سازی مکانیزم توجه انسان به منظور ارتقای عملکرد یادگیری عمیق است [۵۳]. درنهایت مدل ارائه شده سیگنال‌های الکتروکاردیوگرام را در چهار دسته‌ی نرمال، فیبریلاسیون دهلیزی، سایر ریتم‌ها و نویزدار با  $F\text{-score} = 0.88$ ، یادآوری  $= 0.859$ ، دقت  $= 0.867$  و صحت  $= 0.866$  طبقه‌بندی کرده است [۵۴]. معماری شبکه HADLN در شکل ۲-۲۰ نشان داده شده است.

<sup>1</sup> Hybrid Attention-based Deep Learning Network

<sup>2</sup> Attention Mechanism



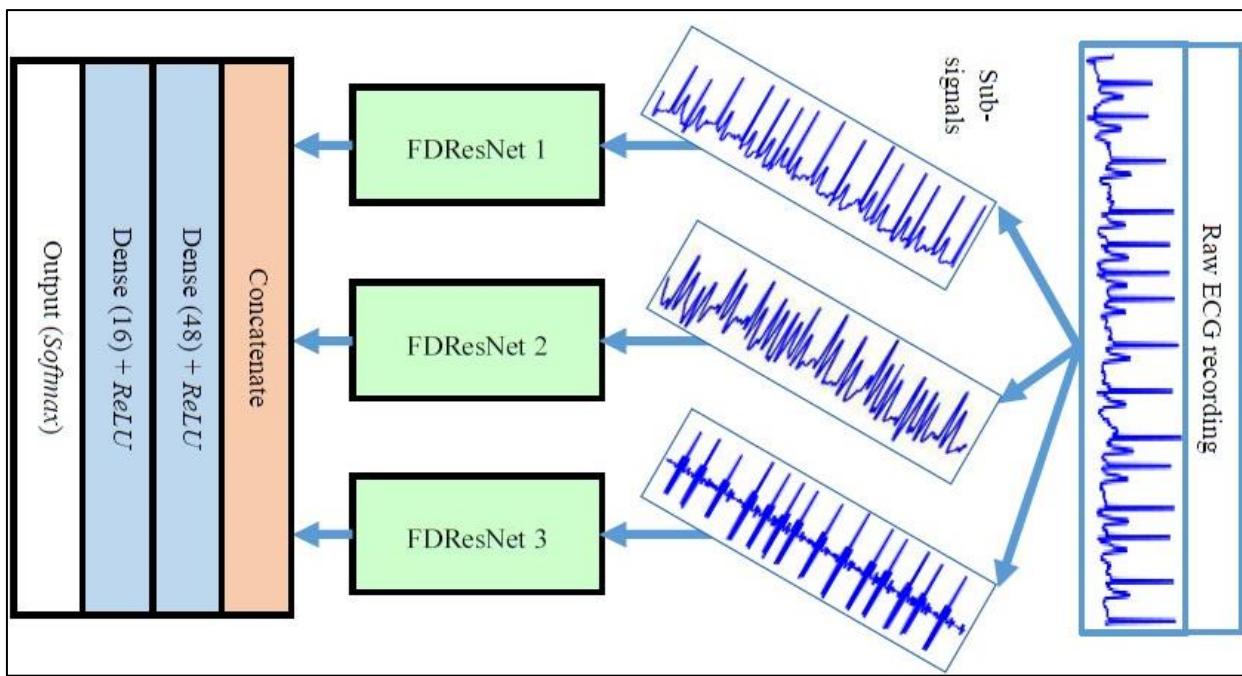
شکل ۲-۲۰. معماری شبکه HADLN ارائه شده توسط مین فنگ چانگ و همکاران.

اکسین چنگ سیو و همکاران به منظور پرداختن به این مشکل، یک شبکه عصبی کانولوشنال باقیمانده با تجزیه چند مقیاسی بهبود یافته پیشنهاد داده‌اند. روش پیشنهادی برروی مجموعه داده الکتروکاردوگرام تک لید ارائه شده توسط چالش ۲۰۱۷ فیزیونت پیاده‌سازی شده و به دقت طبقه‌بندی خوبی دست یافته است. در روش پیشنهادی، سیگنال‌های الکتروکاردوگرام اصلی با اختلاف طول زیاد به نمونه‌های کوتاه ۹ ثانیه تقسیم می‌شوند. سپس، با استفاده از تجزیه قاب موجک<sup>۱</sup>، نمونه‌های کوتاه تقسیم شده، تجزیه شده و سپس به نمونه‌های فرعی سیگنال در مقیاس‌های مختلف بازسازی می‌شوند. ابتدا شبکه‌های عصبی کانولوشنال باقیمانده با نمونه‌برداری سریع (FDResNet<sup>۲</sup>) با سیگنال‌های کوتاه و بازسازی شده هر مقیاس آموزش داده شده سپس روش یادگیری انتقال جهت ترکیب نمودن سه FDResNet با عملکرد خوب در یک شبکه عصبی کانولوشنال باقیمانده با تجزیه چند مقیاسه (MSResNet<sup>۳</sup>) اعمال می‌شود. پس از انجام اعتبارسنجی متقابل ۶ تایی به دقت ۹۲٪/۹ f-score دست یافته‌اند [۵۵]. روش ارائه شده در این تحقیق در شکل ۲-۲۱ نشان داده شده است.

<sup>1</sup> Wavelet Frame Decomposition

<sup>2</sup> Fast Down-sampling Residual Network

<sup>3</sup> Multi-Scale Residual Network



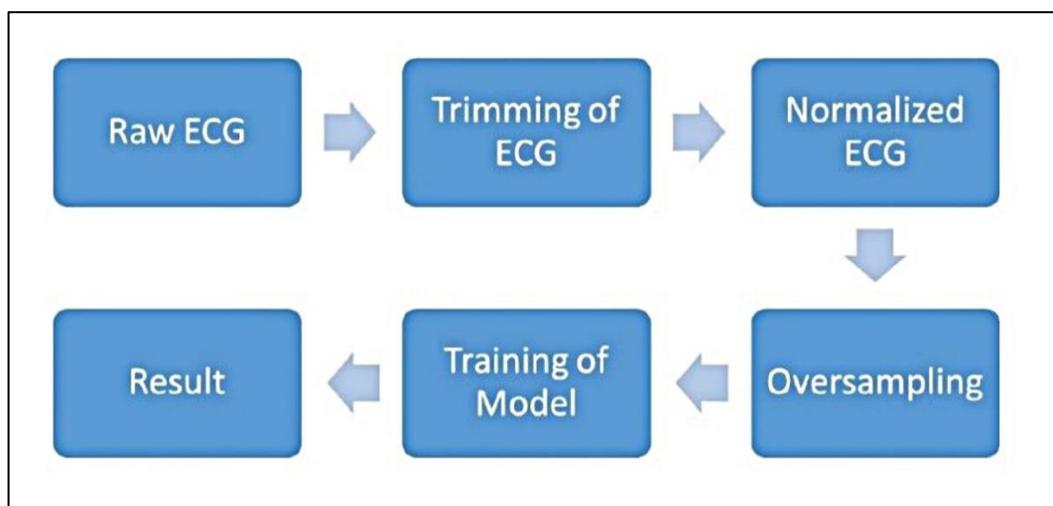
شکل ۲-۲۱. معماری شبکه FDResNet چند مقیاسه پیشنهادی توسط اکسین چنگ سیو و همکاران.

دواج ورما و همکاران یک مدل یادگیری عمیق ترکیبی از شبکه‌ی عصبی کانولوشنال و حافظه‌ی طولانی کوتاه مدت طراحی کردند. این مدل با کمک روش بیش نمونه گیری<sup>۱</sup> داده‌های چالش ۲۰۱۷ فیزیونت را در چهار دسته‌ی نرمال، فیبریلاسیون دهلیزی، سایر ریتم‌ها و نویزدار طبقه‌بندی می‌کند. روش بیش نمونه گیری انتخاب شده در این تحقیق<sup>۲</sup> SMOTE<sup>۳</sup> نام دارد که تعداد نمونه‌های کلاس‌های کم جمعیت را افزایش می‌دهد و از این طریق پایگاه داده را متوازن می‌کند. پس از پیاده‌سازی SMOTE تعداد کل دادها به ۲۰۶۱۶ نمونه می‌رسد. یعنی در هر کلاس ۵۱۵۴ تا نمونه وجود دارد که با رساندن تعداد کلاس‌های کم جمعیت به پرجمعیت‌ترین کلاس به دست آمده است. معماری شبکه‌ی پیشنهادی در این تحقیق به این شکل است که از ۱۳ لایه تشکیل شده است. ۳ لایه کانولوشن یک بعدی جهت استخراج ویژگی‌ها از سیگنال‌های الکتروکاردیوگرام نرمال‌سازی شده و بعد از هر لایه‌ی کانولوشن یک لایه‌ی maxpooling برای استخراج بیشترین مقدار و حذف مقادیر زائد قرار داده شده است. سپس یک لایه‌ی dropout برای جلوگیری از بیش برآش قرار گرفته است. ابعاد کرنل در دو لایه‌ی اول ۶ و در لایه‌ی آخر ۳ می‌باشد. بعد از لایه‌های شبکه‌ی عصبی کانولوشنال، از دو لایه‌ی شبکه‌ی حافظه‌ی طولانی کوتاه مدت با ۶۴ نورون استفاده شده است. بعد از شبکه‌ی حافظه‌ی طولانی کوتاه مدت ویژگی‌های استخراج شده از این دو شبکه به دو لایه‌ی کاملاً متصل با چهار نورون خروجی برای چهار کلاس داده و تابع softmax داده می‌شوند. در نهایت مدل پیشنهادی توسط این مقاله به ۹۱٪/۱ F-score برای طبقه‌بندی چهار کلاسه

<sup>1</sup> Oversampling

<sup>2</sup> Synthetic Minority Over-Sampling Technique

دست یافته است که این امتیاز بالاترین امتیاز به دست آمده در میان تحقیقات برای طراحی الگوریتم‌های چهارکلاسه روی پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت است [۵۶]. روش ارائه شده در این تحقیق در شکل ۲-۲۲ نشان داده شده است.



شکل ۲-۲۲. معماری شبکه‌ی پیشنهادی توسط دواج ورما و همکاران.

خلاصه‌ای از تحقیقات ارائه شده در زمینه‌ی تشخیص فیبریلاسیون دهلیزی بر روی پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت در جدول ۲-۲ گزارش شده است.

جدول ۲-۲. خلاصه‌ای از تحقیقات ارائه شده بر روی پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت

نویسنده	سال	روش	دادگان	F1-score
چور هی شی و همکاران	۲۰۲۰	CNN	PhysioNet	٪۷۸/۲
مین فنگ چانگ و همکاران	۲۰۲۱	ResNet / LSTM	PhysioNet	٪۸۸/۰
دواج رما و همکاران	۲۰۱۸	CNN / LSTM	PhysioNet	٪۹۱/۱
اکسین چنگ سیو و همکاران	۲۰۱۹	FDResNets	PhysioNet	٪۸۹/۹

## ۷-۲- جمع‌بندی

فیبریلاسیون دهلیزی از مهم‌ترین عوامل مرگ و میر در جهان محسوب می‌شوند، جلوگیری از افزایش این مرگ و میرها نیازمند روش‌هایی است که بتوانند به طور خودکار آریتمی را تشخیص دهند. روش‌های

تشخیص خودکار به کاهش خطای پزشکی کمک کرده و نقش مهمی در تشخیص زودهنگام و دقیق بسیاری از بیماری‌ها با کمک روش‌های پردازش سیگنال و یادگیری ماشین ایفا می‌کند. سیگنال الکتروکاردیوگرام معمول‌ترین روش غیرتهاجمی برای بررسی سلامتی قلب یا تشخیص احتمالی بیماری‌های قلبی است. در این فصل ابتدا به معرفی فیبریلاسیون دهلیزی و عوامل موثر در ابتلا و نشانه‌های این آریتمی پرداخته و در ادامه به تعریف هوش مصنوعی، یادگیری ماشین و یادگیری عمیق پرداخته شده است. در نهایت مروری بر روش‌های ارائه شده در زمینه‌ی تشخیص و طبقه‌بندی فیبریلاسیون دهلیزی که به طور کلی در سه گروه روش‌های آماری، روش‌های یادگیری ماشین و روش‌های یادگیری عمیق قرار گرفته‌اند، انجام شده است. سپس با تمرکز بر روش‌های ارائه شده بر روی پایگاهداده‌ی چالش ۲۰۱۷ فیزیونت، روش پیشنهادی سه گروه برنده در این چالش بررسی شده است. در نهایت به مرور روش‌های پیشنهادی در سال‌های بعد از چالش که به صورت تکمیلی و با دقت بالا انجام شده‌اند، پرداخته شده است. با توجه به مطالعات انجام شده در مورد روش‌های پیشین می‌توان دریافت که هریک از روش‌های مبتنی بر یادگیری عمیق و یا یادگیری ماشین سنتی دارای مزیت‌های منحصر به فرد خود بوده و به نتایج مطلوبی دست یافته‌اند. با الهام از شبکه‌ی عمیق پیشنهادی توسط دواج ورما و همکاران که به بالاترین دقت موجود برای طبقه‌بندی چهار کلاسه دست یافته است، تصمیم به طراحی معماری مبتنی بر شبکه‌ی عمیق ترکیبی و روش‌های سنتی یادگیری ماشین گرفته شد. با این امید که با افزودن مزیت‌های حاصل از روش‌های مبتنی بر ویژگی، به عملکرد بهتری دست یافت.

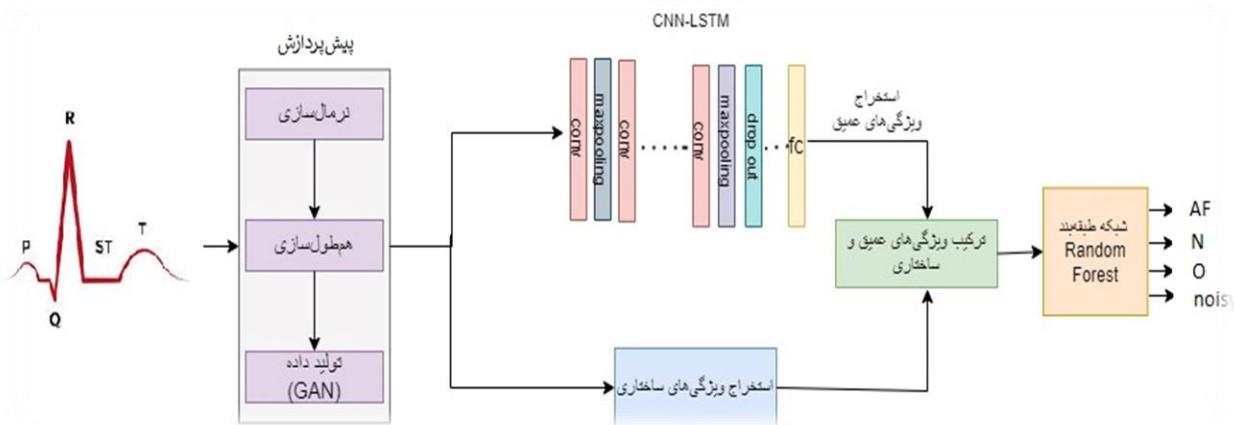
فصل سوم

روش پژوهش

## مقدمه

در گذشته برای پردازش سیگنال‌های الکتروکاردیوگرام و طبقه‌بندی آن‌ها از روش‌های مبتنی بر استخراج دستی ویژگی‌ها و همچنین روش‌های سنتی یادگیری ماشین بهره می‌بردند. اما در سال‌های اخیر طبقه‌بندی سیگنال‌های الکتروکاردیوگرام بیشتر مبتنی بر شبکه‌های عمیق بوده است. مهم‌ترین مزیت این شبکه‌ها توانایی آن‌ها در استخراج ویژگی‌های سیگنال ورودی به صورت خودکار و بدون نیاز به انجام فرآیند پیچیده و زمان‌بر استخراج دستی ویژگی‌هاست. به دلیل این مزیت مهم، استفاده از این شبکه‌ها در جهت کاربردهای مختلف پزشکی مورد توجه پژوهشگران قرار گرفته است. هدف اصلی از پردازش سیگنال‌های الکتروکاردیوگرام با استفاده از شبکه‌های عمیق، تشخیص بهتر و سریع‌تر بیماری برای اطمینان از معالجه‌ی تعداد بسیار زیاد بیمار در یک زمان است. علاوه بر این، پردازش خودکار سیگنال‌های الکتروکاردیوگرام باعث کاهش خطای انسانی و همچنین باعث کاهش زمان و هزینه می‌شود. با این حال پردازش سیگنال‌های الکتروکاردیوگرام با استفاده از شبکه‌های عمیق همواره با محدودیت‌هایی از جمله وابستگی موفقیت این شبکه‌ها به اندازه‌ی مجموعه داده آموزش همراه است که در بیشتر موارد داده با حجم بالا در دسترس نیست و تولید مجموعه داده و برچسب زدن آن، به یک نیروی متخصص نیاز دارد که بسیار پرهزینه بوده و نیاز به تلاش و زمان زیادی دارد.

در این پژوهش سعی بر آن بوده است تا از هر دو رویکرد روش‌های یادگیری ماشین سنتی و یادگیری عمیق در کنار هم استفاده شود. به این ترتیب می‌توان از مزیت‌های هر دو رویکرد در کنار هم بهره برد. در ادامه‌ی این فصل جزئیات روش پیشنهادی به تفصیل شرح داده شده است. جزئیات روش پیشنهادی در شکل ۳-۱ نمایش داده شده است. در ادامه این فصل به جزئیات روش پیشنهادی پرداخته شده است.



شکل ۳-۱. نمای کلی از روش پیشنهادی.

### ۳-۱-۳ - پیش‌پردازش مجموعه دادگان

داده‌های پژوهشی عموماً دارای کیفیت مطلوبی نمی‌باشند و ممکن است دارای انواع نویز باشند؛ یا به علت ضبط ناقص ممکن است بخشی از سیگنال دچار مشکل شده باشد. وجود این عوامل باعث کاهش دقت شبکه‌های مورد استفاده برای تشخیص بیماری‌ها بر روی این گونه سیگنال‌ها می‌شود. برای بهبود عملکرد سیستم می‌توان سیگنال‌های مجموعه دادگان را قبل از ورود به شبکه طبقه‌بندی<sup>۱</sup> پیش‌پردازش کرد. در ادامه جزییات فرآیند پیش‌پردازش مجموعه دادگان شرح داده شده است.

### ۳-۱-۱-۳ - نرمال‌سازی سیگنال‌ها

این عمل جهت نگاشت مقادیر نمونه به فضایی صورت می‌گیرد که با حفظ شکل کلی سیگنال‌ها، دامنه آن‌ها به هم نزدیک‌تر شود. می‌توان گفت منظور از نرمال‌سازی، تبدیل داده‌ها به دامنه‌ی [۰ و ۱] است. هر کدام از داده‌های ثبت شده در مجموعه دادگان به بازه‌ای بین صفر و یک تغییر خواهد نمود. این امر باعث می‌شود داده‌ها تحت دامنه‌ی کوتاه‌تری قرار گیرند و مدل طبقه‌بندی بهتر آموخت باید برای نرمال‌سازی از معادله ۳-۱ استفاده می‌شود:

$$x = \frac{x - X_{min}}{X_{max} - X_{min}} \quad \text{معادله ۳-۱}$$

که در این فرمول  $X_{min}$  و  $X_{max}$  به ترتیب برابر با مقادیر بیشینه و کمینه داده‌ها در مجموعه دادگان هستند و معادل داده‌ی خاص در مجموعه دادگان است.

### ۳-۱-۲-۲ - یکسان‌سازی طول سیگنال‌ها

به منظور یکسان‌سازی طول سیگنال‌های موجود در مجموعه داده، هر سیگنال‌های الکتروکاردیوگرام را اصلاح نموده تا دارای ۹۰۰۰ نمونه باشد (۳۰ ثانیه با فرکانس ۳۰۰ هرتز). به این ترتیب اگر سیگنالی بیش از ۹۰۰۰ نمونه داشته باشد، نمونه‌های باقیمانده نادیده گرفته خواهند شد. هچنین برای سیگنال‌هایی با کمتر از ۹۰۰۰ نمونه از روش لایه‌گذاری یکسان<sup>۲</sup> استفاده شده است.

<sup>1</sup> Classification Network

<sup>2</sup> Same Padding

### ۳-۱-۳- تولید داده

با بررسی مجموعه دادگان به این مهم پی برده شد که مجموعه دادگان غیرمتوازن است که این مسئله باعث سوگیری<sup>۱</sup> شبکه به سمت داده با فراوانی بیشتر می شود و شبکه به خوبی آموزش نمی بیند. از سویی دیگر شبکه های عمیق نیاز به داده زیادی دارند و هرچه میزان داده بیشتر باشد، شبکه نمونه های بیشتری را مشاهده می کند و به طبع میزان دقیق شبکه نیز افزایش می یابد. به منظور افزایش تعداد داده، از شبکه های مولد تخصصی<sup>۲</sup> استفاده شده است. شبکه های مولد تخصصی<sup>۳</sup> که به شبکه های GAN معروف هستند، در سال ۲۰۱۴ میلادی توسط گودفلو<sup>۴</sup> ابداع شد و امروزه مورد توجه متخصصان هوش مصنوعی قرار گرفته است. این شبکه ها بر مبنای رویکرد تئوری بازی ها پدید آمده اند که در آن یک شبکه یادگیری عمیق که مولد<sup>۵</sup> نامیده می شود با یک روند تخصصی رقابت می کند. شبکه عمیق دیگری که متمایز کننده<sup>۶</sup> نام دارد، تلاش می کند تا نمونه های تولید شده از شبکه مولد را از داده های اصلی تمایز کند. رقابت بین این دو شبکه در نهایت باعث یادگیری بهتر و بهبود عملکرد هر دو می شود. در این روش شبکه می آموزد که چگونه از داده های آموزشی، داده های جدیدی پدید آورد، به طوری که از دید آماری داده های آموزشی یکسان ایجاد شوند. به عبارت دیگر، در رویکرد فوق داده هایی که برای آموزش استفاده می شوند و خروجی شبکه به لحاظ برخی ویژگی ها شبیه هستند. در شبکه های فوق وظیفه تولید خروجی بر عهده بخش مولد و وظیفه بررسی شباهت بر عهده متمایز کننده است. شبکه مولد تخصصی رویکردی برای مدل سازی مولد با استفاده از شبکه های عصبی کانولوشنی<sup>۷</sup> است. مدل سازی مولد بر اساس اکتشاف خودکار و یادگیری قواعد یا الگوهای موجود در داده های ورودی است. این کار به گونه ای انجام می شود که از مدل می توان برای تولید یا خروجی گرفتن نمونه های جدیدی از مجموعه داده اصلی استفاده کرد [۴۵]. مراحل انجام فرآیند در شکل ۳-۲ قابل مشاهده است.

<sup>1</sup> Bias

<sup>2</sup> Generative Adversarial Networks (GAN)

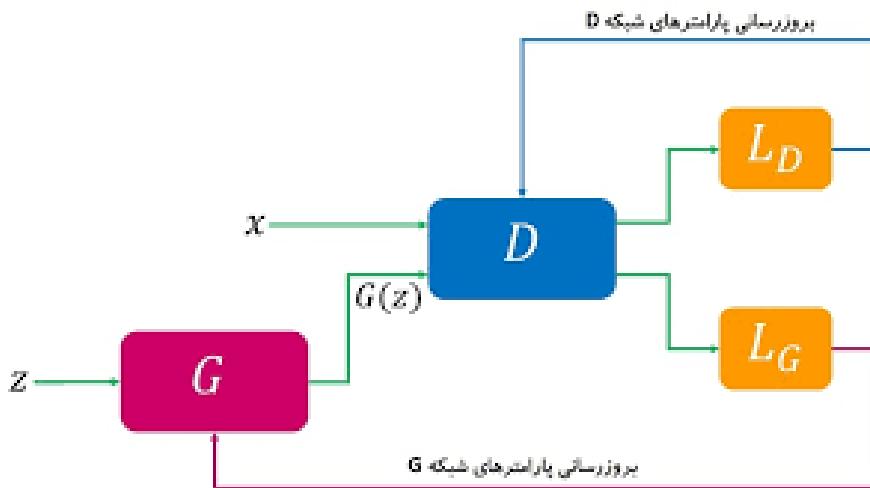
<sup>3</sup> Generative Adversarial Networks

<sup>4</sup> Ian Goodfellow

<sup>5</sup> Generator

<sup>6</sup> Discriminator

<sup>7</sup> Convolutional Neural Networks

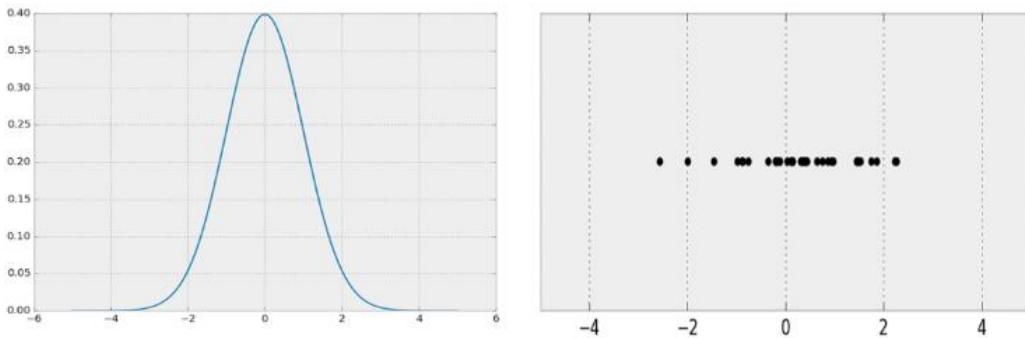


شکل ۲-۳. مراحل تولید سیگنال با استفاده از شبکه GAN.

همان‌طور که در شکل ۲-۳ مشاهده می‌شود، ورودی  $Z$  را از سیگنال رندوم نمونه‌برداری شده‌ی ساده، به‌طور مثال، توزیع نرمال یا توزیع یکنواخت که شناخته شده‌اند، دریافت و سعی در تولید سیگنال حقیقی می‌کند. سیگنالی که توسط مولد تولید شده‌اند باید به تمایزگر بفرستاد شوند تا به فرآیند آموزش تابع موجود در تمایزگر کمک کند. به صورت متناوب به تمایزگر سیگنال‌های حقیقی موجود در مجموعه دادگان را نشان می‌دهیم تا پارامترهای شبکه به درستی تنظیم شوند. در همین زمان مولد همزمان یاد می‌گیرد و سیگنال‌های واقعی تری که قادر به فریب دادن تمایزگر باشد را تولید می‌کند. همان‌طور که گفته شد تابع تمایزگر نشان‌دهنده احتمال تعلق ورودی به داده‌های اصلی است. شبکه تمایزگر به منظور بیشینه کردن دقت آن در تمایز داده‌های اصلی با داده‌های تولید شده از مولد، آموزش داده می‌شود. از طرف دیگر همزمان شبکه مولد با هدف فریب شبکه تمایزگر آموزش داده می‌شود که با کمینه نمودن معادله ۲-۲ حاصل می‌شود.

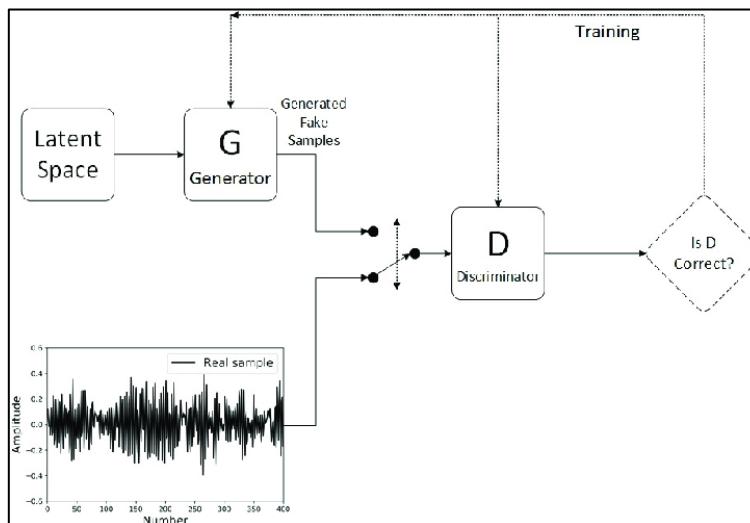
$$\log_2(1 - D(G(z))) \quad \text{معادله ۲-۲}$$

در حقیقت  $Pz$  یک توزیع نرمال از تابع توزیع احتمال می‌باشد که در شکل ۳-۳ مشاهده می‌شود. تصویر سمت چپ توزیع نرمال از تابع توزیع احتمال است و شکل سمت راست نمونه‌ای از تابع توزیع احتمال نرمال می‌باشد. رابطه‌ی کلیدی بین سیگنال و آمار چیزی است که قادر می‌سازد تا سیگنال‌ها را به عنوان نمونه‌هایی از یک تابع توزیع تفسیر شود.



شکل ۳-۳. تابع توزیع. شکل سمت راست: نمونه‌ای از تابع توزیع احتمال نرمال. شکل سمت چپ: توزیع نرمال از تابع توزیع احتمال.

نتایج داده‌افزایی در مدل‌های با عملکرد بهتر هم مهارت مدل را افزایش می‌دهند و هم یک اثر تنظیم‌کننده به همراه دارند که خطای تعمیم را کاهش می‌دهد. داده‌افزایی با ساخت نمونه‌های جدید، مصنوعی، اما قابل اعتماد از دامنه مسئله ورودی کار می‌کند که مدل روی آن آموزش دیده است. مدل‌سازی مولد موفق، یک جایگزین و رویکرد دامنه محورتر را برای داده‌افزایی فراهم می‌کند. در حقیقت، داده‌افزایی نسخه ساده شده مدل‌سازی مولد است. در دامنه‌های پیچیده یا دامنه‌هایی با حجم محدودی از داده‌ها، مدل‌سازی مولد مسیری به سوی آموزش بیشتر برای مدل‌سازی ارایه می‌کند. شبکه‌های مولد تخصصی به شکل قابل توجهی باعث بهبود عملکرد یادگیری ماشین تقویتی عمیق شده‌اند. شبکه‌های مولد تخصصی قادر به تولید سیگنال‌های واقعی هستند، به‌طوری که ناظر انسانی قادر به تمایز آن‌ها از داده‌های واقعی نیست. شکل ۳-۴ نمایی کلی از شبکه مولد تخصصی برای تولید سیگنال را نشان می‌دهد.



شکل ۳-۴. نمای کلی از شبکه مولد تخصصی (GAN).

## ۲-۳ - معماری شبکه طبقه‌بندی

پس از پیش‌پردازش مجموعه دادگان نوبت به شرح معماری طبقه‌بند پیشنهادی برای طبقه‌بندی چهار کلاسه سیگنال‌های الکتروکاردیوگرام می‌رسد. همان‌طور که گفته شد، در سال‌های اخیر یادگیری عمیق تحول اساسی در الگوریتم‌های یادگیری ماشین ایجاد کرده و موفقیت‌های چشم‌گیری داشته است. یکی از مهم‌ترین ویژگی‌های شبکه‌های عمیق که بسیار مورد توجه پژوهشگران می‌باشد، توانایی استخراج ویژگی به صورت خودکار است که در بطن عملیات یادگیری ماشین نهفته است و مانند مدل‌های کلاسیک قسمتی از پیش‌پردازش داده‌ها محسوب نمی‌شود. به عبارتی شبکه‌های عمیق علاوه بر عملکرد خوب در طبقه‌بندی، توانایی استخراج ویژگی خودکار از داده‌های خام را نیز دارند، به این خاصیت یادگیری ویژگی اطلاق می‌شود. از طرفی روش‌های مبتنی بر ویژگی نیز از سال‌های دور توانایی خود در مسائل طبقه‌بندی را ثابت کرده‌اند. همان‌طور که گفته شد، هر کدام از رویکردهای طبقه‌بندی مبتنی بر ویژگی و مبتنی بر شبکه‌های عمیق مزیت‌های خاص و منحصر به فرد خود را دارند، در روش پیشنهادی خود جهت استفاده از مزیت هر دو رویکرد از ترکیب ویژگی‌های استخراج شده این دو رویکرد استفاده شده است. به این ترتیب که برای هر سیگنال الکتروکاردیوگرام ابتدا ۶۴ ویژگی ساختاری استخراج شده و سپس به منظور استخراج ساختارهای ناشناخته در توزیع سیگنال‌های الکتروکاردیوگرام و کشف الگوهای ناشناخته در سیگنال‌های قلبی، خروجی لایه ماقبل آخر شبکه عمیق پیشنهادی به عنوان ویژگی‌های عمیق هر سیگنال در نظر گرفته شده است. در مرحله بعد ویژگی‌های ساختاری سیگنال با ویژگی‌های عمیق ترکیب شده و با استفاده از روش تحلیل مولفه‌ی اصلی تعداد آن‌ها کاهش یافته و مفیدترین ویژگی‌ها برگزیده شده‌اند. در نهایت شبکه طبقه‌بند جنگل تصادفی بر روی ترکیب ویژگی‌های ساختاری و عمیق آموزش داده‌ها را در چهار کلاس طبقه‌بندی نموده است. در ادامه جزئیات این روش پیشنهادی شرح داده خواهد شد.

### ۱-۲-۳ - استخراج ویژگی‌های ساختاری از سیگنال

استخراج ویژگی یکی از مهم‌ترین مراحل یادگیری ماشین است. هدف استخراج ویژگی این است که داده‌های خام به شکل قابل استفاده‌تری برای پردازش‌های آماری بعدی درآیند. انجام استخراج ویژگی فرآیند بسیار متداولی در پردازش انواع مختلف داده‌ها مانند پردازش تصویر، سیگنال وغیره است. استخراج ویژگی یعنی انتخاب ویژگی‌ای که بتواند با اطلاعات اندک، یک سیگنال را توصیف کند. این ویژگی‌ها باید دارای خصوصیاتی باشند که بتوان با مجموعه‌ای از آن‌ها هر سیگنال منحصر بفرد را توصیف نمود. در این فرآیند ۶۴ ویژگی ساختاری مختلف از هر سیگنال استخراج شده و برای آموزش مدل مورد استفاده قرار گرفته است. در ابتدای فرآیند استخراج ویژگی‌های ساختاری، سیگنال‌ها با فیلتر باندگذار در محدوده‌ی فرکانسی ۳ هرتز تا

BioSPPy ۴۵ هرتز فیلتر شده‌اند. سپس قله‌های R با استفاده از الگوریتم همیلتون-تامپکینز که در کتابخانه‌ی BioSPPy<sup>۱</sup> پایتون موجود است، مشخص شده‌اند. نتیجه‌ی این فرآیند، آرایه‌ای از زمان قله‌های R برای هر سیگنال است. پس از مشخص شدن قله‌های R، قالب<sup>۲</sup>‌های PQRST موج کامل استخراج شده‌اند. قالب PQRST شامل موج‌های P، QRS و T است. این قالب از ۲۵۰ میلی‌ثانیه قبل از قله‌ی R تا ۴۰۰ میلی‌ثانیه بعد از آن مشخص می‌شود. در مرحله‌ی بعد، سیگنال‌ها بر اساس دامنه‌ی قله‌ی R در قالب میانه نرم‌افزاری شده‌اند. در ادامه ویژگی‌های ساختاری استخراج شده که در ۳ گروه اصلی جای می‌گیرند شرح داده شده‌اند.

### ۳-۱-۱-۲-۳- دسته اول: ویژگی‌های شکل سیگنال کامل

در این پژوهش ویژگی‌های شکل موج از مدت زمان کامل هر سیگنال استخراج شده‌اند. ویژگی‌های شکل موج در دو دسته‌ی ویژگی‌های پایه‌ای و ویژگی‌های استخراج شده از تجزیه تبدیل موجک ثابت<sup>۲</sup> قرار می‌گیرند.

#### ویژگی‌های پایه‌ای:

ابتدا ۸ ویژگی پایه‌ای شامل موارد زیر از هر سیگنال استخراج شده است:

- حداقل
- حداکثر
- میانه
- مدت زمان
- میانگین

$$\mu = \frac{\sum_{i=1}^N X_i}{N} \quad \text{معادله ۳-۳}$$

- انحراف از معیار

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}} \quad \text{معادله ۳-۴}$$

<sup>1</sup> Template

<sup>2</sup> Stationary Wavelet Transform

## • چولگی

$$skewness = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^3}{(N - 1)\sigma^3}}$$

معادله ۳-۵

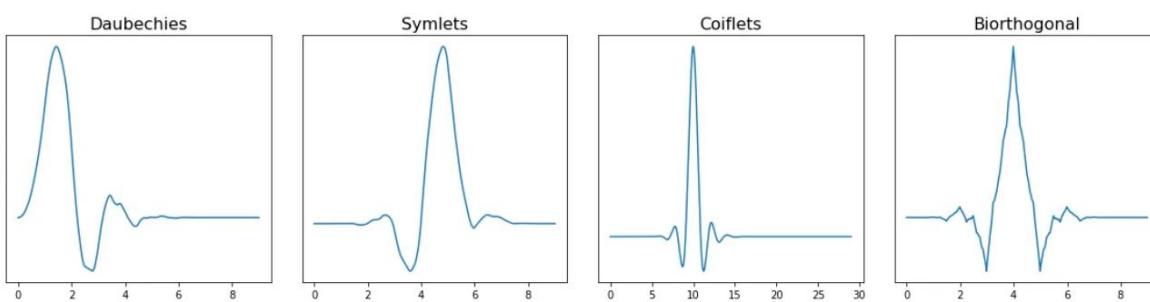
## • کشیدگی

$$kurtosis = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^4}{(N - 1)\sigma^4}}$$

معادله ۳-۶

## ✓ ویژگی‌های تبدیل موجک ثابت:

تبدیل موجک یکی از تبدیلات مهم ریاضی است که به عنوان ابزاری کاربردی و مفید برای تحلیل سیگنال در حوزه‌ی زمان فرکانس به کار می‌رود. ایده اصلی تبدیل موجک این است که بر ضعفها و محدودیت‌های موجود در تبدیل فوریه غلبه کند. تبدیل موجک از تعدادی تابع به نام موجک استفاده می‌کند که هر کدام مقیاس متفاوتی دارند. معنی واژه موجک، موج کوچک است و توابع موجک نیز دقیقاً به همین صورت کوچک هستند. برای تفکیک یک سیگنال به زیرباندهای فرکانسی مختلف به تدریج موجک از نقاط ابتدایی سیگنال به سمت انتهای سیگنال حرکت داده شده و در سیگنال ضرب نقطه‌ای می‌شود، این عمل را کانولوشن می‌گویند. با تغییر مقیاس موجک‌ها، می‌توان سیگنال را به زیرباندهای فرکانسی مختلف تجزیه نمود. پس از تجزیه‌ی سیگنال‌ها با تبدیل موجک، مجموعه تمام ویژگی‌های ایجاد شده از هریک از زیرباندهای مختلف به عنوان ورودی به یک طبقه‌بند منتقل شده‌اند. شکل ۳-۵ تصویر چند نمونه از خانواده‌ی موجک مختلف است.



شکل ۳-۵. تصویر نمونه‌هایی از چند خانواده‌ی موجک.

همانطور که ذکر شد، علاوه بر ویژگی‌های پایه‌ای هر سیگنال، مجموعه پیشرفته‌تری از ویژگی‌های شکل موج نیز از تجزیه تبدیل موجک ثابت<sup>۱</sup> به ازای هر سیگنال استخراج شده‌اند. به این صورت که ابتدا سیگنال ECG با استفاده از تبدیل موجک، با تابع موجک مادر (db4) Daubechies 4 تا ۴ سطح تجزیه شده است. این تبدیل دو مجموعه از ضرایب تقریب و ضرایب جزئیات را به عنوان خروجی باز گردانده است، سپس این ویژگی‌ها با استفاده از این ضرایب استخراج شده‌اند. در نهایت ویژگی‌هایی که با استفاده از تمام ضرایب مختلف مربوط به یک سیگنال محاسبه شده‌اند، به یکدیگر الحق می‌شوند؛ زیرا این ویژگی‌ها در واقع متعلق به یک سیگنال هستند. در مجموع ویژگی‌های استخراج شده از تبدیل موجک شامل ویژگی‌های حوزه‌ی فرکانس و ویژگی‌های غیرخطی می‌شوند.

### ✓ ویژگی‌های حوزه‌ی فرکانس

ویژگی‌های حوزه‌ی فرکانس شامل نسبت چگالی طیفی توان بیشینه به میانگین آن برای سه زیر‌باند فرکانسی پایین، متوسط و بالا است. به منظور محاسبه‌ی این نسبت ابتدا نمودار پریودگرام با روش Welch رسم شده است. سپس حداکثر و میانگین چگالی طیفی توان در هر زیر‌باند فرکانسی به دست آمده و در نهایت نسبت چگالی طیفی توان از فرمول زیر محاسبه شده است. زیرباندهای فرکانسی به شرح زیر است:

- ۳ تا ۱۰ هرتز
- ۱۰ تا ۳۰ هرتز
- ۳۰ تا ۴۵ هرتز

$$\frac{\text{حداکثر چگالی طیفی توان}}{\text{میانگین چگالی طیفی توان}} = \text{نسبت چگالی طیفی توان}$$

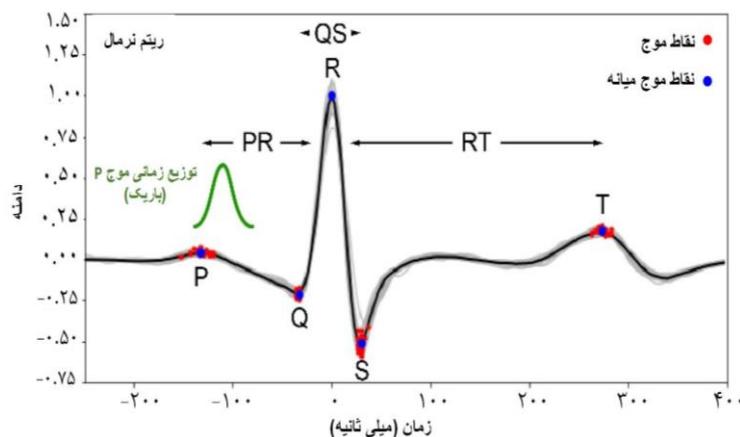
### ✓ ویژگی‌های غیرخطی

ویژگی‌های غیرخطی استخراج شده از تبدیل موجک شامل لگاریتم آنتروپی و همچنین بعد فراکتال هیگوچی می‌باشند. در هر سطح تجزیه‌ی سیگنال و ۵ ویژگی آنتروپی انرژی، نسبت چگالی طیفی توان برای زیرباند بالا، متوسط و پایین و فراکتال هیگوچی برای دو ضریب جزئیات و تقریب استخراج می‌شوند. بنابراین در هر سطح تجزیه سیگنال ۱۰ ویژگی از سیگنال استخراج می‌شود و با توجه به این که سیگنال تا ۴ سطح تجزیه شده است، در مجموع با استفاده از تبدیل موجک ۴۰ ویژگی از هر سیگنال به دست آمده است.

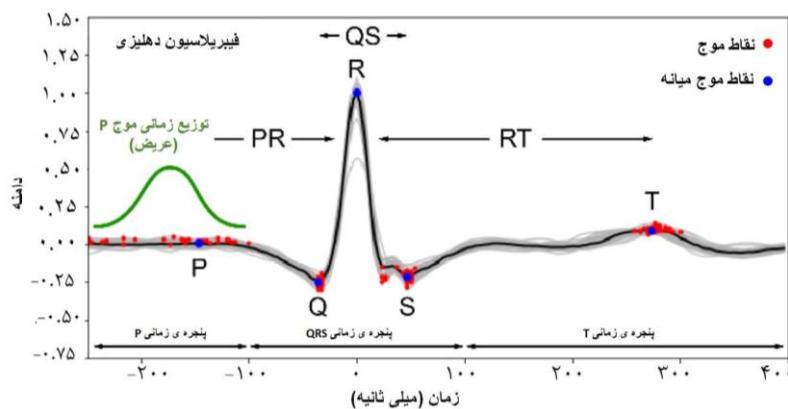
<sup>۱</sup> stationary wavelet transform decomposition

### ۳-۱-۲-۲- دسته دوم: ویژگی‌های قطعه‌های سیگنال

در ادامه‌ی فرآیند استخراج ویژگی، دامنه و زمان موج‌های P، Q، R، S، T برای هر قطعه سیگنال استخراج شده است. علاوه بر این، زمان بازه‌های PR، QS و RT و انرژی موج P و فاصله RR برای هر سیگنال نیز محاسبه و به مجموعه ویژگی‌های استخراج شده اضافه شد. این ویژگی‌ها برای ایجاد تمایز بین ریتم طبیعی و فیبریلاسیون دهلیزی مفید می‌باشند. به‌طورمثال در ریتم نرمال سینوسی، توزیع زمان‌های مربوط به موج P فشرده است که این نشان‌دهنده‌ی وجود موج P مشخص در سیگنال است. اما در سیگنال مربوط به فیبریلاسیون دهلیزی توزیع زمان‌های موج P بسیار گسترده و پراکنده است که این نشان‌دهنده‌ی عدم وجود موج P در سیگنال و از علائم بارز فیبریلاسیون دهلیزی است. در مجموع ۱۰ ویژگی نیز از این دسته استخراج شده است.



شکل ۳-۶. نمونه‌ای از نقاط موج انتخاب شده برای ریتم نرمال سینوسی.



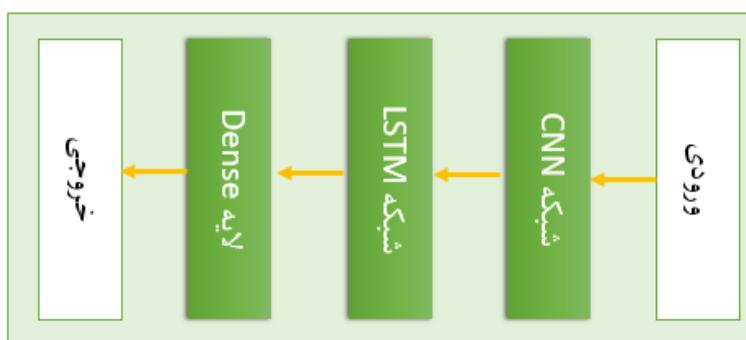
شکل ۳-۷. نمونه‌ای از نقاط موج انتخاب شده برای فیبریلاسیون دهلیزی.

### ۳-۱-۲-۲- دسته سوم: ویژگی‌های بازه RR

سری‌های زمانی زیر از قله‌های R محاسبه شده‌اند: بازه RR (RRI)، سرعت RRI و شتاب RRI. ویژگی‌های متنوعی از تغییرپذیری ضربان قلب از این سری‌های زمانی استخراج شده است که شامل آماره‌های استاندارد تغییرات ضربان قلب مانند حداکثر، حداقل، میانه، میانگین، انحراف استاندارد می‌باشد که در مجموع شامل ۶ ویژگی می‌شود.

### ۴-۲- استخراج ویژگی‌های عمیق سیگنال

در ادامه فرآیند استخراج ویژگی نوبت به استخراج ویژگی‌های عمیق هر سیگنال می‌رسد. شبکه عمیق در نظر گرفته شده در این بخش الهام گرفته از معماری ارائه شده توسط دواج ورما [۴۵] می‌باشد. طرح شماتیک این معماری که در شکل ۳-۵ نمایش داده شده است. از دو شبکه، شبکه‌های عصبی کانولوشنال<sup>۱</sup> (CNN) و شبکه‌ی عصبی حافظه طولانی کوتاه مدت<sup>۲</sup> (LSTM) به صورت متوالی تشکیل شده است. شبکه‌ی CNN عملکرد مطلوبی در یادگیری ویژگی‌های ساختاری و شبکه‌ی LSTM مناسب یادگیری ویژگی‌های زمانی داده است. با هدف بهره بردن از مزایای هر دو مدل شبکه عصبی جهت دستیابی به اطلاعات پنهان موجود در داده‌ها، در این تحقیق یک مدل ترکیبی CNN-LSTM استفاده شده است. در ادامه ابتدا دو شبکه‌ی CNN و LSTM معرفی و سپس جزئیات معماری حاصل از ترکیب شبکه‌ها شرح داده شده است.



شکل ۳-۸. طرح شماتیک از معماری در نظر گرفته شده برای استخراج ویژگی‌های عمیق.

<sup>۱</sup> Convolutional Neural Network

<sup>۲</sup> Long Short-Term Memory

### ۱-۲-۲-۳ - شبکه‌های عصبی کانولوشنال

شبکه عصبی کانولوشنال از مهمترین شبکه‌های عصبی عمیق است که معماری آن از الگویی مشابه اتصال نورون‌های مغز به یکدیگر پیروی می‌کند و از بخش Visual Cortex (بخش متعلق به بینایی مغز) الگوبرداری شده است. دسته‌های کوچکی از نورون‌های بینایی در هر قسمت به تنها‌یی مشغول هستند و از ترکیب این نورون‌ها و ایجاد شبکه‌های به هم پیوسته باعث دیدن یک منطقه می‌شود. در دهه‌ی اخیر، شبکه‌های عصبی کانولوشنال در حل مسائل بینایی ماشین<sup>۱</sup> بسیار پرکاربرد بوده‌اند. شبکه‌های عصبی کانولوشنال شبکه‌های عصبی پیش خور<sup>۲</sup> با لایه‌های متفاوت کانولوشنی و Pooling هستند. شبکه‌های عصبی کانولوشنال عمیق دو بعدی با تعداد بالای لایه‌های پنهان و میلیون‌ها پارامتر توانایی یادگیری الگوهای پیچیده را دارند. این امر نشان می‌دهد که این شبکه مناسب و مطلوب برای کاربردهای متفاوت سیگنال‌های دو بعدی مانند تصاویر است. اما شبکه‌های دو بعدی برای پردازش سیگنال‌های یک بعدی مانند سیگنال الکتروکاردیوگرام به ویژه زمانی که تعداد داده‌های در دسترس کم باشد، مناسب نیستند. برای حل این مشکل، دانشمندان اخیراً شبکه‌های عصبی کانولوشنال یک بعدی را طراحی کرده‌اند. این شبکه‌ها به روزترین و با کیفیت‌ترین عملکرد را در پردازش سیگنال‌های یک بعدی داشته‌اند. یکی دیگر از مزایای مهم شبکه عصبی کانولوشنال یک بعدی این است که ساختار فشرده و ساده‌ای دارد که فقط ضرب و جمع‌های اسکالر را انجام می‌دهد. به همین دلیل با سخت‌افزارهای مقرر به صرفه و به صورت بی‌وقفه<sup>۳</sup> می‌توان آن‌ها را پیاده‌سازی نمود و برای حل مسائل استفاده کرد.

معماری شبکه عصبی کانولوشنال در شبکه پیشنهادی از سه نوع لایه تشکیل شده است که این لایه‌ها عبارتند از لایهی کانولوشن<sup>۴</sup>، لایهی Pooling و لایهی کاملاً متصل<sup>۵</sup>. لایه‌های کانولوشن و Pooling به ترتیب عملیات استخراج ویژگی‌ها و کاهش بعد<sup>۶</sup> را انجام می‌دهند و لایه‌های کاملاً متصل نیز با استفاده از ویژگی‌های استخراج شده داده‌های ورودی را طبقه‌بندی می‌کنند. هر لایه خروجی خود را به لایهی بعدی می‌دهد. هرچه اطلاعات وارد لایه‌های عمیق‌تر شبکه می‌شوند، خروجی لایه‌ها پیچیده‌تر می‌شود. این فرآیند یادگیری<sup>۷</sup> نام دارد و هدف آن به حداقل رساندن اختلاف بین پیش‌بینی‌های شبکه و برچسب‌های واقعی داده‌هاست. شبکه این وظیفه را از طریق یک الگوریتم بهینه‌سازی که تکثیر رو به عقب را با گرادیان نزولی<sup>۸</sup> ترکیب می‌کند صورت می‌گیرد.

<sup>1</sup> Computer Vision

<sup>2</sup> Feed-Forward

<sup>3</sup> Real-Time

<sup>4</sup> Convolution

<sup>5</sup> Fully Connected

<sup>6</sup> Feature Extraction

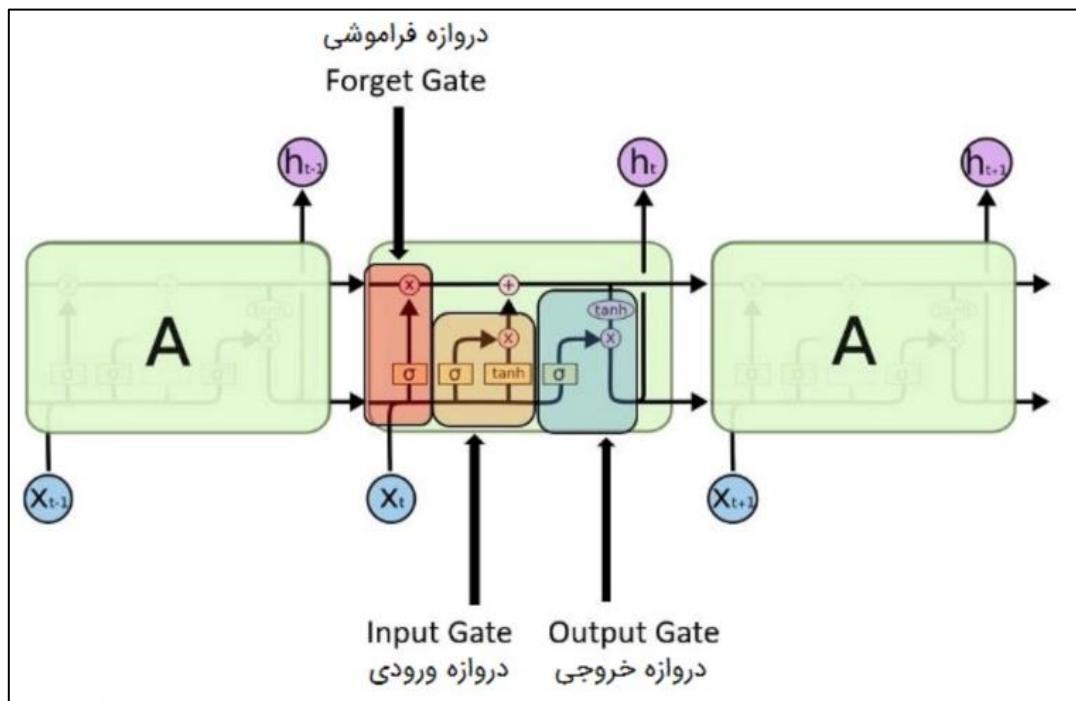
<sup>7</sup> Dimensionality Reduction

<sup>8</sup> Training

<sup>9</sup> Gradient Decent

### ۲-۲-۳-۴- شبکه‌ی عصبی حافظه طولانی کوتاه مدت

شبکه‌ی عصبی حافظه طولانی کوتاه مدت نوع خاصی از شبکه‌ی عصبی بازگشتی<sup>۱</sup> است که مشکل حافظه‌ی بلندمدت شبکه‌ی بازگشتی را حل می‌کند. شبکه‌ی عصبی حافظه طولانی کوتاه مدت توانایی یادگیری وابستگی‌های بلندمدت را دارند. این شبکه‌ها برای اولین بار توسط هاخایتر و اشمیدهور در سال ۱۹۹۷ معرفی شدند. در حقیقت هدف از طراحی شبکه‌های عصبی حافظه طولانی کوتاه مدت، حل کردن مشکل وابستگی بلندمدت بود. به یاد سپاری اطلاعات برای بازده‌های زمانی بلندمدت، رفتار پیش‌فرض و عادی شبکه‌های عصبی حافظه طولانی کوتاه مدت است و ساختار آن‌ها به صورتی است که اطلاعات خیلی دور را به خوبی یاد می‌گیرند، این ویژگی در ساختار آن‌ها نهفته است. همه شبکه‌های عصبی بازگشتی به شکل دنباله‌ای (زنجیره‌ای) تکرار شونده از مازول‌های (واحدهای) شبکه‌های عصبی هستند. در شبکه‌های عصبی بازگشتی استاندارد، این مازول‌های تکرار شونده ساختار ساده‌ای دارند، برای مثال تنها شامل یک لایه تانژانت هایپربولیک (tanh) هستند. در شکل ۳-۶ نمایشی از شبکه‌ی عصبی حافظه طولانی کوتاه مدت نمایش داده شده است.



شکل ۳-۹. نمایشی از شبکه‌ی عصبی حافظه طولانی کوتاه مدت.

<sup>۱</sup> Recurrent Neural Network

### ✓ دروازه ورودی

تشخیص می‌دهد که از کدام مقدار ورودی باید برای بهبود حافظه استفاده شود. تابع سیگموید<sup>۱</sup> تصمیم می‌گیرد که کدام مقادیر را از  $0^+$  عبور دهد. تابع  $\tanh$  به مقادیر عبور کرده، بر اساس اهمیت آن‌ها، وزنی در بازه  $1 - \tfrac{1}{C_t}$  می‌دهد.

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \end{aligned} \quad \text{معادله ۳-۷}$$

### ✓ دروازه فراموشی

تشخیص می‌دهد چه جزئیاتی را باید از بلوک دور انداخت. این موضوع توسط تابع سیگموئید تصمیم‌گیری می‌شود. تابع سیگموئید، به حالت قبلی  $h_{t-1}$  و ورودی محتوا  $x_t$  نگاه می‌کند و برای هر عدد در وضعیت سلول  $C_t$ ، عددی بین  $0$  (این را حذف کنید) و  $1$  (این را نگه دارید) به عنوان خروجی برمی‌گرداند.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad \text{معادله ۳-۸}$$

### ✓ دروازه خروجی

از ورودی و حافظه بلوک برای تصمیم‌گیری در مورد خروجی استفاده می‌شود. تابع سیگموئید تصمیم می‌گیرد که کدام مقادیر را از  $0^+$  عبور دهد. تابع  $\tanh$  به مقادیر عبور کرده، بر اساس اهمیت آن‌ها، وزنی در بازه  $1 - \tfrac{1}{C_t}$  می‌دهد و با خروجی تابع سیگموئید ضرب می‌شود.

$$\begin{aligned} o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned} \quad \text{معادله ۳-۹}$$

حال که دو معماری LSTM و CNN معرفی شد، در ادامه به شرح جزئیات شبکه‌ی ترکیبی و پارامترهای LSTM تعیین شده برای آن پرداخته خواهد شد. شبکه CNN-LSTM از یک شبکه CNN و یک شبکه LSTM ایجاد شده است. ساختار این شبکه‌ی ترکیبی در جدول ۳-۱ نشان داده شده است.

<sup>۱</sup> Sigmoid

جدول ۱-۳. لایه‌های شبکه‌ی عمیق ترکیبی

لایه‌ها	نوع لایه	تابع فعال‌ساز	اندازه کرنل	تعداد فیلتر	ابعاد خروجی	تعداد پارامترها
.	Input	-	-	-	-	-
۱	Conv1D	ReLU	۵*۱	۶۴	(None,9000,64)	۳۸۴
۲	Max Pool	-	۲*۱	-	(None,4500,64)	.
۳	Conv1D	ReLU	۵*۱	۶۴	(None,4500,64)	۲۰۵۴۴
۴	Max Pool	-	۲*۱	-	(None,2250,64)	.
۵	Conv1D	ReLU	۵*۱	۶۴	(None,2250,64)	۲۰۵۴۴
۶	Max Pool	-	۲*۱	-	(None,1125,64)	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
۲۳	Conv1d	ReLU	۵*۱	۶۴	(None,5,64)	۲۰۵۴۴
۲۴	Max Pool	-	۲*۱	-	(None,3,64)	.
۲۵	Drop out	-	۰/۵	-	(None,3,64)	.
۲۶	Flatten	-	-	-	(None,192)	.
۲۷	LSTM	ReLU	-	۲۰۰	(None,200)	۳۱۴۴۰۰
۲۸	Drop out	-	۰/۵	-	(None,200)	.
۲۹	Dense	ReLU	-	۶۰	(None,60)	۱۲۰۶۰
۳۰	Dense	-	-	۴	(None,4)	۵۱۶

شبکه‌ی عصبی کانولوشنال دارای ۱۲ لایه کانولوشنی است که تابع فعال‌ساز این لایه‌ها ReLU است. تعداد نورون‌های لایه ورودی ۹۰۰۰ است. پس از لایه‌های کانولوشنی، Max pooling و Flatten از یک لایه Dropout با اندازه ۰/۵ استفاده شده است.

بخش حافظه‌ی طولانی کوتاه مدت نیز به صورت Single و با ۲۰۰ عدد سلول ایجاد شده است. پس از لایه‌ی LSTM نیز یک لایه‌ی Dropout برای جلوگیری از بیش‌برازش در این شبکه قرار گرفته است. تابع فعال‌ساز این بخش نیز ReLU است. ۲ لایه‌ی کاملاً متصل با تعداد نورون‌های به ترتیب ۶۰ و ۴ برای طبقه‌بندی چهار کلاس داده‌های ورودی در انتهای شبکه قرار داده شده است.

برای محاسبه خطای شبکه در طبقه‌بند چهار کلاسه، ازتابع خطای آنتروپی متقاطع دسته‌ای<sup>۱</sup> استفاده شده است. تابع خطای شبکه برای  $n_{out}$  سیگنال از معادله ۳-۱۰ محاسبه می‌شود:

$$Loss = - \sum_{i=1}^{n_{out}} (T_i \log(S_i)) \quad \text{معادله ۳-۱۰}$$

در فرمول فوق  $T_i$  برابر با خروجی واقعی برای هر سیگنال و  $S_i$  نیز خروجی تخمین زده شده توسط شبکه برای سیگنال  $i$  می‌باشد. در این شبکه ترکیبی از تابع بهینه‌سازآدام برای بهینه‌سازی شبکه CNN-LSTM استفاده شده است. بعد از آموزش شبکه فوق برای ۱۰۰ دوره، خروجی لایه‌ی ماقبل آخر این شبکه که ۶۰ نورون دارد به عنوان ۶۰ ویژگی عمیق از سیگنال‌های پیش‌پردازش شده استخراج شده است.

### ۳-۲-۳- الگوریتم کاهش بعد تحلیل مولفه اصلی

با توجه به این‌که پردازش در ابعاد بالا احتمال بیش‌پردازش شبکه را افزایش و قدرت تعمیم الگوریتم را کاهش می‌دهد و هم‌چنین پردازش در ابعاد باعث کاهش سرعت الگوریتم می‌شود، نیاز است قبل از ورود داده به شبکه طبقه‌بند از روش‌های کاهش ابعاد کمک گرفته شود. الگوریتم کاهش بعد<sup>۲</sup> PCA می‌تواند مولفه‌های اصلی را شناسایی کند و کمک می‌کند تا به جای اینکه کل ویژگی‌ها مورد بررسی قرار گیرند، مجموعه‌ای از ویژگی‌هایی که ارزش‌بیشتری دارند، تحلیل شوند [۵۷]. در واقع باید در نظر داشت که روش تحلیل مولفه‌های اصلی با تحلیل ویژگی‌های موجود، مجموعه‌ای از ویژگی جدید که ارزش بیشتری فراهم می‌کنند را استخراج می‌کند. در نتیجه در معماری پیشنهادی بعد از ترکیب ویژگی‌های ساختاری (۶۴ ویژگی ساختاری) و ویژگی‌های عمیق (۶۰ ویژگی)، به منظور کاهش تعداد ویژگی‌های استخراج شده، روش تحلیل مولفه‌های اصلی به کار برده شده است تا با کاهش تعداد ویژگی‌ها از ۱۲۴ به ۳۰ علاوه بر حفظ ۹۸٪ واریانس داده‌ها، از سربار شبکه طبقه‌بند نیز کاسته شود. برای انتخاب تعداد ویژگی‌های بهینه الگوریتم PCA از روش نسبت واریانس‌ها یا  $POV^3$  استفاده شده است. در فصل بعد در بخش تنظیم ابرپارامترها با جزئیات شرح داده شده است.

<sup>۱</sup> Categorical Cross Entropy Loss

<sup>۲</sup> Principal Component Analysis

<sup>۳</sup> Proportion of Variance

### ۳-۲-۴- الگوریتم طبقه‌بند جنگل تصادفی

جنگل تصادفی (RF<sup>۱</sup>) یکی از الگوریتم‌های پرکاربرد یادگیری ماشین است. این الگوریتم که توسط دو متخصص علم آمار یعنی لئو برایمن<sup>۲</sup> ادل کاتلر<sup>۳</sup> ابداع شده است، خروجی چندین درخت تصمیم<sup>۴</sup> را برای رسیدن به یک نتیجه واحد، ترکیب می‌کند. جنگل تصادفی با استقبال خوبی توسط پژوهشگران روبرو شده است، زیرا علاوه بر سهولت در استفاده و انعطاف‌پذیری، مشکل گروه‌بندی و رگرسیون را نیز توانسته حل کند. الگوریتم جنگل تصادفی یک الگوریتم یادگیری ترکیبی<sup>۵</sup> بوده که از درخت‌های تصمیم، برای الگوریتم‌های ساده و ضعیف خود استفاده می‌کند. یک الگوریتم درخت تصمیم، می‌تواند به راحتی عملیات طبقه‌بندی را بر روی داده‌ها انجام دهد. در الگوریتم جنگل تصادفی از چندین درخت تصمیم استفاده می‌شود. در واقع مجموعه‌ای از درخت‌های تصمیم، با هم یک جنگل را تولید می‌کنند و این جنگل می‌تواند تصمیم‌های بهتری را (نسبت به یک درخت) اتخاذ نماید. در الگوریتم جنگل تصادفی به هر کدام از درخت‌ها، یک زیرمجموعه‌ای از داده‌ها تزریق می‌شود. این درخت‌ها با همین مجموعه داده‌ی زیر مجموعه، می‌توانند تصمیم بگیرند و مدل طبقه‌بندی خود را بسازند. در هنگام پیش‌بینی، یعنی وقتی که یک سری داده‌ی جدید به الگوریتم، جهت پیش‌بینی داده می‌شود، هر کدام از این الگوریتم‌های آموزش دیده، یک نتیجه را پیش‌بینی می‌کنند. الگوریتم جنگل تصادفی در نهایت، می‌تواند با استفاده از رای‌گیری، آن طبقه‌ای را که بیشترین رای را آورده است انتخاب کرده و به عنوان طبقه‌ی نهایی جهت انجام عملیات طبقه‌بندی قرار دهد. جنگل تصادفی مورد استفاده در این پژوهش از ۱۰۰ درخت تصمیم تشکیل شده است. در شکل ۳-۱۰ یک نمای کلی از الگوریتم جنگل تصادفی مورد استفاده نمایش داده شده است.

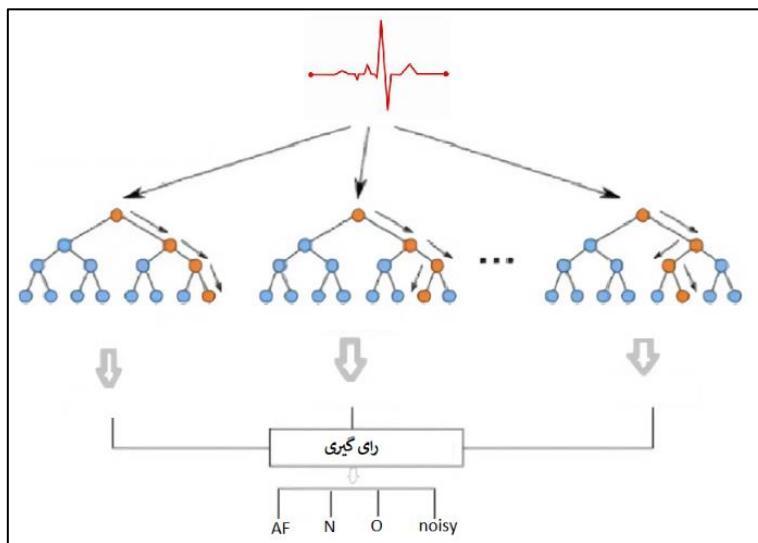
<sup>1</sup> Random Forest

<sup>2</sup> Leo Breiman

<sup>3</sup> Adele Cutler

<sup>4</sup> Decision Tree

<sup>5</sup> Ensemble Learning



شکل ۳-۱۰. نمای کلی از الگوریتم جنگل تصادفی برای طبقه‌بندی ۴ کلاسه.

### ۳-۳- جمع‌بندی

توانایی استخراج ویژگی خودکار و کشف الگوهای ناشناخته از سیگنال‌ها توسط شبکه‌های عمیق، همچنین اثبات توپولوژی روش‌های سنتی مبتنی بر ویژگی یادگیری ماشین انگیزه استفاده از ترکیب این دو رویکرد در پژوهش پیش‌رو می‌باشد. در این فصل ابتدا فرآیند پیش‌پردازش مجموعه دادگان مورد استفاده در این پژوهش شرح داده شد. این فرآیند برای رسیدن به مجموعه داده‌ای مطلوب جهت ورود به معماری طبقه‌بندی پیشنهادی است. از آنجا که یکی از مهم‌ترین چالش‌های پیش‌روی محققان حوزه‌ی پزشکی، کمبود مجموعه دادگان و از طرفی نیاز تمام شبکه‌های عمیق، داده با حجم بالا است. در مراحل پیش‌پردازش، توضیح داده شد که به منظور افزایش تعداد داده، از شبکه‌های مولد تخصصی<sup>۱</sup> استفاده شده است تا بدون دغدغه کمبود داده ادامه‌ی روند پژوهش طی شود. در ادامه نیز ویژگی‌های به معماری طراحی شده برای طبقه‌بندی چهار کلاسه سیگنال‌های الکتروکاردیوگرام شرح داده شد.

<sup>۱</sup> Generative Adversarial Networks (GAN)

## فصل چهارم

### نتایج و ارزیابی

## مقدمه

در این فصل، ابتدا ابزار پژوهش و در ادامه معیارهای مورد استفاده برای ارزیابی روش پیشنهادی معرفی شده است. سپس به شرح نحوه تعیین ابرپارامترهای شبکه‌ی عمیق پرداخته و در ادامه روش پیشنهادی با استفاده از معیارهای معرفی شده مورد ارزیابی قرار گرفته است و همچنین نتایج حاصل از روش پیشنهادی با برخی الگوریتم‌های موجود مقایسه خواهد شد.

### ۴-۱- ابزار پژوهش

در این پژوهش مرحله پردازش اصلی با زبان برنامه‌نویسی پایتون و با استفاده از کتابخانه Tensorflow<sup>۱</sup> [۵۸] و کراس<sup>۲</sup> انجام شد [۵۹]. برنامه نویسی کدهای مربوطه در محیط برنامه نویسی جوبیتر<sup>۳</sup> در نرم افزار آنکوندا<sup>۴</sup> انجام شده است. برای آموزش شبکه پیشنهادی از GPUهای شرکت گوگل (google colab) استفاده شده است.

### ۴-۲- پایگاه داده

به منظور بررسی نتایج به دست آمده از روش پیشنهادی، ابتدا لازم است که داده‌های پزشکی مورد استفاده در این پژوهش معرفی و توصیف شوند. قلب سیگنال‌های الکتریکی تولید می‌کند که می‌تواند به عنوان ابزار تشخیص عملکرد نواحی مختلف قلبی مورد استفاده قرار گیرد. پتانسیل‌های الکتریکی تولید شده توسط قلب در سراسر بدن منتشر شده و اختلاف پتانسیل‌هایی را در سطح بدن به وجود می‌آورند. در الکتروکاردیوگرافی از یک جفت الکترود که به عنوان لید معروف است، استفاده می‌شود و معمولاً این سیگنال‌ها از چند لید مختلف برداشت می‌شود. این لیدها ممکن است به صورت دو قطبی (لیدهای اصلی) یا تک قطبی انتخاب شوند. الکتروکاردیوگرام روشی سریع و آسان برای ارزیابی عملکرد قلب از جمله تشخیص دقیق آریتمی‌ها یا بی‌نظمی‌های قلب است. برای تشخیص این آریتمی‌ها چالش‌های زیادی مطرح شده است که معروف‌ترین آن‌ها می‌توان به چالش فیزیونت اشاره کرد. در ادامه به بررسی چالش فیزیونت و همچنین داده‌های ارائه شده توسط چالش فیزیونت که در این پژوهش استفاده شده‌اند، می‌پردازیم.

<sup>1</sup> Tensorflow

<sup>2</sup> Keras

<sup>3</sup> Jupyter

<sup>4</sup> Anaconda

#### ۴-۱-۲-۱- معرفی چالش فیزیونت<sup>۱</sup>

فیزیونت نام یک منبع تحقیقاتی برای سیگنال‌های فیزیولوژیکی پیچیده<sup>۲</sup> است که در سال ۱۹۹۹ با حمایت موسسه‌های ملی سلامت (NIH<sup>۳</sup>) تأسیس شد. هدف اصلی این پایگاه داده هدایت و تسريع تحقیقات و تحصیلات زیست پزشکی است که این هدف با ارائه ی دسترسی به مجموعه داده‌های فیزیولوژیکی و پزشکی و نرمافزارهای مرتبط به صورت رایگان میسر شده است. فیزیونت سالانه با مشارکت کنفرانس سالانه‌ی محاسبات قلب و عروق<sup>۴</sup> رشته‌ای از چالش‌ها را برگزار می‌کند. این چالش‌ها عمدتاً متمرکز بر مسائل حل نشده در علوم پزشکی و علوم پایه هستند که در آن‌ها از محققین و دانشجویان دعوت می‌شود که با استفاده از مجموعه داده‌های ارائه شده توسط فیزیونت به حل مسائل پزشکی بپردازند [۴۵].

این پایگاه داده توسط اعضای آزمایشگاه فیزیولوژی محاسباتی دانشگاه MIT مدیریت می‌شود. آزمایشگاه اصلی دیگر فیزیونت موسسه‌ی مارگارت و ری برای پویایی‌های غیرخطی در BIDMC<sup>۵</sup> است. پایگاه داده‌ی فیزیونت از سه بخش وابسته به یکدیگر تشکیل شده است:

- ❖ فیزیوبانک<sup>۶</sup> که یک آرشیو از سیگنال‌های پزشکی سازمان یافته، سری‌های زمانی و داده‌های مرتبط جهت تحقیقات در حوزه‌ی مهندسی پزشکی می‌باشد. این بانک داده شامل سیگنال‌های قلبی ریوی، عصبی و سایر سیگنال‌های پزشکی مربوط به افراد سالم و بیماران مبتلا به انواع مختلفی از مشکلات جسمی مانند خفگی در خواب، پیری، اختلالات راه رفتن و حرکتی، صرع، نارسایی احتقانی قلب و غیره می‌شود.

- ❖ کتابخانه‌ی نرم افزاری<sup>۷</sup> برای پردازش و تحلیل سیگنال‌های پزشکی و تشخیص بیماری‌ها با استفاده از روش‌های کلاسیک و جدید.

- ❖ مجموعه‌ای از آموزش‌ها و مواد درسی معروف و پرطرفدار که راهنمایی تخصصی در مورد تحلیل داده‌ای سلامت و سیگنال‌های پزشکی ارائه می‌دهد. این منابع آموزشی عمدتاً بر استخراج و تشخیص اطلاعات مخفی از داده‌های پزشکی تمرکز دارند. اطلاعات ارائه شده توسط آن‌ها دارای ارزش بالایی در کمک به تشخیص و پیش‌گیری بیماری‌ها و یا پیش‌بینی در علوم پایه هستند.

فیزیونت جهت تسهیل تبادل سیگنال‌های پزشکی ضبط شده و نرم افزارهای منبع باز<sup>۸</sup> به داوطلبان تحقیقات مهندسی پزشکی، وب سایتی با آدرس physionet.org تأسیس کرده است. وب سایت

<sup>1</sup> PhysioNet

<sup>2</sup> Research Resource for Complex Physiologic Signals

<sup>3</sup> National Institutes of Health

<sup>4</sup> Computing in Cardiology

<sup>5</sup> Beth Israel Deaconess Medical Center

<sup>6</sup> PhysioBank

<sup>7</sup> PhysioToolkit

<sup>8</sup> Open-source

فیزیونت علاوه بر دسترسی الکترونیکی رایگان به داده‌ها و نرم افزارها، خدماتی مانند آموزش‌های برخط<sup>۱</sup> جهت کمک به کاربران در سطوح پیشرفته ارائه می‌دهد.

زمانی که فیزیونت تأسیس شد، اعضای تیم فیزیونت در دانشگاه MIT در حال آماده‌سازی برای برگزاری رویداد CinC 2000<sup>۲</sup> بودند. هدف این رویداد معرفی فیزیونت به همه‌ی همکاران و محققین در سطح بین‌المللی بود. در این رویداد محققین به شرکت در فعالیت‌هایی تشویق می‌کرد که با استفاده از تسهیلات ارائه شده توسط فیزیونت باعث حل مسائل کاربردی و مهم در زمینه‌ی مهندسی پزشکی می‌شدند.

با استفاده‌ی به موقع از داده‌ها اولین چالش Challenge Physionet/CinC فیزیونت (Challenge Physionet/CinC) در سال ۲۰۰۰ ایجاد شد. این چالش توجه بیش از ۵ تیم به موضوع تشخیص خفگی در خواب با استفاده از سیگنال الکتروکاردیوگرام جلب نمود. تلاش محققین بسیار موفقیت آمیز بود و آن‌ها نتایج و یافته‌های خود را مورد بحث قرار دادند. این رویداد باعث تولد این سنت و برگزاری سالانه‌ی چالش‌ها در فیزیونت شد.

چالش ۲۰۱۷ فیزیونت (Physionet/CinC Challenge 2017) با هدف تشویق محققین به طراحی الگوریتم‌هایی برای طبقه‌بندی سیگنال‌های کوتاه الکتروکاردیوگرام تک لید<sup>۳</sup> با طول ۳۰ تا ۶۰ ثانیه برگزار گردید. این سیگنال‌ها در چهار کلاس ریتم سیونسی نرمال<sup>۴</sup>، فیبریلاسیون دهلیزی، سایر ریتم‌ها<sup>۵</sup> و سیگنال‌های نویزی<sup>۶</sup> قرار گرفته‌اند [۴۶].

#### ۴-۲-۲- مجموعه دادگان چالش فیزیونت

سیگنال‌های الکتروکاردیوگرام ثبت شده توسط دستگاه AliveCor که توسط کمپانی AliveCor به این چالش اهدا شده است، جمع‌آوری شده‌اند. مجموعه داده‌های آموزش شامل ۸۵۲۸ سیگنال الکتروکاردیوگرام تک لید است که طول این سیگنال بین ۹ تا ۶۰ ثانیه می‌باشد و توسط یک متخصص برچسب گذاری شده‌اند. مجموعه داده‌های آزمایشی نیز شامل ۳۶۵۸ سیگنال الکتروکاردیوگرام ثبت شده با طول مشابه داده‌های آموزشی می‌باشد. مجموعه داده‌های آزمایشی برای عموم قابل دسترس نیست و جهت ارزیابی و امتیازدهی به الگوریتم‌های شرکت‌کننده در چالش تهیه شده است.

سیگنال‌های الکتروکاردیوگرام با فرکانس ۳۰۰ هرتز نمونه‌برداری شده‌اند و توسط دستگاه AliveCore فیلتر باند گذر<sup>۷</sup> حفظ سیگنال‌ها در یک محدوده‌ی فرکانسی خاص و حذف فرکانس‌های خارج از محدوده

<sup>1</sup> Online

<sup>2</sup> Computers in Cardiology

<sup>3</sup> Single Lead Short ECG

<sup>4</sup> Normal Sinus Rhythm

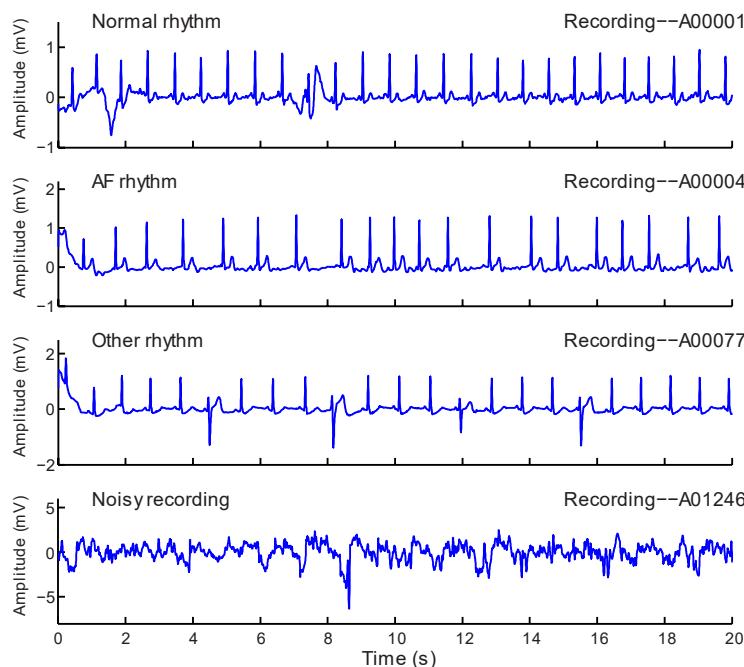
<sup>5</sup> Other Rhythms

<sup>6</sup> Too Noisy to be Classified

<sup>7</sup> Band Pass Filter

روی آن اعمال شده است. این دستگاه قابل حمل با دست بوده و سیگنال‌های ثبت شده را به صورت خودکار و همزمان در اپلیکیشن تلفن همراه هوشمند بارگزاری می‌کند.

هریک از سیگنال‌ها توسط فردی که یکی از سه نسل دستگاه AliveCore تک کاناله را خریده باشد، ثبت شده است. به این ترتیب که فرد هریک از الکترودهای دستگاه را در هر دست گرفته و یک سیگنال الکتروکاردیوگرام تک لید ایجاد می‌شود. بسیاری از سیگنال‌ها معکوس بودند، زیرا در دستورالعمل استفاده از دستگاه، جهت استفاده خاصی تعریف نشده است. سپس دستگاه سیگنال را برای میانگین مدت زمان ۳۰ ثانیه ضبط می‌نمود. سپس سخت افزار مربوطه داده‌ها را با استفاده از اپلیکیشن در یک گوشی هوشمند یا تبلت به صورت خودکار و صوتی با میکروفون (از طریق هوا و نه سیم) بارگزاری می‌نمود. این عمل با استفاده از یک انتقال‌دهنده با فرکانس ۱۹ کیلوهرتز و شاخص مدولاسیون ۲۰۰ هرتز بر میلی‌ولت انجام می‌شود. داده‌ها به صورت همزمان<sup>۱</sup> با رزولوشن ۲۴ بیت و فرکانس ۴۴/۱ کیلوهرتز دیجیتال‌سازی می‌شدند. در نهایت داده‌ها در فایل‌هایی با فرکانس ۳۰۰ هرتز و ۱۶ بیت با پهنای باند ۴۰/۵ هرتز ذخیره می‌شدند. جزئیات بیشتر در مورد داده‌ها در جدول زیر نشان داده شده است. شکل ۴-۱ نیز نمونه‌هایی از سیگنال الکتروکاردیوگرام از چهار کلاس نرمال سینوسی، فیبریلاسیون دهلیزی، سایر ریتم‌ها و ریتم‌های نویزی را نشان می‌دهد.



شکل ۴-۱. نمونه‌های سیگنال الکتروکاردیوگرام از چهار کلاس مجموعه دادگان.

<sup>۱</sup> Real time

در جدول ۴-۱ نیز اطلاعات مربوط به کلاس‌های مختلف مجموعه دادگان نمایش داده شده است.

جدول ۴-۱. جزئیات داده‌های آموزش

نوع سیگنال	تعداد سیگنال	طول زمان (ثانیه)				
		میانگین	انحراف استاندارد	بیشینه	میانه	کمینه
نرمال	۵۱۵۴	۳۱/۹	۱۰/۰	۶۱/۰	۳۰	۹/۰
فیبریلاسیون دهلیزی	۷۷۱	۳۱/۶	۱۲/۵	۶۰	۳۰	۱۰/۰
سایر ریتم‌ها	۲۵۵۷	۳۴/۱	۱۱/۸	۶۰/۹	۳۰	۹/۱
نویزدار	۴۶	۲۷/۱	۹/۰	۶۰	۳۰	۱۰/۲
کل	۸۵۲۸	۳۲/۵	۱۰/۹	۶۱/۰	۳۰	۹/۰

#### ۴-۳-۴- معرفی معیارهای سنجش

در این پژوهش برای ارزیابی کمی روش پیشنهادی از چهار معیار  $f1\_score$ ، صحت<sup>۱</sup> و یادآوری<sup>۲</sup> و support استفاده کردایم. در ادامه به توضیح هر کدام می‌پردازیم. پیش از بررسی معیارهای سنجش مدل ابتدا به معرفی چند متغیر می‌پردازیم.

- ❖ مثبت صحیح (TP)<sup>۳</sup>: نشان‌دهنده تعداد نمونه‌هایی است که برچسب واقعی کلاس و برچسب پیش‌بینی شده نیز ۱ باشد.
- ❖ منفی صحیح (TN)<sup>۴</sup>: نشان‌دهنده تعداد نمونه‌هایی است که برچسب واقعی کلاس صفر و برچسب پیش‌بینی شده نیز صفر باشد.
- ❖ مثبت غلط (FP)<sup>۵</sup>: نشان‌دهنده تعداد نمونه‌هایی است که برچسب واقعی کلاس صفر و برچسب پیش‌بینی شده به غلط ۱ باشد.
- ❖ منفی غلط (FN)<sup>۶</sup>: نشان‌دهنده تعداد نمونه‌هایی است که برچسب واقعی کلاس ۱ و برچسب پیش‌بینی شده به غلط صفر باشد.

<sup>1</sup> Precision

<sup>2</sup> Recall

<sup>3</sup> True Positive

<sup>4</sup> True Negative

<sup>5</sup> False Positive

<sup>6</sup> False Negative

#### ۴-۱-۳-۱- معیار Precision

معیار کمی که درجه تکرارپذیری نتایج طی اندازه‌گیری‌های متوالی را صحت می‌نامند [۶۰]. نسبت تعداد پیش‌بینی‌های صحیح انجام شده، برای نمونه‌های یک کلاس خاص، به تعداد کل پیش‌بینی‌ها، برای نمونه‌های همان کلاس خاص را (این تعداد، مجموع تمامی پیش‌بینی‌های صحیح و پیش‌بینی‌های نادرست را شامل می‌شود) ارزیابی می‌کند. مقدار بالا برای معیار دقت، بیانگر تعداد کم داده‌هایی است که به اشتباه، در کلاس خاص دسته‌بندی شده‌اند. قابل توجه است که معیار دقت، فقط برای مواردی ارزیابی می‌شود که در آن‌ها، مدل دسته‌بندی تعلق یک نمونه به یک کلاس خاص را پیش‌بینی کرده باشد. معیار دقت از فرمول زیر به دست می‌آید:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad \text{معادله ۴-۱}$$

#### ۴-۲-۳-۲- معیار Recall

معیار بعدی معیار یادآوری (حساسیت) است که بیان‌کننده‌ی نسبت تعداد داده‌های درست دسته‌بندی شده در یک کلاس خاص، به تعداد کل داده‌هایی که باید در همان کلاس خاص دسته‌بندی شوند [۶۱]. مقدار بالا برای معیار یادآوری، بیانگر تعداد کم داده‌هایی است که به اشتباه، در آن کلاس خاص دسته‌بندی نشده‌اند. استفاده از این معیار، به تنها‌ی، برای ارزیابی عملکرد سیستم درست نیست و باید در کنار معیار دقت مورد استفاده قرار بگیرد. زیرا به راحتی می‌توان مدل‌هایی طراحی کرد که یادآوری بالایی داشته باشند و این لزوماً به معنای دقت بالا نیست. یادآوری از فرمول زیر به دست می‌آید:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad \text{معادله ۴-۲}$$

#### ۴-۳-۳-۳- معیار F1\_score

اگر بتوانیم معیاری ترکیبی از دو معیار Precision و Recall برای سنجش الگوریتم‌های دسته‌بندی به دست آوریم، تمرکز بر آن معیار به جای بررسی همزمان این دو، مناسب‌تر خواهد بود. مثلاً از میانگین این دو به عنوان یک معیار جدید استفاده کنیم و سعی در بالا بردن میانگین حسابی این دو داشته باشیم. اگر بخواهیم میانگین معمولی دو معیار بازخوانی و صحت را ملاک کار درنظر بگیریم، برای حالت‌هایی که صحت بالا و بازخوانی پایینی داریم (و یا بالعکس)، میانگین معمولی عددی قابل قبول خواهد بود در صورتی

که الگوریتم پیشنهادی نباید نمره قبولی بگیرد. برای رفع این نقیصه و تولید یک معیار واحد که متمایل به عدد کوچکتر باشد، از میانگین هارمونیک و با فرمول زیر استفاده می‌کنیم که به آن معیار  $f1\_score$  می‌گویند [۶۲].

$$f1\_score = \frac{2 * Recall * Precision}{Recall + Precision} \quad \text{معادله ۴-۳}$$

در این فرمول همانطور که مشاهده می‌کنید اگر یکی از دو مقدار عددی کوچک باشد، یا حتی صفر باشد، نتیجه نهایی عددی کوچک و یا صفر خواهد بود. توضیح این امر هم ساده است چون دو معیار بازخوانی و صحت اعدادی بین صفر تا یک هستند و در صورت کسر در هم دیگر ضرب شده‌اند. بنابراین نتیجه نهایی به سمت عدد کوچکتر، متمایل خواهد بود و اگر هر دو با هم، عددی بزرگ (نژدیک ۱) باشند، نتیجه نهایی به سمت یک حرکت خواهد کرد. در دنیای واقعی یک حد آستانه پذیرش هم می‌توانیم برای F1-Score تعیین کنیم مثلاً  $0.9/0.9$  و اعلام کنیم که مدل‌هایی با نمره بالاتر از این آستانه، مورد تایید نهایی قرار خواهند گرفت. در فرمول میانگین هارمونیک، وزنی مساوی به هر دو پارامتر داده‌ایم و بسته به نیاز می‌توانیم میانگین هارمونیک مرتبه‌های بالاتر یعنی  $F2$ ,  $F3$  و غیره را هم به کار ببریم.

#### ۴-۳-۴ - معیار Support

می‌دانیم از نسبت تعداد تراکنش‌هایی که در آن اشیاء A و B هر دو حضور دارند، به کل تعداد رکوردها Support به دست می‌آید که دارای مقداری عددی بین صفر و یک می‌باشد و هر چه این میزان بیشتر باشد، نشان می‌دهد که این دو شیء بیشتر با هم در ارتباط هستند. کاربر می‌تواند با مشخص کردن یک آستانه برای این معیار، تنها قوانینی را به دست آورد که Support آن‌ها بیشتر از مقدار آستانه باشد، بدین ترتیب می‌توان با کاهش فضای جستجو، زمان لازم جهت پیدا کردن قوانین انجمانی را کمینه کرد. البته باید به ضعف این روش نیز توجه داشت که ممکن است قوانین با ارزشی را بدین ترتیب از دست دهیم. در واقع استفاده از این معیار به تنها یکی کافی نیست.

#### ۴-۳-۵ - منحنی ROC

منحنی مشخصه عملکرد سیستم (ROC<sup>۱</sup>)، ارتباط بین دو معیار حساسیت و دقت را نشان می‌دهد و سطح زیر این نمودار که AUC نام دارد، معیاری برای عملکرد مدل است. هرچه مقدار AUC به یک نژدیکتر باشد، نشان‌دهنده‌ی عملکرد بهتر مدل است [۶۲].

<sup>۱</sup> Receiver Operating Characteristic

## ۴-۴- تنظیم ابرپارامترها

همانطور که در فصل روش پژوهش گفته شد، برای استخراج ویژگی‌های عمیق از مدل ترکیبی CNN استفاده شده است. شبکه CNN عملکرد مطلوبی در یادگیری ویژگی‌های ساختاری و شبکه LSTM مناسب یادگیری ویژگی‌های زمانی داده است. با هدف بهره بردن از مزایای هر دو مدل شبکه عصبی جهت دستیابی به اطلاعات پنهان موجود در داده در این پژوهش یک مدل ترکیبی CNN-LSTM که نقاط قوت هر دو مدل را دارد، استفاده شده است. همچنین برای جلوگیری از بیش‌برازش شبکه طبقه‌بند از الگوریتم کاهش بعد PCA استفاده شده است و در الگوریتم جنگل تصادفی به منظور طبقه‌بندی سیگنال‌ها در چهار کلاس آموزش دیده است. در ادامه مقادیر ابرپارامترهای هر یک از بخش‌های شبکه پیشنهادی به همراه نحوه انتخاب مقدار مناسب آن‌ها شرح داده شده است.

### ۴-۱- ابرپارامترهای شبکه CNN-LSTM

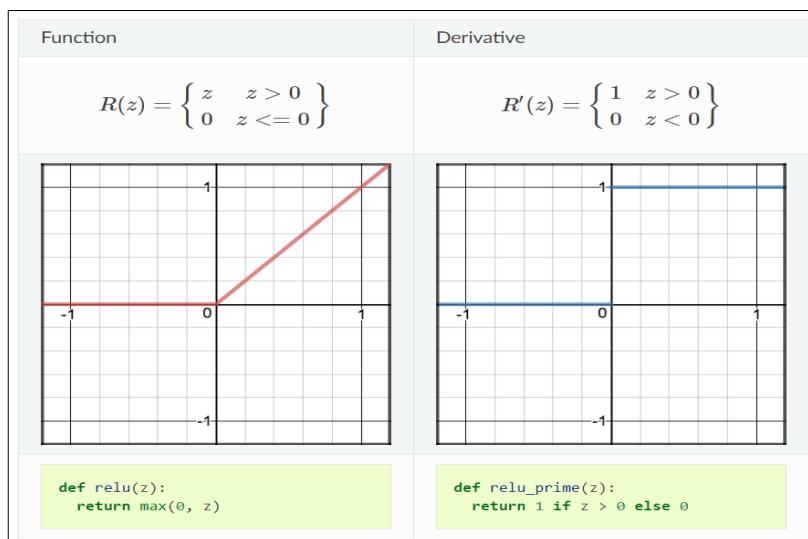
به منظور یافتن بهترین ترکیب برای ابرپارامترهای شبکه عمیق، سناریوهای مختلفی طراحی شده است که احتمال رسیدن به جواب بهینه در این سناریوهای بالاتر حدس زده می‌شد. در جدول ۴-۲، سناریو برتر و نتایج آن‌ها نشان داده شده است. در این سناریوها با تغییر ابعاد کرنل و تعداد فیلترها، دقت مدل برای ۱۰ تکرار گزارش شده است و پس از انتخاب بهترین سناریو، مدل با ۱۰۰ تکرار به آموزش دیده است.

جدول ۴-۲. سناریوهای مختلف CNN-LSTM و دقت به ازای هر سناریو.

سناریو	ابعاد کرنل	تعداد فیلترها	دقت مدل
۱	۱۵	۳۲	%۸۱/۰
۲	۱۵	۶۴	%۷۴/۳۲
۳	۱۰	۳۲	%۷۱/۸۹
۴	۱۰	۱۲۸	%۸۲/۴۰
۵	۷	۱۶	%۷۳/۱۲
۶	۷	۶۴	%۸۴
(مدل پیشنهادی)	۵	۶۴	%۸۴/۱۶

بخش CNN دارای ۱۲ لایه کانولوشنی است که به ترتیب دارای کرنل‌ها و فیلترهای مشابه و به اندازه ۶۴\*۶۴ می‌باشد. ماتریس Max polling در لایه‌های ذکر شده به صورت ۱\*۲ در نظر گرفته شده است. تعداد نورون‌های لایه ورودی ۹۰۰۰ تاست. پس از لایه‌های کانولوشنی، Flatten و Max pooling از یک لایه Dropout با اندازه ۵/۰ استفاده می‌کنیم. زیرا با افزودن لایه Dropout می‌توان جلوی بیش برآذش<sup>۱</sup> شبکه را تا حدی گرفت. Dropout به معنای صفر کردن تعدادی از نورون به صورت تصادفی در طول آموزش است. این باعث می‌شود تا از یادگیری یک مسیر تنها از ورودی به خروجی توسط شبکه جلوگیری شود. به صورت مشابه، به دلیل پارامتری شدن زیاد شبکه‌های عصبی، این امکان برای شبکه‌های عصبی وجود دارد که به صورت مؤثری ورودی را به خاطر بسپارد. اگرچه، با Dropout، تعداد بی‌نهایت شبکه را که در بود، ورودی هر برای به یک شبکه متفاوت داده می‌شود؛ زیرا Dropout می‌تواند به روش هر زمان با هم متفاوت هستند به صورت مؤثری آموزش می‌دهد. بنابراین، Dropout می‌تواند یه روش قدرتمند برای کنترل بیش برآذش بوده و مقاومت در برابر تغییرات کوچک در ورودی را پدید می‌آورد.

بخش LSTM به صورت Single و با ۲۰۰ عدد سلول ایجاد شده است. پس از لایه‌ی LSTM نیز یک لایه‌ی Dropout برای جلوگیری از بیش برآذش در این شبکه قرار گرفته است. تابع فعال‌ساز این بخش نیز ReLU است. ۲ لایه‌ی کاملاً متصل با تعداد نورون‌های به ترتیب ۲۰۰ و ۴ قادر است تا کلاس داده‌های ورودی را در چهار کلاس مذکور طبقه‌بندی کند، ابعاد داده ورودی که به صورت اعتبارسنجی متقابل ۵ لایه آماده آموزش و ارزیابی شده‌اند؛ به صورت ۹۰۰۰\*۴۸۰۰ برای هر دو کلاس است. تابع فعال‌ساز این شبکه ReLU است. تابع ReLU و مشتق اول آن در شکل ۴-۲ زیر نمایش داده شده‌اند.



شکل ۴-۲. تابع فعال‌ساز ReLU

<sup>۱</sup> Overfitting

دلایل انتخاب این تابع فعال‌ساز می‌توان به موارد زیر اشاره کرد [۶۳]:

- پیاده‌سازی ساده‌ای دارد ( $(0, x)$  Max).
- مشکل saturation یعنی از بین رفتن گرادیان را ندارد.
- از نظر محاسباتی سریع است و سرعت همگرایی را چندین برابر افزایش می‌دهد.
- از نظر بیولوژیکی محتمل‌تر<sup>۱</sup> است. الهام دقیق‌تری از نورون‌های مغزی دارد.

همچنین برای محاسبه خطای شبکه در طبقه‌بندی چهار کلاسه، از تابع خطای آنتروپی متقطع<sup>۲</sup> چند کلاسه استفاده شده است.

تابع خطای شبکه برای  $n_{out}$  سیگنال از فرمول ۵-۵ محاسبه می‌شود [۶۴]:

$$L = - \sum_{i=1}^{n_{out}} (T_i \log(S_i)) \quad \text{معادله ۴-۴}$$

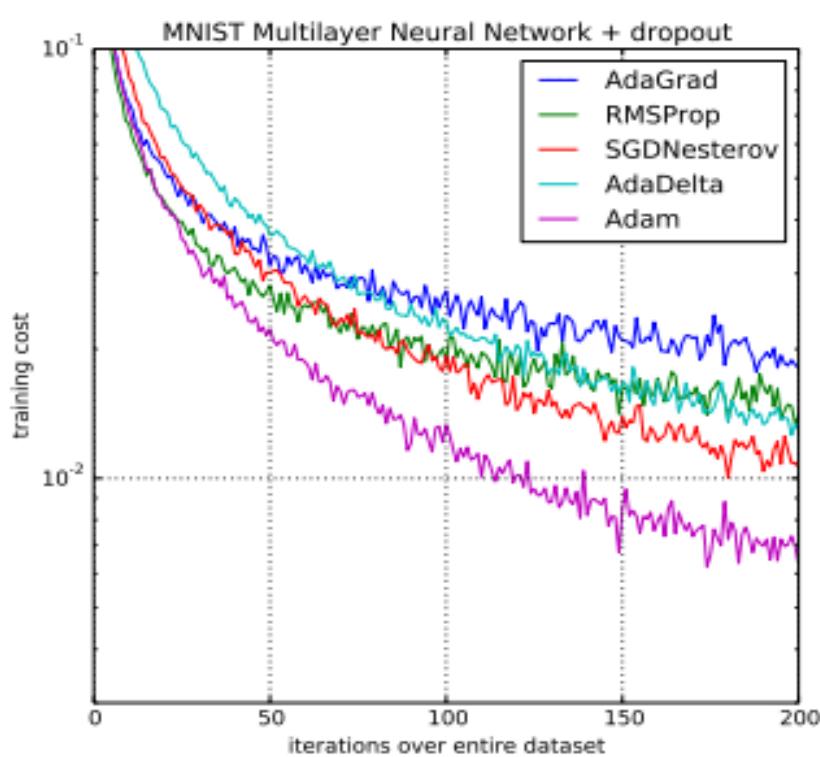
در فرمول فوق  $T_i$  برابر با خروجی واقعی برای هر سیگنال و  $S_i$  نیز خروجی تخمین زده شده توسط شبکه برای سیگنال  $i$  می‌باشد.

در این شبکه ترکیبی از تابع بهینه‌ساز آدام برای بهینه‌سازی شبکه CNN-LSTM استفاده می‌شود. الگوریتم بهینه‌ساز آدام توسعه یافته الگوریتم نزول شیب تصادفی<sup>۳</sup> است که اخیراً برای کاربردهای یادگیری عمیق در بینایی رایانه و پردازش زبان طبیعی مورد استفاده گسترده‌تری قرار گرفته است. در الگوریتم نزول شیب تصادفی یک نرخ یادگیری واحد برای همه به روزرسانی‌های وزن‌ها حفظ می‌شود و نرخ یادگیری در طول آموزش تغییر نمی‌کند. اما در الگوریتم آدام نرخ یادگیری در به صورت نمایی متناسب با مقادیر گرادیان‌های اخیر کاهش می‌یابد. این امر باعث افزایش سرعت یادگیری خواهد شد و نتایج تجربی نشان می‌دهد که آدام در عمل خوب عمل می‌کند [۶۵]. در شکل ۴-۳ سایر روش‌های بهینه‌سازی تصادفی مطلوب در یک فرآیند آموزش شبکه عصبی مقایسه شده است. همان‌طور که در نمودار مشخص است آدام توانسته با سرعت همگرایی بیشتری نسبت به سایر روش‌ها به خطای کمتری دست یابد.

<sup>1</sup> Plausible

<sup>2</sup> Categorical Cross Entropy Loss

<sup>3</sup> Stochastic Gradient Descent



شکل ۴-۳. مقایسه بهینه‌ساز آدام با سایر الگوریتم‌های بهینه‌ساز.

در پیاده‌سازی آدام مقدار بتا ۱ برابر با  $0/9$  و بتا ۲ برابر با  $0/999$  و همچنین نرخ یادگیری برابر با  $3 * 10^{-4}$  در نظر گرفته شده است. برای یافتن بهترین مقادیر این سه پارامتر از الگوریتم جستجوی گرید<sup>۱</sup> استفاده شده است. روش جستجوی گرید ابزاری اساسی برای بهینه‌سازی ابرپارامتر است. روش جستجوی گرید چندین ترکیب ابرپارامتر را در نظر می‌گیرد و ترکیبی را انتخاب می‌کند که نمره خطای کمتری را بر می‌گرداند. شبکه پیشنهادی برای ۱۰۰ دوره<sup>۲</sup> آموزش دیده است، زیرا با مشاهده نمودار خطای شبکه در حین آموزش مشاهده شده است که بعد از ۱۰۰ دوره خطای شبکه کاهش محسوسی نخواهد داشت. پس از انتخاب بهترین ترکیب ابرپارامترها، ساختار بهینه‌ی شبکه‌ی ترکیبی عمیق CNN-LSTM در جدول ۴-۳ نشان داده شده است.

جدول ۴-۳. لایه‌های شبکه‌ی عمیق ترکیبی.

لایه‌ها	نوع لایه	تابع فعالساز	اندازه کرنل	تعداد فیلتر	ابعاد خروجی	تعداد پارامترها
.	Input	-	-	-	-	-
۱	Conv1D	ReLU	۵*۱	۶۴	(None,9000,64)	۳۸۴
۲	Max Pool	-	۲*۱	-	(None,4500,64)	.

<sup>1</sup> Grid Search<sup>2</sup> Epoch

۲۰۵۴۴	(None,4500,64)	۶۴	۵*۱	ReLU	Conv1D	۳
.	(None,2250,64)	-	۲*۱	-	Max Pool	۴
۲۰۵۴۴	(None,2250,64)	۶۴	۵*۱	ReLU	Conv1D	۵
.	(None,1125,64)	-	۲*۱	-	Max Pool	۶
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
۲۰۵۴۴	(None,5,64)	۶۴	۵*۱	ReLU	Conv1d	۲۳
.	(None,3,64)	-	۲*۱	-	Max Pool	۲۴
-	(None,3,64)	-	۰/۵	-	Drop out	۲۵
-	(None,192)	-	-	-	Flatten	۲۶
۳۱۴۴۰۰	(None,200)	۲۰۰	-	ReLU	LSTM	۲۷
.	(None,200)	-	۰/۵	-	Drop out	۲۸
۱۲۰۶۰	(None,128)	۶۰	-	ReLU	Dense	۲۹
۵۱۶	(None,4)	۴	-	-	Dense	۳۰

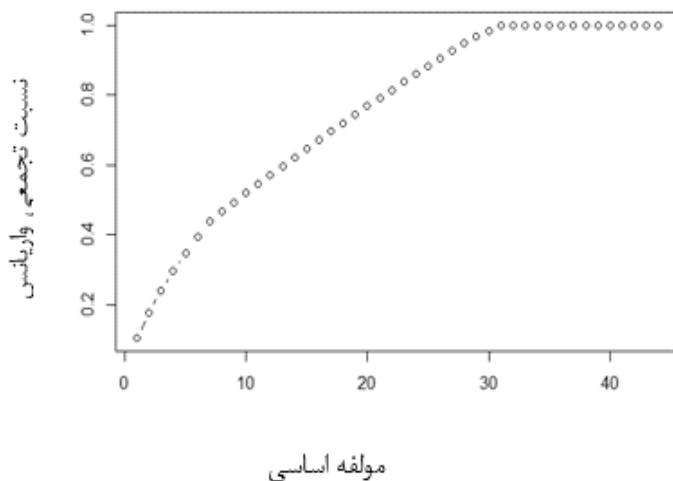
#### ۴-۴-۲- ابرپارامترهای روش تحلیل مولفه‌ی اصلی

گاه‌ها ممکن است در کاربردهای مختلف با حالت‌هایی مواجه شویم که در آن‌ها ابعاد مجموعه دادگان بسیار بزرگ باشد. به عبارت دیگر تعداد ویژگی‌ها بسیار زیاد است. این بزرگ بودن سبب پیچیدگی داده‌ها و در نتیجه پیچیده‌تر شدن مدل‌های یادگیری ماشین می‌شود. در نتیجه این امر باعث افزایش حجم محاسبات می‌گردد و همچنین قابلیت تفسیرپذیری مدل نیز کاهش می‌یابد. لذا با توجه به تمامی موارد گفته شده نیاز به روش‌هایی جهت کاهش ابعاد حس می‌شود. همانطور که در فصل روش پیشنهادی نیز گفته شده در این پژوهش برای کاهش ابعاد ویژگی‌ها از الگوریتم PCA استفاده شده است.

یکی از مباحث مهم در PCA انتخاب تعداد ویژگی‌هایی است که میخواهیم آن‌ها را انتخاب کنیم. اگر این تعداد کوچک انتخاب شود تعداد ویژگی‌ها کم خواهد بود و ویژگی‌های انتخابی نمی‌توانند به خوبی سایر ویژگی‌ها را نمایندگی کنند و اگر بزرگ انتخاب شود، تعداد ویژگی‌هایی به دست آمده خیلی به تعداد ویژگی‌های اصلی نزدیک است و ابعاد ما به اندازه‌ی کافی کاهش نیافته است. یکی از راه‌های یافتن تعداد ویژگی‌ها، روش نسبت واریانس‌ها یا  $POV^1$  می‌باشد که در ادامه نحوه انتخاب تعداد ویژگی‌ها با استفاده از این روش شرح داده شده است.

<sup>1</sup> Proportion of Variance

در روش تحلیل مولفه اساسی هدف پیدا کردن مولفه‌هایی است که بیشترین اطلاعات را در بردارند. با محاسبه بخشی از واریانس که توسط هر مولفه ارائه می‌شود، می‌توان اهمیت هر مولفه را استنتاج کرد. برای مثال فرض کنید که اولین مولفه  $10/3\%$  واریانس را در بر دارد. مولفه دوم  $7/3\%$  واریانس را در بر دارد. مولفه سوم  $6/2\%$  واریانس را در بر دارد و به همین ترتیب برای دیگر مولفه‌ها می‌توان استنتاج کرد. بنابراین باید تصمیم گرفت که چند مولفه باید برای مدل‌سازی انتخاب شوند. برای یافتن تعداد مناسب مولفه‌ها، از نمودار سنگریزه<sup>۱</sup> استفاده می‌شود. نمودار سنگریزه برای دسترسی داشتن به مولفه‌ها یا عامل‌هایی که بیشترین تنوع در داده‌ها را دارند استفاده می‌شود. در شکل ۴-۴ نمودار واریانس تجمعی ترسیم شده است. این نمودار یک تصویر روشن از تعداد مولفه‌ها ارائه می‌کند.



شکل ۴-۴. نمودار واریانس تجمعی از تعداد مولفه‌ها.

این نمودار نشان می‌دهد که  $30$  مولفه دارای واریانسی نزدیک به  $98\%$  هستند. بنابراین، در این مساله تعداد  $30$  مولفه (از مولفه اساسی اول تا سیام) انتخاب می‌شوند. این کار گام‌های پیاده‌سازی PCA روی مجموعه داده آموزش را کامل می‌سازد. در نتیجه در این پژوهش برای طبقه‌بندی از  $30$  مولفه به عنوان ویژگی‌های موجود استفاده شده است.

#### ۴-۳-۴- ابرپارامترهای شبکه‌ی طبقه‌بند جنگل تصادفی

ابرپارامترها در جنگل تصادفی برای افزایش قدرت پیش‌بینی مدل و یا سریع‌تر کردن آن مورد استفاده قرار می‌گیرند. در ادامه، پیرامون ابرپارامترهای تابع جنگل تصادفی شده است.

**تعداد درختان تصمیم:** این ابرپارامتر که قدرت پیش‌بینی را تعیین می‌کند، در واقع تعداد درختانی است که الگوریتم برای تصمیم گیری و دریافت آرا می‌سازد. به‌طور کلی، تعداد بیشتر درخت‌ها، کارایی را افزایش می‌دهند و پیش‌بینی‌ها را پایدارتر می‌سازند، اما محاسبات را کندتر می‌کنند.

<sup>۱</sup> Scree Plot

**حداقل تعداد برگ‌ها:** این ابرپارامتر نیز که قدرت پیش‌بینی را تعیین می‌کند، دیگر ابرپارامتر مهم جنگل تصادفی است. همانطور که از نام آن مشخص است، حداقل تعداد برگ‌هایی که برای تقسیم یک نود خارجی مورد نیاز است را مشخص می‌کند.

تعیین بهترین ابرپارامترها معمولاً کار غیرممکنی است ولی با تجربه و خطا می‌توان به مقادیر مناسبی دست یافت. برای این منظور، باید تعداد زیادی از ترکیبات ابرپارامترها را مورد آزمون قرار دهیم و کارایی هر مدل به دست آمده را ارزیابی کنیم. این کار را با جستجوی گردید انجام شده است، که با انتخاب بازه کوچکی از اعداد برای هر ابرپارامتر، همه ترکیبات موجود از این بازه انتخابی مورد ارزیابی قرار می‌گیرد. نتیجه جستجوی الگوریتم جستجوی گردید تعداد درختان تصمیم برابر با ۱۰۰ پیشنهاد داده است و همچنین حداقل تعداد برگ‌های مناسب ۵ در نظر گرفته شده است.

#### ۴-۵- نتایج طبقه‌بندی روش پیشنهادی

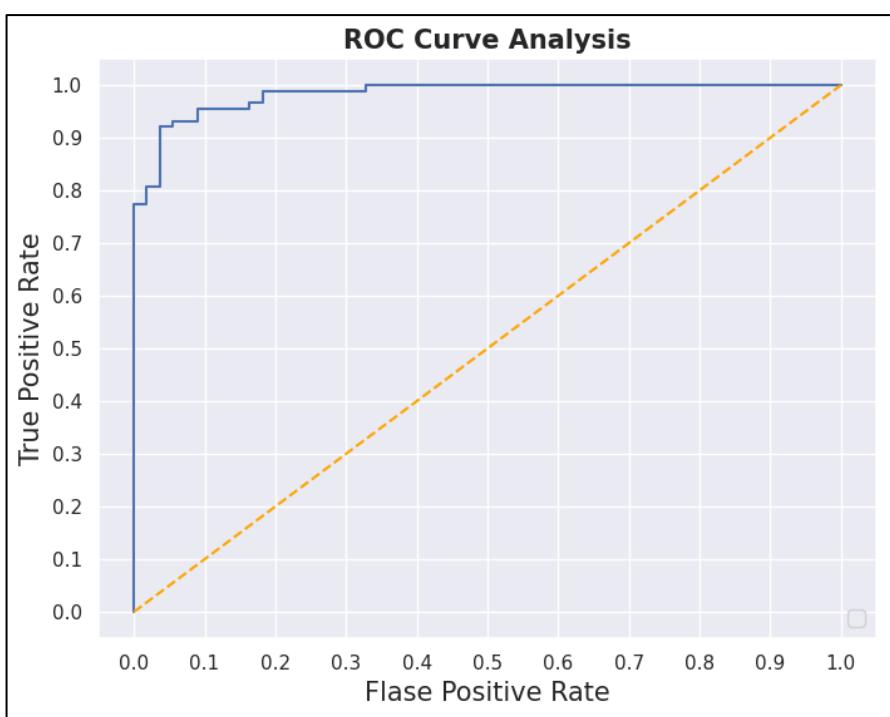
همانطور که در فصل قبل توضیح داده شد، ویژگی‌های استخراج شده از شبکه‌های عمیق و ویژگی‌های ساختاری سیگنال‌ها هر دو از مزیت‌های منحصر به فرد و خاص مربوط به خود برخوردارند. به همین سبب در روش پیشنهادی این پژوهش جهت بهره بردن از مزیت ویژگی‌های عمیق و ساختاری از ترکیب هر دو نوع به عنوان ورودی برای الگوریتم طبقه‌بند استفاده شده است. به بیان دیگر، پس از آموزش شبکه‌ی عمیق CNN-LSTM، تعداد ۶۰ ویژگی از لایه ماقبل آخر شبکه استخراج شده است. سپس ویژگی‌های عمیق با ویژگی‌های ساختاری هر سیگنال که تعداد آن ۶۴ است، ترکیب شده است. در نتیجه، مجموعاً ۱۲۴ ویژگی به ازای هر سیگنال خواهیم داشت. در نهایت از ۱۲۴ ویژگی موجود، با استفاده از روش تحلیل مولفه‌ی اصلی، ۳۰ ویژگی مفید که درصد واریانس داده‌ها را حفظ می‌کنند، از سیگنال‌ها استخراج می‌شود. این ویژگی‌ها با استفاده از الگوریتم طبقه‌بند جنگل تصادفی که پیش‌تر در فصل روش پژوهش مفصل شرح داده شده است، در چهار کلاس مورد نظر طبقه‌بندی می‌شوند. در جدول ۴-۴ نتایج حاصل از طبقه‌بندی با استفاده از روش پیشنهادی گزارش شده‌اند.

جدول ۴-۴. ارزیابی شبکه‌ی طبقه‌بند چهار کلاسه با روش پیشنهادی با چهار معیار ارزیابی مختلف.

کلاس	precision	recall	f1-score	support
۰	۰.۸۹	۰.۸۷	۰.۸۸	۵۲۴
۱	۰.۹۹	۰.۹۹	۱	۵۰۵
۲	۰.۸۷	۰.۸۸	۰.۸۸	۵۱۰
۳	۱	۱	۱	۵۲۳

<i>Accuracy</i>	-	-	0.94	2062
<i>macro avg</i>	0.94	0.94	0.94	2062
<i>Weighted avg</i>	<u>0.94</u>	<u>0.94</u>	<u>0.94</u>	2062

همانطور که از نتایج جدول فوق مشخص است، روش پیشنهادی ارائه شده در این پژوهش موفق شده است با  $f1\text{-score}$  ۰.۹۴٪ سیگنال را در چهار کلاس طبقه‌بندی کند. همچنین منحنی مشخصه عملکرد روش پیشنهادی در شکل ۴-۵ رسم شده است.



شکل ۴-۵. منحنی مشخصه عملکرد روش پیشنهادی.

منحنی مشخصه عملکرد سیستم که ارتباط بین دو معیار حساسیت و دقت را نشان می‌دهد و همانطور که از شکل فوق مشخص است، سطح زیر این نمودار که AUC نام دارد بسیار به یک نزدیک می‌باشد، که نشان‌دهنده‌ی عملکرد خوب روش پیشنهادی است.

## ۶-۴- ماتریس درهم ریختگی

در این بخش به بررسی ماتریس درهم ریختگی پرداخته شده است. ستون‌های این ماتریس مقادیر پیش‌بینی شده و سطرهای آن برچسب‌های واقعی داده‌ها را نشان می‌دهد. این ماتریس روشی برای ارزیابی عملکرد طبقه‌بند ارائه شده است. شکل ۶-۴ ماتریس درهم ریختگی طبقه‌بند ارائه شده را نشان می‌دهد.

برچسب پیش‌بینی شده

		۴۶۲	۱	۶۴	.
		۰	۴۹۷	۰	۰
		۵۳	۰	۴۷۸	۰
		۰	۰	۰	۵۰۷
نوع زدنار	فیبریلاسیون دهلیزی	سلایر دیتم ها	فیبریلاسیون دهلیزی	سلایر دیتم ها	نوع زدنار
نوع زدنار		فیبریلاسیون دهلیزی		سلایر دیتم ها	

شکل ۶-۴. ماتریس درهم ریختگی طبقه‌بند.

همان‌طور که در فصل سوم توضیح داده شد، مزیت روش پیشنهادی و برتری آن نسبت به سایر روش‌های ارائه شده این است که در آن از ترکیب ویژگی‌های عمیق و ساختاری استفاده شده است. بدین معنا که از مزایای ویژگی‌های استخراج شده از شبکه‌های عمیق و اطلاعات به دست آمده از لایه‌های پنهان شبکه و همچنین ویژگی‌های ساختاری سیگنال که از تفسیرپذیری بالایی برخوردارند، استفاده مفیدی شده است. جهت نشان دادن برتری روش پیشنهادی نسبت به حالتی که تنها از یکی از دو رویکرد مبتنی بر ویژگی‌های ساختاری و یا مبتنی بر ویژگی‌های استخراج شده از شبکه‌های عمیق استفاده شود، نتایج روش پیشنهادی با نتایج این رویکردها مقایسه شده است.

در رویکرد مبتنی بر ویژگی پس از پیش‌پردازش داده‌ها، ابتدا ۶۴ ویژگی ساختاری که در فصل ۳ توضیح داده شد، از هر سیگنال استخراج شده است. بعد از مرحله استخراج ویژگی، از الگوریتم جنگل تصادفی با تعداد ۱۰۰ درخت برای طبقه‌بندی چهار کلاسه داده‌ها استفاده شده است. در این رویکرد از شبکه‌ی عمیق و ویژگی‌های استخراج شده از آن استفاده نشده و صرفاً از روش سنتی یادگیری ماشین که مبتنی بر ویژگی‌های ساختاری است، استفاده شده است. جهت طبقه‌بندی چهار کلاسه مبتنی شبکه‌های

عمیق از همان مدل طراحی شده ترکیبی CNN-LSTM برای استخراج ویژگی‌های عمیق استفاده شده است. به این ترتیب که این بار به جای آموزش شبکه و استخراج ویژگی‌ها از لایه‌ی ماقبل آخر، از شبکه‌ی عمیق ترکیبی به عنوان طبقه‌بند استفاده شده است. بدین معنا که این شبکه‌ی ترکیبی هردو وظیفه‌ی استخراج ویژگی‌ها به صورت خودکار و طبقه‌بندی داده‌ها را انجام می‌دهد. در این رویکرد تنها از ویژگی‌های عمیق به‌دست آمده از لایه‌های پنهان شبکه استفاده شده است. در جدول ۴-۵ نتایج این دو رویکرد با نتایج روش پیشنهادی مقایسه شده است.

جدول ۴-۵. مقایسه نتایج دو رویکرد با روش ترکیبی پیشنهاد شده.

روش	معیار ارزیابی	Precision	Recall	F-score
CNN-LSTM (رویکرد مبتنی بر یادگیری عمیق)	% ۸۸/۱۶	% ۸۸/۱۵	% ۸۸/۱۵	
ویژگی‌های ساختاری + جنگل تصادفی (رویکرد مبتنی ویژگی)	% ۸۵/۱۸	% ۸۷/۱۹	% ۸۶/۱۷	
روش پیشنهادی (ترکیب دو رویکرد)	% ۹۴/۰	% ۹۴/۰	% ۹۴/۰	

#### ۴-۷- مقایسه روش پیشنهادی با کارهای پیشین

برای مقایسه نتایج حاصل از روش پیشنهادی، نتایج به دست آمده در این پژوهش با کارهای زیر که برای طبقه‌بندی چهار کلاسه معرفی شده و به بالاترین دقیقت نسبت به سایر روش‌های موجود دست یافته‌اند، مقایسه شده است.

اولین مدل که توسط چوره‌ی شی و همکاران معرفی شده است، یک شبکه CNN است که ابرپارامترهای آن با استفاده از روش جستجوی گرید<sup>۱</sup> بهینه‌سازی شده است. سیگنال‌های ورودی به شبکه‌ی CNN نیز با استفاده از یک الگوریتم نرمال‌سازی طول به طول یکسان ۳۰ ثانیه رسیده‌اند که چون نرخ نمونه‌برداری ۳۰۰ نمونه در ثانیه است، معادل با ۹۰۰۰ نمونه برای هر سیگنال می‌باشد. در نهایت مقدار میانگین به دست آمده برای F-score کل برابر با ۷۸/۲٪ می‌باشد.

دومین کاری که برای مقایسه در نظر گرفته شده است، مدل معرفی شده توسط مین‌فنگ‌چانگ و همکارانش می‌باشد، آن‌ها روش ترکیبی یادگیری عمیق را که از مزایای هر دو شبکه‌ی LSTM و ResNet دو طرفه (Bi-LSTM) استفاده کرده است، پیشنهاد دادند. این مدل به ویژگی‌های تلفیقی دست می‌یابد

<sup>۱</sup> Grid Search

و تفسیرپذیری آن با استفاده از مکانیزم توجه<sup>۱</sup> بهبود می‌یابد. در نهایت مدل ارائه شده سیگنال‌های الکتروکاردیوگرام را در چهار دسته‌ی نرمال، AF، سایر ریتم‌ها و نویزدار با F-score ۰/۸۸، یادآوری ۰/۸۵۹، دقت ۰/۸۷ و صحت ۰/۸۷٪ طبقه‌بندی کرده است.

مدل سومی که به دقت خوبی در طبقه‌بندی چهار کلاسه دست یافته است، کاری است که توسط دواج‌ورما و همکارانش ارائه شده است. آن‌ها ابتدا با کمک روش بیش نمونه‌گیری<sup>۲</sup> SMOTE<sup>۳</sup> تعداد نمونه‌های کلاس‌های کم جمعیت را افزایش می‌دهد و از این طریق پایگاه داده را متوازن می‌نماید. سپس یک مدل F-score ۰/۹۱٪ دست یافته است که این امتیاز بالاترین امتیاز به دست آمده در میان تحقیقات برای طراحی الگوریتم‌های چهار کلاسه روی پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت است.

آخرین مدل برای مقایسه، مدلی است که اکسین‌چنگ‌سیو و همکارانش معرفی کرده‌اند. در این کار یک شبکه عصبی کانولوشنال با قیمانده با تجزیه چند مقیاسی بهبود یافته (FDResNets) پیشنهاد شده است. روش پیشنهادی برای مجموعه داده سیگنال الکتروکاردیوگرام تک لید بزرگ ارائه شده توسط چالش ۲۰۱۷ فیزیونت اعمال می‌شود. در روش پیشنهادی آن‌ها، سیگنال الکتروکاردیوگرام اصلی با اختلاف طول زیاد به نمونه‌های کوتاه ۹ ثانیه تقسیم شده است. سپس، با استفاده از تجزیه قاب موجک تجزیه شده و به نمونه‌های سیگنال فرعی در مقیاس‌های مختلف بازسازی می‌شوند. در این روش میانگین دقت آزمون شبکه عصبی با قیمانده چند مقیاسی ۰/۹۲٪ گزارش شده است و میانگین F-score ۰/۸۹٪ گزارش شده است. دقت به دست آمده از روش پیشنهادی با سایر روش‌هایی که شرح داده شده، در جدول ۴-۶ مقایسه شده‌اند.

جدول ۴-۶. مقایسه دقت روش پیشنهادی با سایر پژوهش‌های انجام شده در مساله تشخیص فیبریلاسیون دهلیزی.

نویسنده	سال	روش	دادگان	F1-Score
چور هی شی و همکاران [۵۲]	۲۰۲۰	CNN	CinC Challenge 2017 PhysioNet	۰/۷۸٪
مین فنگ چانگ و همکاران [۵۴]	۲۰۲۱	ResNet LSTM	CinC Challenge 2017 PhysioNet	۰/۸۸٪
دواج رما و همکاران [۵۶]	۲۰۱۸	CNN LSTM	CinC Challenge 2017 PhysioNet	۰/۹۱٪
اکسین‌چنگ‌سیو و همکاران [۵۵]	۲۰۱۹	FDResNets	CinC Challenge 2017 PhysioNet	۰/۸۹٪

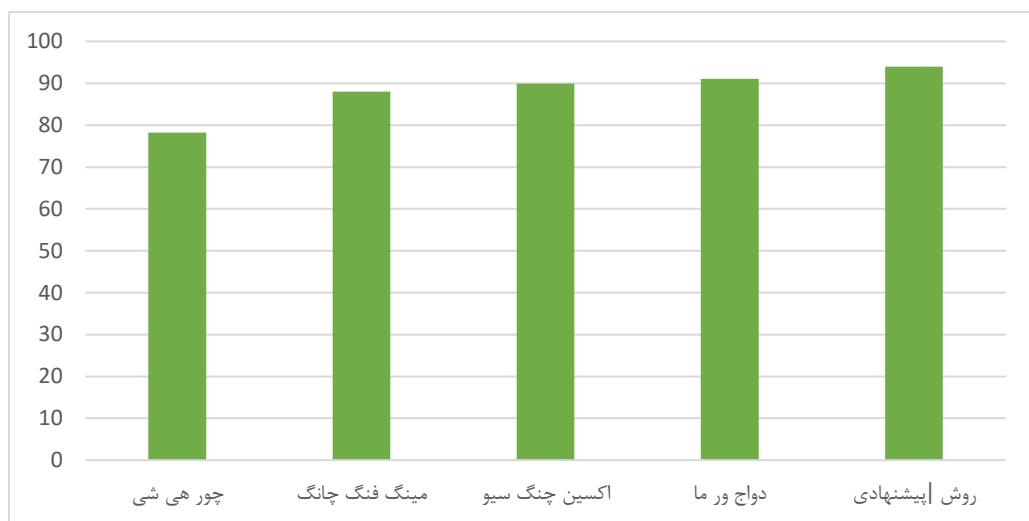
<sup>1</sup> Attention Mechanism

<sup>2</sup> Oversampling

<sup>3</sup> Synthetic Minority Over-Sampling Technique

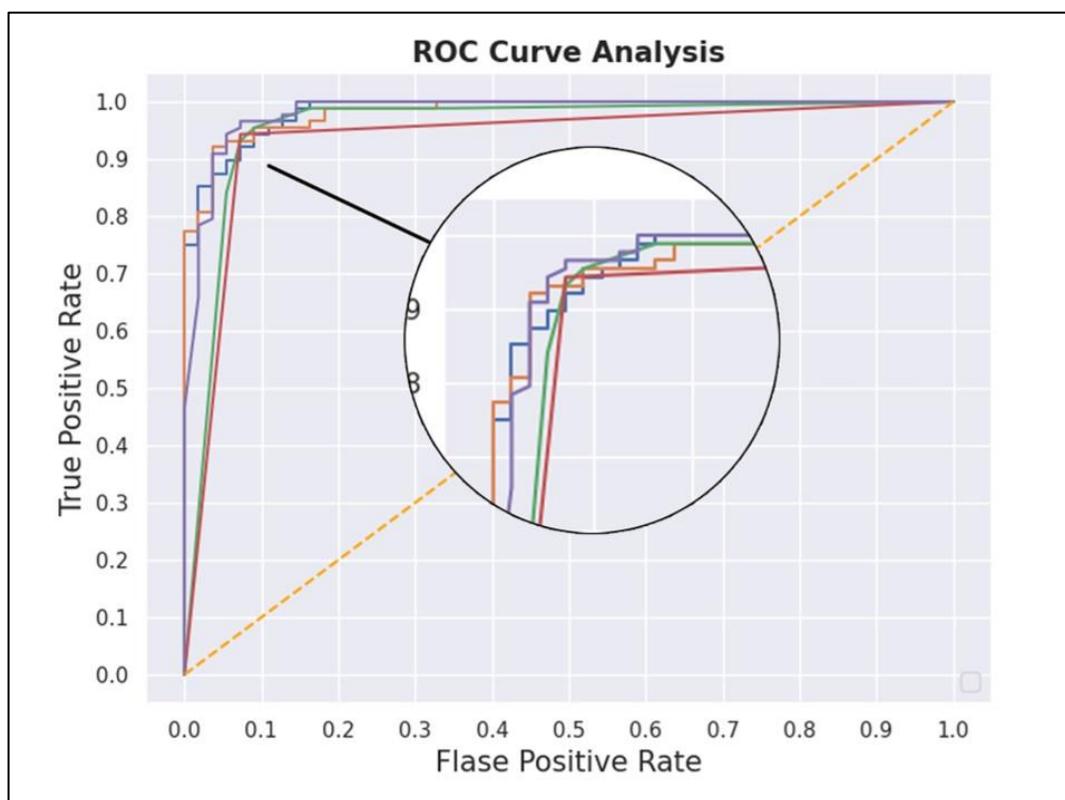
<u>روش پیشنهادی</u>	۲۰۲۳	<u>GAN</u> <u>CNN-LSTM</u> <u>RF</u>	CinC Challenge 2017 PhysioNet	%۹۴/۰
---------------------	------	--	-------------------------------	-------

همان طور که در جدول فوق مشاهده می شود، روش پیشنهادی ارائه شده در این پژوهش موفق شده است تا از بسیاری از روش های موجود پیشی بگیرد و به دقت بالاتری دست بیابد. برای مقایسه بهتر دقت این روش ها در نمودار رسم شده در شکل ۴-۷ با یکدیگر مقایسه شده اند.



شکل ۴-۷. مقایسه دقت روش پیشنهادی با سایر روش های موجود.

همچنین نمودار ROC این چهار مدل به همراه ROC روش پیشنهادی در شکل ۴-۸ ترسیم شده است.



شکل ۴-۸. مقایسه نمودار ROC چهار مدل به همراه ROC روش پیشنهادی.

**منحنی قرمز:** اکسین چنگ سیو و همکاران، **منحنی سبز:** مین فنگ چانگ و همکاران، **منحنی آبی:** چورهی شی **منحنی نارنجی:** دواج رما و همکاران **منحنی بنفش:** روش پیشنهادی

#### ۴-۸- جمع‌بندی

فیریلاسیون دهلیزی، شایع ترین آریتمی قلبی است و تشخیص به موقع و دقیق آن یک چالش بزرگ برای پژوهشگران در زمینه پزشکی است. بسیاری از تحقیقات صورت گرفته در سال‌های اخیر تلاش کرده‌اند با استفاده از روش‌های یادگیری عمیق به تشخیص و طبقه‌بندی این آریتمی بپردازنند. از طرفی دیگر بسیاری از مطالعات نیز با رویکردی متفاوت و با تمرکز بر ویژگی‌های ساختاری استخراج شده از سیگنال‌های الکتروکاردیوگرام و روش‌های سنتی یادگیری ماشین به رفع این چالش پرداخته‌اند. در این پژوهش با بهره‌گیری از مزیت‌های هر دو رویکرد مبتنی بر استخراج ویژگی‌های ساختاری و مبتنی بر استخراج ویژگی از شبکه‌های عمیق، یک روش ترکیبی برای طبقه‌بندی چهار کلاسه سیگنال‌های الکتروکاردیوگرام پیشنهاد داده شده است. در این فصل ابتدا درمورد ابزار پژوهش به کار رفته توضیح داده شده است و سپس پایگاه داده‌ی مورد بررسی معرفی شده است. در ادامه به بررسی معیارهای ارزیابی پرداخته شده است. سپس

توضیحی در مورد نحوه تنظیم ابرپارامترها ارائه شده است. در نهایت نتایج مدل پیشنهادی ارائه شده و با روش‌های مبتنی بر ویژگی و مبتنی بر شبکه‌های عمیق مقایسه شده و برتری روش ترکیبی نشان داده شده است. سپس نتایج پژوهش‌های پیشین با نتایج روش پیشنهادی مقایسه شده است. روش پیشنهادی ارائه شده در این پژوهش موفق شده است تا با F-score برابر با ۹۴٪ از بسیاری از روش‌های موجود پیشی گرفته و به دقت بالاتری دست یابد.

## فصل پنجم

جمع‌بندی، نتیجه‌گیری و پیشنهادات

## ۱-۵ - جمع‌بندی

در این پژوهش مساله طبقه‌بندی چهار کلاسه‌ی سیگنال‌های الکتروکاردیوگرام به منظور تشخیص فیبریلاسیون دهلیزی با ترکیب روش‌های یادگیری عمیق و روش‌های یادگیری ماشین سنتی مورد بررسی قرار گرفته است. داده‌های مورد استفاده در این پژوهش، پایگاه داده‌ی چالش ۲۰۱۷ فیزیونت است. این داده‌ها شامل سیگنال‌های الکتروکاردیوگرام کوتاه مربوط به چهار کلاس ریتم نرمال سینوسی، فیبریلاسیون دهلیزی، سایر ریتم‌ها و ریتم‌های نویزدار می‌باشد. جهت جلوگیری از سوگیری شبکه و افزایش تعداد داده‌ها، مجموعه داده‌ها با استفاده از الگوریتم مولد تخاصمی، متوازن شده‌اند. توانایی یادگیری و استخراج داده‌ها، مجموعه داده‌ها با استفاده از الگوریتم مولد تخاصمی، متوازن شده‌اند. توانایی یادگیری و استخراج ویژگی خودکار شبکه‌های عصبی کانولولوشنی و حافظه‌ی کوتاه مدت طولانی، انگیزه‌ما برای استفاده از این شبکه‌ها در جهت طبقه‌بندی و تشخیص دقیق‌تر این آریتمی شده است. معماری عمیق پیشنهادی با الهام از روش ترکیبی CNN-LSTM طراحی شده است. علاوه بر آن به منظور بهره بردن از تفسیرپذیری بالای ویژگی‌های ساختاری استخراج شده از سیگنال‌های الکتروکاردیوگرام، از این دسته از سیگنال‌ها نیز استفاده شده است. به این ترتیب که پس از آموزش شبکه‌ی عمیق CNN-LSTM با داده‌های متوازن شده، ابتدا از لایه‌ی ماقبل آخر آن تعداد ۶۰ ویژگی استخراج شده و سپس ویژگی‌های عمیق با ویژگی‌های ساختاری ترکیب شده و در نهایت تعداد آن‌ها با استفاده از روش تحلیل مولفه‌ی اصلی به ۳۰ ویژگی کاهش یافته است. سپس ۳۰ ویژگی حاصل با استفاده از یک الگوریتم جنگل تصادفی در چهار کلاس مذکور طبقه‌بندی شده‌اند. در نهایت روش پیشنهادی با رسیدن به دقت ۹۴ درصد موفق شده است که از سایر روش‌های موجود پیشی بگیرد.

## ۲-۵ - پیشنهادات

فیبریلاسیون دهلیزی شایع‌ترین نوع آریتمی قلبی است. اما فیبریلاسیون دهلیزی ناگهانی (PAF) معمولاً شناسایی نمی‌شود. زیرا این نوع از آریتمی معمولاً علائم خاصی که باعث مراجعه‌ی بیمار به متخصص شود ندارد. تشخیص به هنگام فیبریلاسیون دهلیزی ناگهانی جهت تصمیم‌گیری در مورد نوع درمان به‌طور مثال انجام جراحی یا نوع مداخلات دارویی بسیار حائز اهمیت است. زیرا در صورتی که بیماری پیشرفت کند، ممکن به مراحل غیرقابل درمان برسد و کیفیت زندگی بیمار کاهش یابد. اگرچه تشخیص دقیق فیبریلاسیون دهلیزی پراهمیت است، در حال حاضر الگوریتمی برای شناسایی زمان شروع و پایان این آریتمی در سیگنال‌های ثبت شده توسط دستگاه‌های قابل حمل یا پوشیدنی وجود ندارد. الگوریتم‌های تشخیص فیبریلاسیون دهلیزی که در گذشته ارائه شده‌اند، بر طبقه‌بندی ریتم‌های فیبریلاسیون دهلیزی تمرکز دارند و توجهی به تشخیص نقطه‌ی زمانی شروع و پایان آن نداشته‌اند. بنابراین تعداد نتایج و تحقیقاتی که در جهت بهبود مدیریت فرآیند درمان بیمار و شخصی‌سازی درمان برای هر بیمار انجام شده‌اند، بسیار محدود است. در نتیجه پیشنهاد می‌شود که در تحقیقات آتی تمرکز بیشتری بر روی

شناسایی بخش‌هایی از سیگنال که در آن ریتم فیبریلاسیون دهلیزی رخ می‌دهد، صورت بگیرد. تعداد و مدت رخ دادن ریتم فیبریلاسیون دهلیزی می‌تواند تفاوت‌های فیزیولوژیکی عملکرد فیبریلاسیون دهلیزی و نتایج پزشکی مرتبط با آن را تحلیل و توصیف کند. در نهایت این نتایج این نوع تحقیقات می‌تواند در شخصی‌سازی درمان بیماران مبتلا به فیبریلاسیون دهلیزی و ارزیابی نتایج درمان‌های صورت گرفته موثر باشد.

همچنین داده نقش بسیار اساسی را در طراحی و اعتبارسنجی مدل‌های تشخیص فیبریلاسیون دهلیزی ایفا می‌کند، بنابراین پایگاه داده‌ی در دسترس برای انجام این تحقیقات بسیار ارزشمند هستند تا بتوان با آن‌ها صحه‌گذاری و اعتبارسنجی و مقایسه‌ی الگوریتم‌های مختلف تشخیصی را انجام داد. متأسفانه تعداد و تنوع داده‌های در دسترس برای این موضوع کافی نیست. بنابراین پیشنهاد برای تحقیقات آتی این است که با طراحی الگوریتم‌هایی که توانایی شبیه‌سازی پایگاه داده‌های سیگنال الکتروکاردیogram را دارند، چالش کمبود داده در این زمینه را رفع کنند. الگوریتم‌هایی که کاربرد عمومی داشته و مختص به یک پایگاه داده‌ی خاص نیستند و قابلیت شبیه‌سازی سیگنال‌هایی با ریتم نرمال سینوسی، ریتم‌های فیبریلاسیون دهلیزی دارند. برای نزدیک‌تر شدن ساختار سیگنال‌های شبیه‌سازی شده به سیگنال‌های واقعی می‌توان قابلیت اضافه نمودن نویز به آن‌ها را نیز در الگوریتم طراحی شده تعییه نمود.

راه حل پیشنهادی دیگر برای مقابله با معضل کمبود داده، بهره‌گیری از روش یادگیری انتقال<sup>۱</sup> می‌باشد. یادگیری انتقال یک روش متداول برای آموزش شبکه‌های عصبی کانولوشن بر روی داده‌های پزشکی، بر اساس باز تنظیم شبکه‌های از پیش آموزش یافته<sup>۲</sup>، می‌باشد که معضل ناشی از کمبود داده‌های طبقه‌بندی شده جهت آموزش و زمان بر بودن فرآیند آموزش تا یک همگرایی مناسب را حل می‌کند. این شبکه‌ها توسط سخت‌افزارهای قوی همانند پردازشگرهای قوی گرافیکی با داده‌های میلیونی از پیش آموزش دیده‌اند. بنابراین پیشنهاد می‌شود که در تحقیقات آتی به منظور بهره‌گیری از مزایای ذکر شده از روش یادگیری انتقال نیز در طراحی معماری‌های پیشنهادی استفاده شود.

<sup>1</sup> Transfer Learning

<sup>2</sup> Pretrained Network

## منابع و مراجع

- .١ Sodmann, P., et al., *A convolutional neural network for ECG annotation as the basis for classification of cardiac rhythms*. Physiological measurement, 2018. **39**(10): p. 104005.
- .٢ William, A.D., et al., *Assessing the accuracy of an automated atrial fibrillation detection algorithm using smartphone technology: The iREAD Study*. Heart rhythm, 2018. **15**(10): p. 1561-1565.
- .٣ Kirchhof, P., et al., *2016 ESC Guidelines for the management of atrial fibrillation developed in collaboration with EACTS*. Kardiologia Polska (Polish Heart Journal), 2016. **74**(12): p. 1359-1469.
- .٤ Chugh, S.S., et al., *Worldwide epidemiology of atrial fibrillation: a Global Burden of Disease 2010 Study*. Circulation, 2014. **129**(8): p. 837-847.
- .٥ Morillo, C.A., et al., *Atrial fibrillation: the current epidemic*. Journal of geriatric cardiology: JGC, 2017. **14**(3): p. 195.
- .٦ Oldgren, J., et al., *Variations in cause and management of atrial fibrillation in a prospective registry of 15 400 emergency department patients in 46 countries: the RE-LY Atrial Fibrillation Registry*. Circulation, 2014. **129**(15): p. 1568-1576.
- .٧ Camm, A.J., G. Corbucci, and L. Padeletti, *Usefulness of continuous electrocardiographic monitoring for atrial fibrillation*. The American journal of cardiology, 2012. **110**(2): p. 27.-٢٧٩
- .٨ Humphries, K.H., et al., *New-onset atrial fibrillation: sex differences in presentation, treatment, and outcome*. Circulation, 2001. **103**(19): p. 2365-2370.
- .٩ Defaye, P., et al., *Prevalence of supraventricular arrhythmias from the automated analysis of data stored in the DDD pacemakers of 617 patients: the AIDA study*. Pacing and Clinical Electrophysiology, 1998. **21**(1): p. 250-255.
- .١٠ Nattel, S., *New ideas about atrial fibrillation 50 years on*. Nature, 2002. **415**(6868): p. 219-226.

- .١١ Rizwan, A ,et al., *A review on the state of the art in atrial fibrillation detection enabled by machine learning.* IEEE reviews in biomedical engineering, 2020. **14**: p. 219-239.
- .١٢ Qi, Y., *Random forest for bioinformatics*, in *Ensemble machine learning*. 2012, Springer. p. 307-323.
- .١٣ Staff, M.C. *Atrial Fibrillation*. 2021.
- .١٤ Faust, O., E.J. Ciaccio, and U.R. Acharya, *A review of atrial fibrillation detection methods as a service*. International journal of environmental research and public health, 2020. **17**(9): p. 309.¶
- .١٥ Charniak, E., *Introduction to artificial intelligence*. 1985: Pearson Education India.
- .١٦ Stodden, V., *The data science life cycle: a disciplined approach to advancing data science as a science*. Communications of the ACM, 2020. **63**(7): p. 58-66.
- .١٧ Mitchell, T.M., *Machine learning and data mining*. Communications of the ACM, 1999. **42**(11): p. 30-36.
- .١٨ Hastie, T., R. Tibshirani, and J. Friedman, *Overview of supervised learning*, in *The elements of statistical learning*. 2009, Springer. p. 9-41.
- .١٩ Cormack, R.M., *A review of classification*. Journal of the Royal Statistical Society: Series A (General), 1971. **134**(3): p. 321-353.
- .٢٠ Draper, N.R. and H. Smith, *Applied regression analysis*. Vol. 326. 1998: John Wiley & Sons.
- .٢١ Cortes, C. and V. Vapnik, *Support-vector networks*. Machine learning, 1995. **20**(3): p. 273-297.
- .٢٢ Hosmer Jr, D.W., S. Lemeshow, and R.X. Sturdivant, *Applied logistic regression*. Vol. 398. 2013: John Wiley & Sons.
- .٢٣ McCulloch, W.S. and W. Pitts, *A logical calculus of the ideas immanent in nervous activity*. The bulletin of mathematical biophysics, 1943. **5**(4): p. 115-133.
- .٢٤ Barlow, H.B., *Unsupervised learning*. Neural computation, 1989. **1**(3): p. 295-311.

- 
- .٢٥ Kaelbling, L.P., M.L. Littman, and A.W. Moore, *Reinforcement learning: A survey*. Journal of artificial intelligence research, 1996. **4**: p. 237-285.
- .٢٦ Rabiner, L. and B. Juang, *An introduction to hidden Markov models*. ieee assp magazine, 1986. **3**(1): p. 4-16.
- .٢٧ Zoni-Berisso, M., et al., *Epidemiology of atrial fibrillation: European perspective*. Clinical epidemiology, 2014. **6**: p. 213.
- .٢٨ Lee, J., et al., *Atrial fibrillation detection using an iPhone 4S*. IEEE Transactions on Biomedical Engineering, 2012. **60**(1): p. 203-206.
- .٢٩ Noble, W.S., *What is a support vector machine?* Nature biotechnology, 2006. **24**(12): p. 1565-1567.
- .٣٠ Peterson, L.E., *K-nearest neighbor*. Scholarpedia, 2009. **4**(2): p. 1883.
- .٣١ Dash, S., et al., *Automatic real time detection of atrial fibrillation*. Annals of biomedical engineering, 2009. **37**(9): p. 1701-1709.
- .٣٢ Lown, M., et al., *Machine learning detection of Atrial Fibrillation using wearable technology*. PLoS One, 2020. **15**(1): p. e0227401.
- .٣٣ Afdala, A., N. Nuryani, and A.S. Nugroho. *Automatic Detection of atrial fibrillation using basic Shannon entropy of RR Interval feature*. in *Journal of Physics: Conference Series*. 2017. IOP Publishing.
- .٣٤ Fan, X., et al., *Multiscaled fusion of deep convolutional neural networks for screening atrial fibrillation from single lead short ECG recordings*. IEEE journal of biomedical and health informatics, 2018. **22**(6): p. 1744-1753.
- .٣٥ Fan, X., et al., *A novel hybrid network fusing rhythmic and morphological features for atrial fibrillation detection on mobile ECG signals*. Neural Computing and Applications, 2020. **32**(12) :p. 8101-8113.
- .٣٦ Xia, Y., et al., *Detecting atrial fibrillation by deep convolutional neural networks*. Computers in biology and medicine, 2018. **93**: p. 84-92.
- .٣٧ Andersen, R.S., A. Peimankar, and S. Puthusserypady, *A deep learning approach for real-time detection of atrial fibrillation*. Expert Systems with Applications, 2019. **115**: p. 465-473.

- .٣٨ Petmezas, G., et al., *Automated atrial fibrillation detection using a hybrid CNN-LSTM network on imbalanced ECG datasets*. Biomedical Signal Processing and Control, 2021. **63**: p. 102194.
- .٣٩ Wu, X., et al. *Detection of atrial fibrillation from short ECG signals using a hybrid deep learning model*. in *International conference on smart health*. 2019. Springer.
- .٤٠ Pandey, S.K. and R.R. Janghel, *Automated detection of arrhythmia from electrocardiogram signal based on new convolutional encoded features with bidirectional long short-term memory network classifier*. Physical and Engineering Sciences in Medicine, 2021. **44**(1): p. 173-182.
- .٤١ Geweid, G.G. and J.D. Chen, *Automatic classification of atrial fibrillation from short single-lead ECG recordings using a hybrid approach of dual support vector machine*. Expert Systems with Applications, 2022. **198**: p. 116848.
- .٤٢ Xu, H., et al., *A dynamic transfer network for cross-database atrial fibrillation detection*. Biomedical Signal Processing and Control, 2024. **90**: p. 105799.
- .٤٣ Pandey, S.K., et al., *Automatic Detection of Atrial Fibrillation from ECG Signal Using Hybrid Deep Learning Techniques*. Journal of Sensors, 2022. **2022**.
- .٤٤ Zhang, H., et al., *An Effective Atrial Fibrillation Detection from Short Single-Lead Electrocardiogram Recordings Using MCNN-BLSTM Network*. Algorithms, 2022. **15**(12): p. 454.
- .٤٥ Goldberger, A.L.A., Luis A. N., et al., *{PhysioBank}, {PhysioToolkit} ,and {PhysioNet}: Components of a New Research Resource for Complex Physiologic Signals*. Circulation. **101**: p. e215--e220.
- .٤٦ Gari Clifford, C.L., Benjamin Moody, Li-Wei Lehman, Ikaro Silva, Qiao Li, Alistair Johnson, Roger Mark, *AF Classification from a Short Single Lead ECG Recording: the Physionet Computing in Cardiology Chaleenge 2017*. Computers in Cardiology 2017, 2017.
- .٤٧ Zabihi, M., et al. *Detection of atrial fibrillation in ECG hand-held devices using a random forest classifier*. in *2017 Computing in Cardiology (CinC)*. 2017. IEEE.
- .٤٨ Hong, S., et al. *ENCASE: An ENsemble CLASSifiEr for ECG classification using expert features and deep neural networks*. in *2017 Computing in cardiology (cinc)*. 2017. IEEE.

- 
- .۴۹ Datta, S., et al. *Identifying normal, AF and other abnormal ECG rhythms using a cascaded binary classifier*. in *2017 Computing in cardiology (cinc)*. 2017. IEEE.
- .۵۰ Doyle, S., et al. *Cascaded multi-class pairwise classifier (CASCAMPA) for normal, cancerous, and cancer confounder classes in prostate histology*. in *2011 IEEE international symposium on biomedical imaging: from nano to macro*. 2011. IEEE.
- .۵۱ Kopinski, T., et al. *A pragmatic approach to multi-class classification*. in *2015 International Joint Conference on Neural Networks (IJCNN)*. 2015 .IEEE.
- .۵۲ Hsieh, C.-H., et al., *Detection of atrial fibrillation using 1D convolutional neural network*. Sensors, 2020. **20**(7): p. 2136.
- .۵۳ Niu, Z., G. Zhong, and H. Yu, *A review on the attention mechanism of deep learning*. Neurocomputing, 2021. **452**: p. 48–62.
- .۵۴ Jiang, M., et al., *HADLN: Hybrid attention-based deep learning network for automated arrhythmia classification*. Frontiers in Physiology, 2021. **12**.
- .۵۵ Cao, X.-C., B. Yao, and B.-Q. Chen, *Atrial fibrillation detection using an improved multi-Scale decomposition enhanced residual convolutional neural network*. IEEE Access, 2019. **7**: p. 89152-89161.
- .۵۶ Verma, D. and S. Agarwal. *Cardiac Arrhythmia Detection from Single-lead ECG using CNN and LSTM assisted by Oversampling*. in *2018 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. 2018. IEEE.
- .۵۷ Wold, S., K. Esbensen, and P. Geladi, *Principal component analysis*. Chemometrics and intelligent laboratory systems, 1987. **2**(1-3): p. 37-52.
- .۵۸ Abadi, M., et al. *{TensorFlow}: a system for {Large-Scale} machine learning*. in *12th USENIX symposium on operating systems design and implementation (OSDI 16)*. 2016.
- .۵۹ Ketkar, N., *Introduction to keras*, in *Deep learning with Python*. 2017, Springer. p. 97-111.
- .۶۰ Davis, J. and M. Goadrich. *The relationship between Precision-Recall and ROC curves*. in *Proceedings of the 23rd international conference on Machine learning*. 2006.

- .٦١ Grandini, M., E. Bagli, and G. Visani, *Metrics for multi-class classification: an overview*. arXiv preprint arXiv:2008.05756, 2020.
- .٦٢ Fawcett, T., *An introduction to ROC analysis*. Pattern recognition letters, 2006. **27**(8): p. 861-874.
- .٦٣ Agarap, A.F., *Deep learning using rectified linear units (relu)*. arXiv preprint arXiv:1803.08375, 2018.
- .٦٤ Zhang ,Z. and M. Sabuncu, *Generalized cross entropy loss for training deep neural networks with noisy labels*. Advances in neural information processing systems, 2018. **31**.
- .٦٥ Kingma, D.P. and J. Ba, *Adam: A method for stochastic optimization*. arXiv preprint arXiv:1412.6980, 2014.
- .٦٦ Clifford, G.D., et al. *AF classification from a short single lead ECG recording: The PhysioNet/computing in cardiology challenge 2017*. in *2017 Computing in Cardiology (CinC)*. 2017. IEEE.

## Abstract

Heart arrhythmia is one of the most common heart diseases in which atrial fibrillation is the most commonly occurring arrhythmia. Atrial fibrillation can lead to several heart complications like heart failure, blood clots, and stroke and is a dangerous disease that threatens human lives. In the following research, ECG signals have been classified using artificial intelligence methods to diagnose atrial fibrillation. The utilized database is the 2017 Physionet/CinC Challenge which contains short single lead ECG signals. In the proposed method ECG signals have been classified into four categories, including atrial fibrillation, normal sinus rhythm, other rhythms, and too noisy to be classified, using the combination of traditional machine learning and deep learning methods' advantages. The features extracted automatically from deep networks have been combined with structural and key features of ECG signals and fed into a traditional machine learning classifier. In the first step, 60 features were extracted from the penultimate layer of a hybrid deep CNN-LSTM network and then combined with 64 structural features. Then the number of combined features has been reduced to 30 using principal component analysis to achieve the most important deep and structural features. Finally, the reduced features have been categorized in the mentioned four classes using a random forest classifier. The designed network has succeeded to achieve 94% accuracy which has been able to surpass other existing methods.

## KeyWord:

PhysioNet2017, deep learning, feature based, CNN-LSTM, random forest.



**Amirkabir University of Technology  
(Tehran Polytechnic)**

**Faculty of Industrial Engineering and Management Systems**

**MSc Thesis**

# **Developing a model to detect heart arrhythmia using machine learning algorithms**

**By  
Paryia Gharedaghi**

**Supervisors**  
**Dr. Abbas Ahmadi**  
**Dr. Majid Amin Nayeri**

**Advisor**  
**Dr. Sayed Habibullah Rahmati**

**February 2024**